

Formelsammlung – Sozialwissenschaftliche Methoden I (Anhang zur Klausur)

Grundlagen der deskriptiven Statistik

Formel	Beschreibung
$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	Arithmetisches Mittel
$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$	Stichprobenvarianz
$s = \sqrt{s^2}$	Standardabweichung
$z_i = \frac{x_i - \bar{x}}{s}$	Z-Standardisierung
$D = 1 - \sum_{g=1}^G \left(\frac{N_g}{N} \right)^2$	Diversität (Simpson)
Median = $\begin{cases} x_{\frac{n+1}{2}} & \text{ungerade} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & \text{gerade} \end{cases}$	Lageparameter, robust gegenüber Ausreißern
$IQR = Q_3 - Q_1$	Interquartilsabstand (Streuung der mittleren 50 % der Daten)
Whisker _u = $Q_1 - 1.5 \cdot IQR$ Whisker _o = $Q_3 + 1.5 \cdot IQR$	Boxplot-Grenzen zur Identifikation von Ausreißern

Wahrscheinlichkeiten und Verteilungen

Formel	Beschreibung
$p(X) = \frac{X}{N}$	Relative Häufigkeit
$Odd_Y = \frac{P(Y)}{1 - P(Y)}$	Odds
$RR_Y = \frac{P(Y X=a)}{P(Y X=b)}$	Relatives Risiko
$OR_Y = \frac{Odd_{Y X=a}}{Odd_{Y X=b}}$	Odds Ratio
$P(A B) = \frac{P(B A) \cdot P(A)}{P(B)}$	Satz von Bayes
$RR = \frac{OR}{1 - P_{BL} + OR \cdot P_{BL}}$	Umrechnung Odds Ratio → Relatives Risiko (bei bekanntem Baseline-Risiko P_{BL})
$OR = \frac{RR \cdot (1 - P_{BL})}{1 - P_{BL} \cdot RR}$	Umrechnung Relatives Risiko → Odds Ratio

Konzepte der Reliabilität und Validität

Formel	Beschreibung
$\rho_T = \frac{N \cdot \bar{r}}{1 + (N - 1) \cdot \bar{r}}$	Cronbachs Alpha
$y_i = \tau_i + \epsilon_i$	Klassische Testtheorie: beobachteter Wert = wahrer Wert + Messfehler
$y_{ki} = \lambda_k \cdot f_i + \epsilon_{ki}$	Faktormodell: Item k lädt mit λ_k auf latenten Faktor f

Bivariate und multivariate Regression

Formel	Beschreibung
Korrelation und Kovarianz:	
$Cov_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$	Kovarianz: gemeinsame Variation von x und y
$r_{xy} = \frac{Cov_{xy}}{s_x \cdot s_y}$	Pearsons r : standardisierte Kovarianz
Einfache lineare Regression:	
$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$	Allgemeine Form der linearen Regression
$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$	Steigungskoeffizient in der einfachen Regression
$\hat{\alpha} = \bar{y} - \hat{\beta}_1 \bar{x}$	Intercept in der einfachen Regression
Multiple Regression (2 Prädiktoren):	
$\hat{y} = \hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$	Multiple Regression mit zwei Prädiktoren
$\hat{\beta}_1 = \frac{r_{yx_1} - r_{yx_2} \cdot r_{x_1 x_2}}{1 - r_{x_1 x_2}^2} \cdot \frac{s_y}{s_{x_1}}$	Partieller Steigungskoeffizient für x_1 in multivariater Regression
$\hat{\beta}_2 = \frac{r_{yx_2} - r_{yx_1} \cdot r_{x_1 x_2}}{1 - r_{x_1 x_2}^2} \cdot \frac{s_y}{s_{x_2}}$	Partieller Steigungskoeffizient für x_2
Interaktionseffekt:	
$\hat{y} = \hat{\alpha} + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 (x_1 \cdot x_2)$	Regression mit Interaktionsterm zwischen x_1 und x_2

Inferenzstatistik und Hypothesentests

Formel	Beschreibung
$\hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$	Geschätzte Varianz einer Stichprobe
$\hat{\sigma} = \sqrt{\hat{\sigma}^2}$	Geschätzte Standardabweichung
Konfidenzintervalle:	
$UG = \bar{x} - t_{\alpha/2, df} \cdot \frac{\hat{\sigma}}{\sqrt{n}}$	Untere Grenze des Konfidenzintervalls für den Mittelwert
$OG = \bar{x} + t_{\alpha/2, df} \cdot \frac{\hat{\sigma}}{\sqrt{n}}$	Obere Grenze des Konfidenzintervalls
t-Test für einen Mittelwert (inkl. Standardfehler):	
$t = \frac{\bar{x} - \mu_0}{\hat{\sigma}_{\bar{x}}}, df = n - 1$	t-Statistik gegen einen Referenzwert von μ_0
$\hat{\sigma}_{\bar{x}} = \frac{\hat{\sigma}}{\sqrt{n}}$	zugehöriger Standardfehler des Mittelwerts
t-Test für Mittelwertdifferenzen (inkl. Standardfehler):	
$t = \frac{\bar{x}_A - \bar{x}_B}{\hat{\sigma}_{\bar{x}_A - \bar{x}_B}},$	t-Statistik für den Vergleich zweier Mittelwerte
$df = n_A + n_B - 2$	

Formel	Beschreibung
$\hat{\sigma}_{\bar{x}_A - \bar{x}_B} = \sqrt{\frac{(n_A - 1)\hat{\sigma}_A^2 + (n_B - 1)\hat{\sigma}_B^2}{n_A + n_B - 2}}$ $\sqrt{\frac{1}{n_A} + \frac{1}{n_B}}$	zugehöriger Standardfehler der Mittelwertdifferenz
t-Test für einen Regressionskoeffizienten (inkl. Standardfehler):	
$t = \frac{\hat{\beta}}{\hat{\sigma}_{\hat{\beta}}}, df = n - 2$	t-Statistik für die Signifikanz eines Steigungskoeffizienten
$\hat{\sigma}_{\hat{\beta}} = \sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}$	zugehöriger Standardfehler des Regressionskoeffizienten
z-Test für einen Anteilswert (inkl. Standardfehler):	
$z = \frac{\hat{p}}{\hat{\sigma}_p}$	z-Statistik für einen Anteilswert gegen einen Referenzwert von 0
$\hat{\sigma}_p = \sqrt{\frac{p(1-p)}{n}}$	zugehöriger Standardfehler des Anteilswerts
z-Test für eine Anteilsdifferenz (inkl. Standardfehler):	
$z = \frac{\hat{p}_1 - \hat{p}_2}{\hat{\sigma}_{p_1 - p_2}}$	z-Statistik für den Vergleich zweier Anteilswerte
$\hat{\sigma}_{p_1 - p_2} = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$	zugehöriger Standardfehler der Anteilsdifferenz
z-Test für eine Odds Ratio, log-Skala (inkl. Standardfehler):	
$z = \frac{\log(\text{OR})}{\hat{\sigma}_{\log(\text{OR})}}$	z-Statistik für die Signifikanz einer Odds Ratio
$\hat{\sigma}_{\log(\text{OR})} = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$	zugehöriger Standardfehler von log(OR) (Zellhäufigkeiten a, b, c, d der Kreuztabelle)
χ^2-Test für eine Varianz:	
$\chi^2 = df \cdot \frac{s^2}{\sigma_0^2}, df = n - 1$	Testet die Stichprobenvarianz s^2 gegen einen hypothetischen Wert σ_0^2
F-Test für ein Varianzverhältnis:	
$F = \frac{s_1^2}{s_2^2},$ $df_1 = n_1 - 1, df_2 = n_2 - 1$	Testet, ob sich die Varianzen zweier Gruppen signifikant unterscheiden