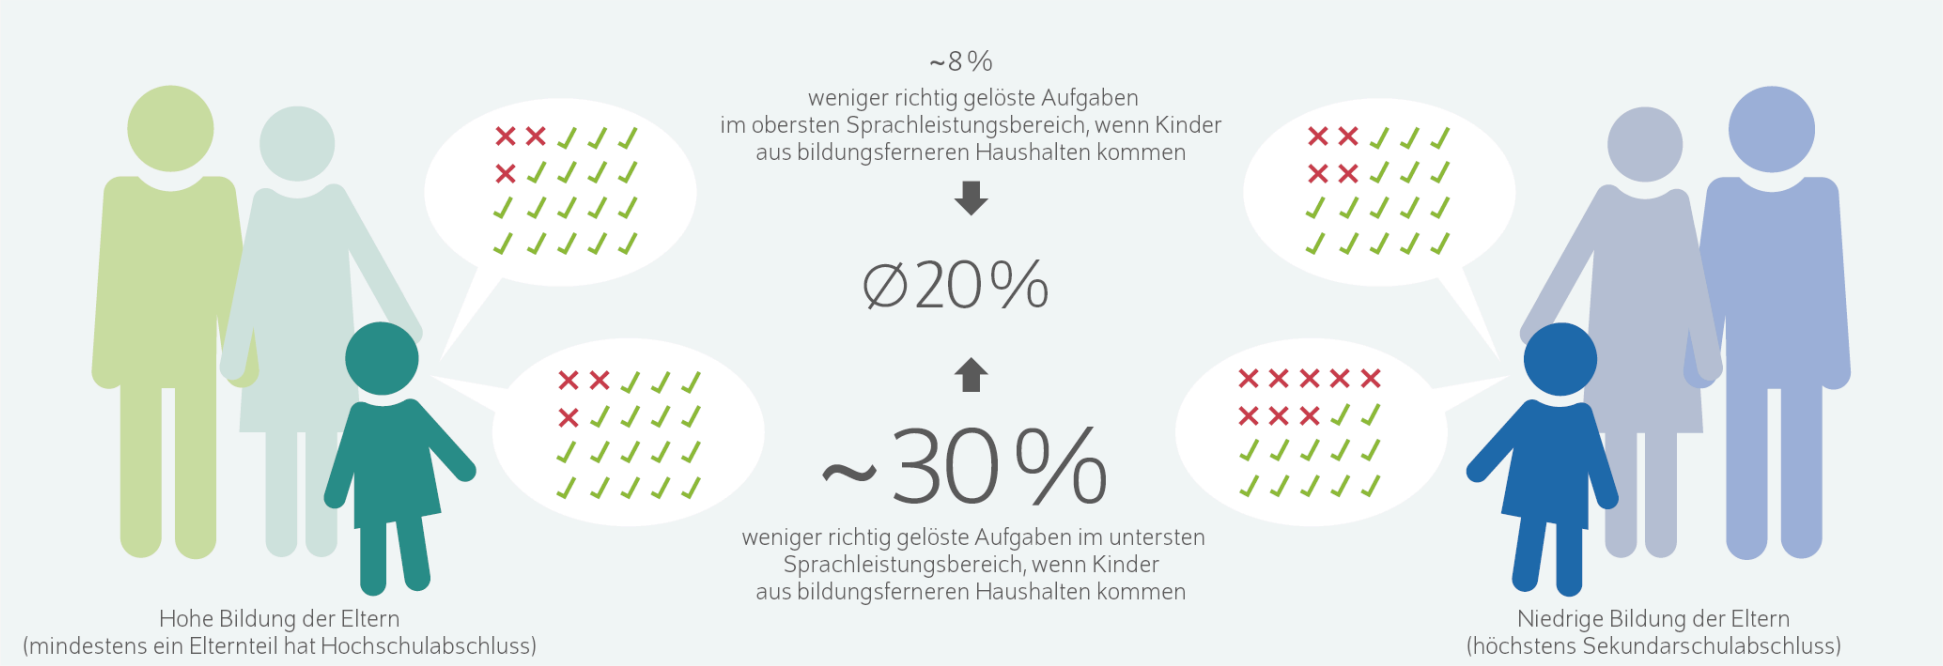
Gute Vergleiche: Vergleichsgegenstände – Akt I

Worauf hin wir vergleichen, ist bedeutsam!

Unterschiede in der Sprachkompetenz nach Bildung der Eltern sind im untersten Leistungsbereich deutlich größer – Betrachtung des Durchschnitts greift zu kurz



Quelle: Eigene Berechnungen auf Basis des Nationalen Bildungspanels (NEPS), Data Version SC2: 5.1.0.

© DIW Berlin 2019

Sprachkompetenz und Bildungshintergrund der Eltern (Link zur Studie)

Die Daten für die Vorlesung: FReDA

„FReDA - Das familiendemografische Panel“ ist eine wissenschaftliche Studie, die sich mit Beziehungen und Familienleben in Deutschland befasst. Dazu werden bundesweit mehrere tausend zufällig ausgewählte Menschen im Alter von 18 bis 49 Jahren sowie ihre Partnerinnen und Partner befragt. Die Daten werden wissenschaftlich ausgewertet und ermöglichen aktuelle Analysen zu Familie und Bevölkerung in Deutschland.

FReDA befasst sich mit der individuellen Lebenssituation der Menschen: mit dem Leben als Single, in Partnerschaften oder in Familien mit Kindern. Im Zentrum stehen die Themen Beziehung und Familienleben. Die Studie erforscht, wie die Menschen in Deutschland leben, wie sie ihren Alltag in der Partnerschaft organisieren und wie zufrieden sie mit ihrem Leben sind.

Beispielhafte Fragen im Verlauf der Vorlesung

1. Wie unterscheiden sich Gruppen, wie sie sich kennenlernen (Partnerschaften, Freundschaften)?
2. Gibt es Unterschiede, wie es den Menschen in sozialen Beziehungen geht und wie sie sich verhalten?
    a. Zufriedenheit
    b. Sexualität
    c. Kinderwunsch und -realität
    d. Beziehungsalltag

Beschreiben von Verteilungen (=deskriptive Statistik)

Nachdem wir operationalisiert und Daten für die theoretischen Konstrukte erhoben haben, liegen die Daten nun in einer Datenmatrix vor.

Diese Datenmatrix ist meist in ihrer Gesamtheit uninformativ, denn einzelne Werte sagen uns nichts über die **Typik** von Eigenschaften oder über **Zusammenhänge** zwischen Eigenschaften etwas aus.

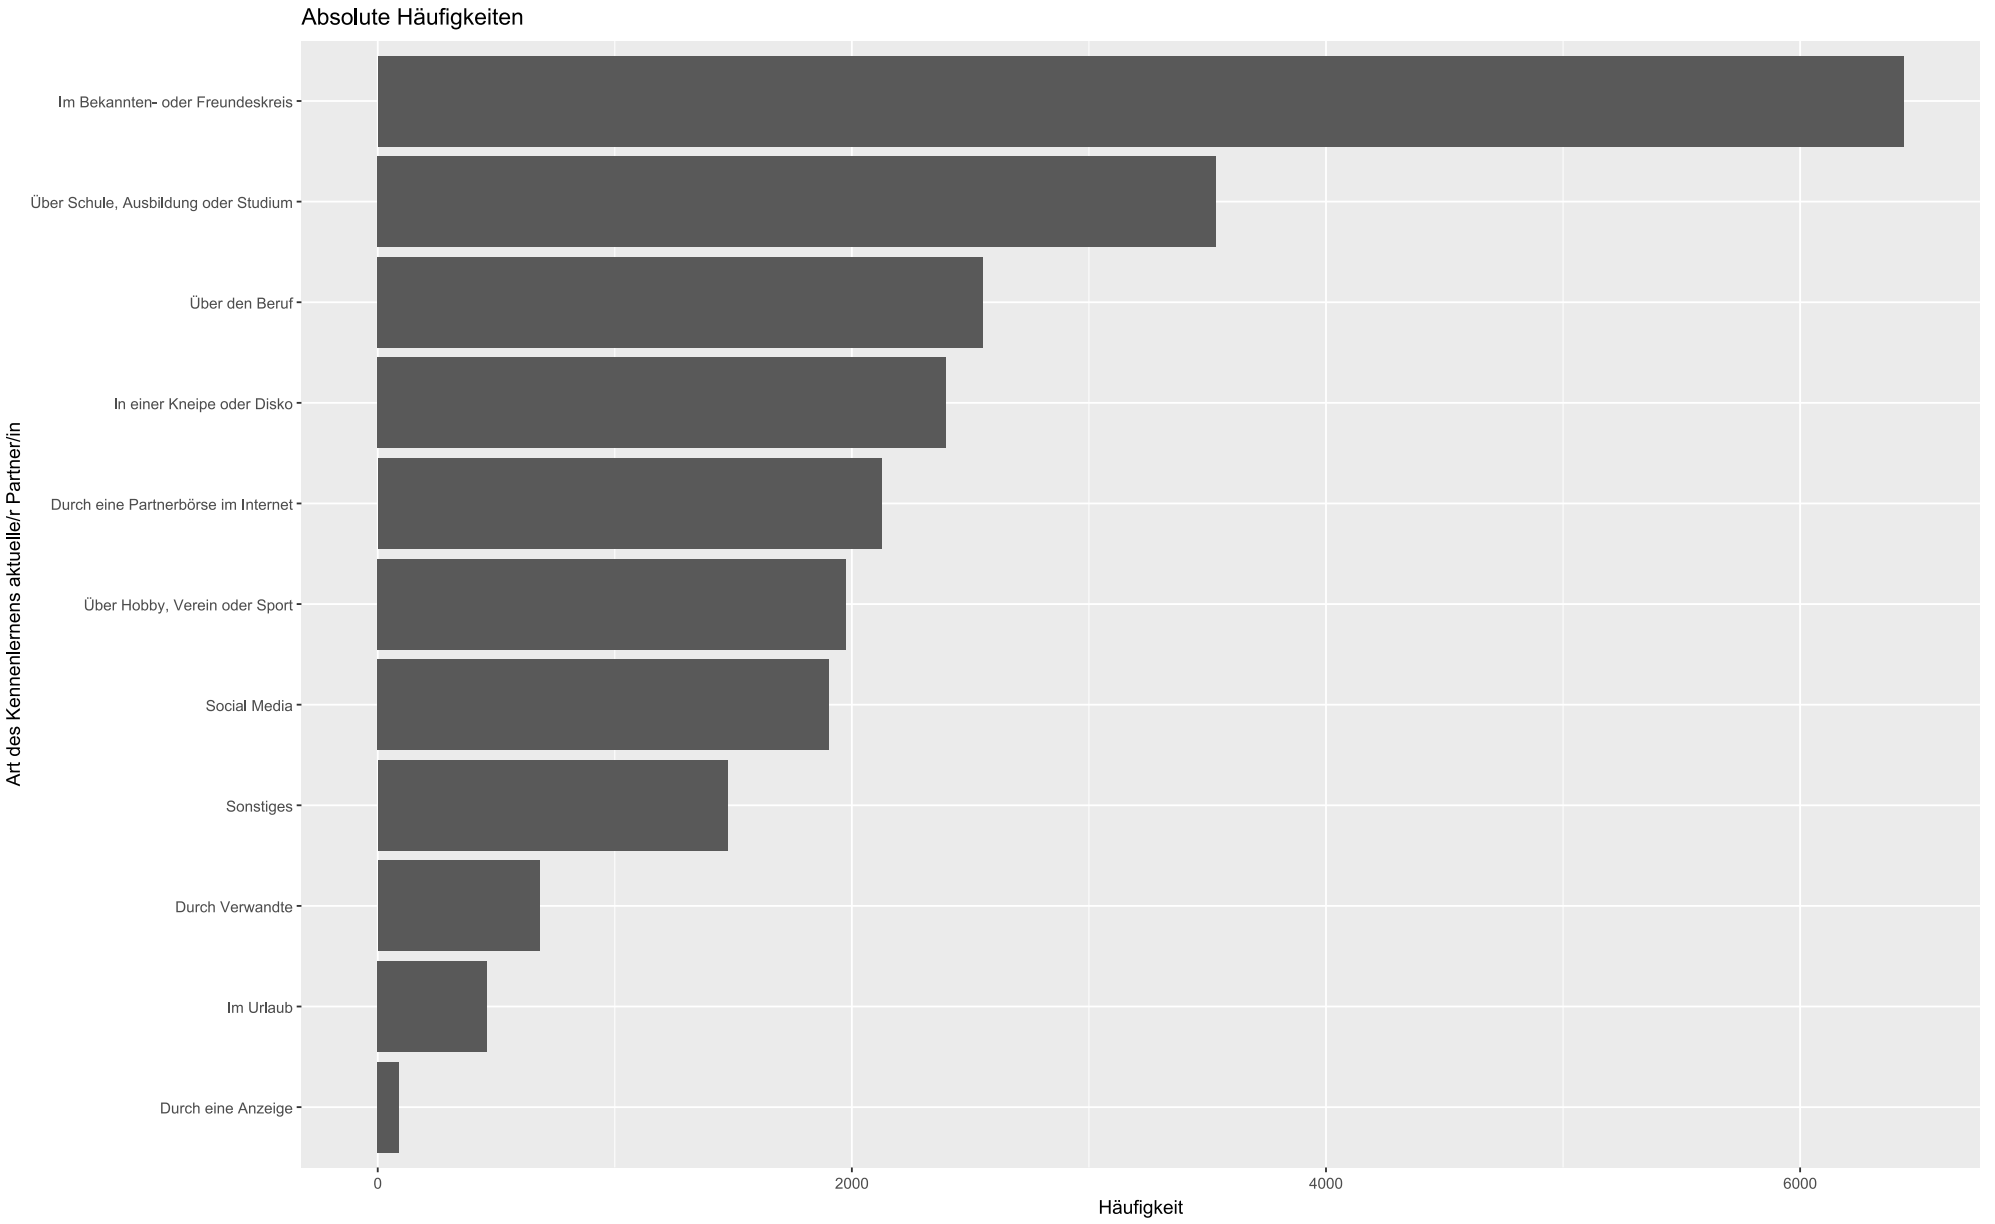
Um Daten gut zu beschreiben, müssen wir sie sinnvoll zusammenfassen (= aggregieren). Dies ist Aufgabe der *deskriptiven Statistik*.

Ein Schritt zurück: Was heißt es “Daten” sinnvoll zu aggregieren?

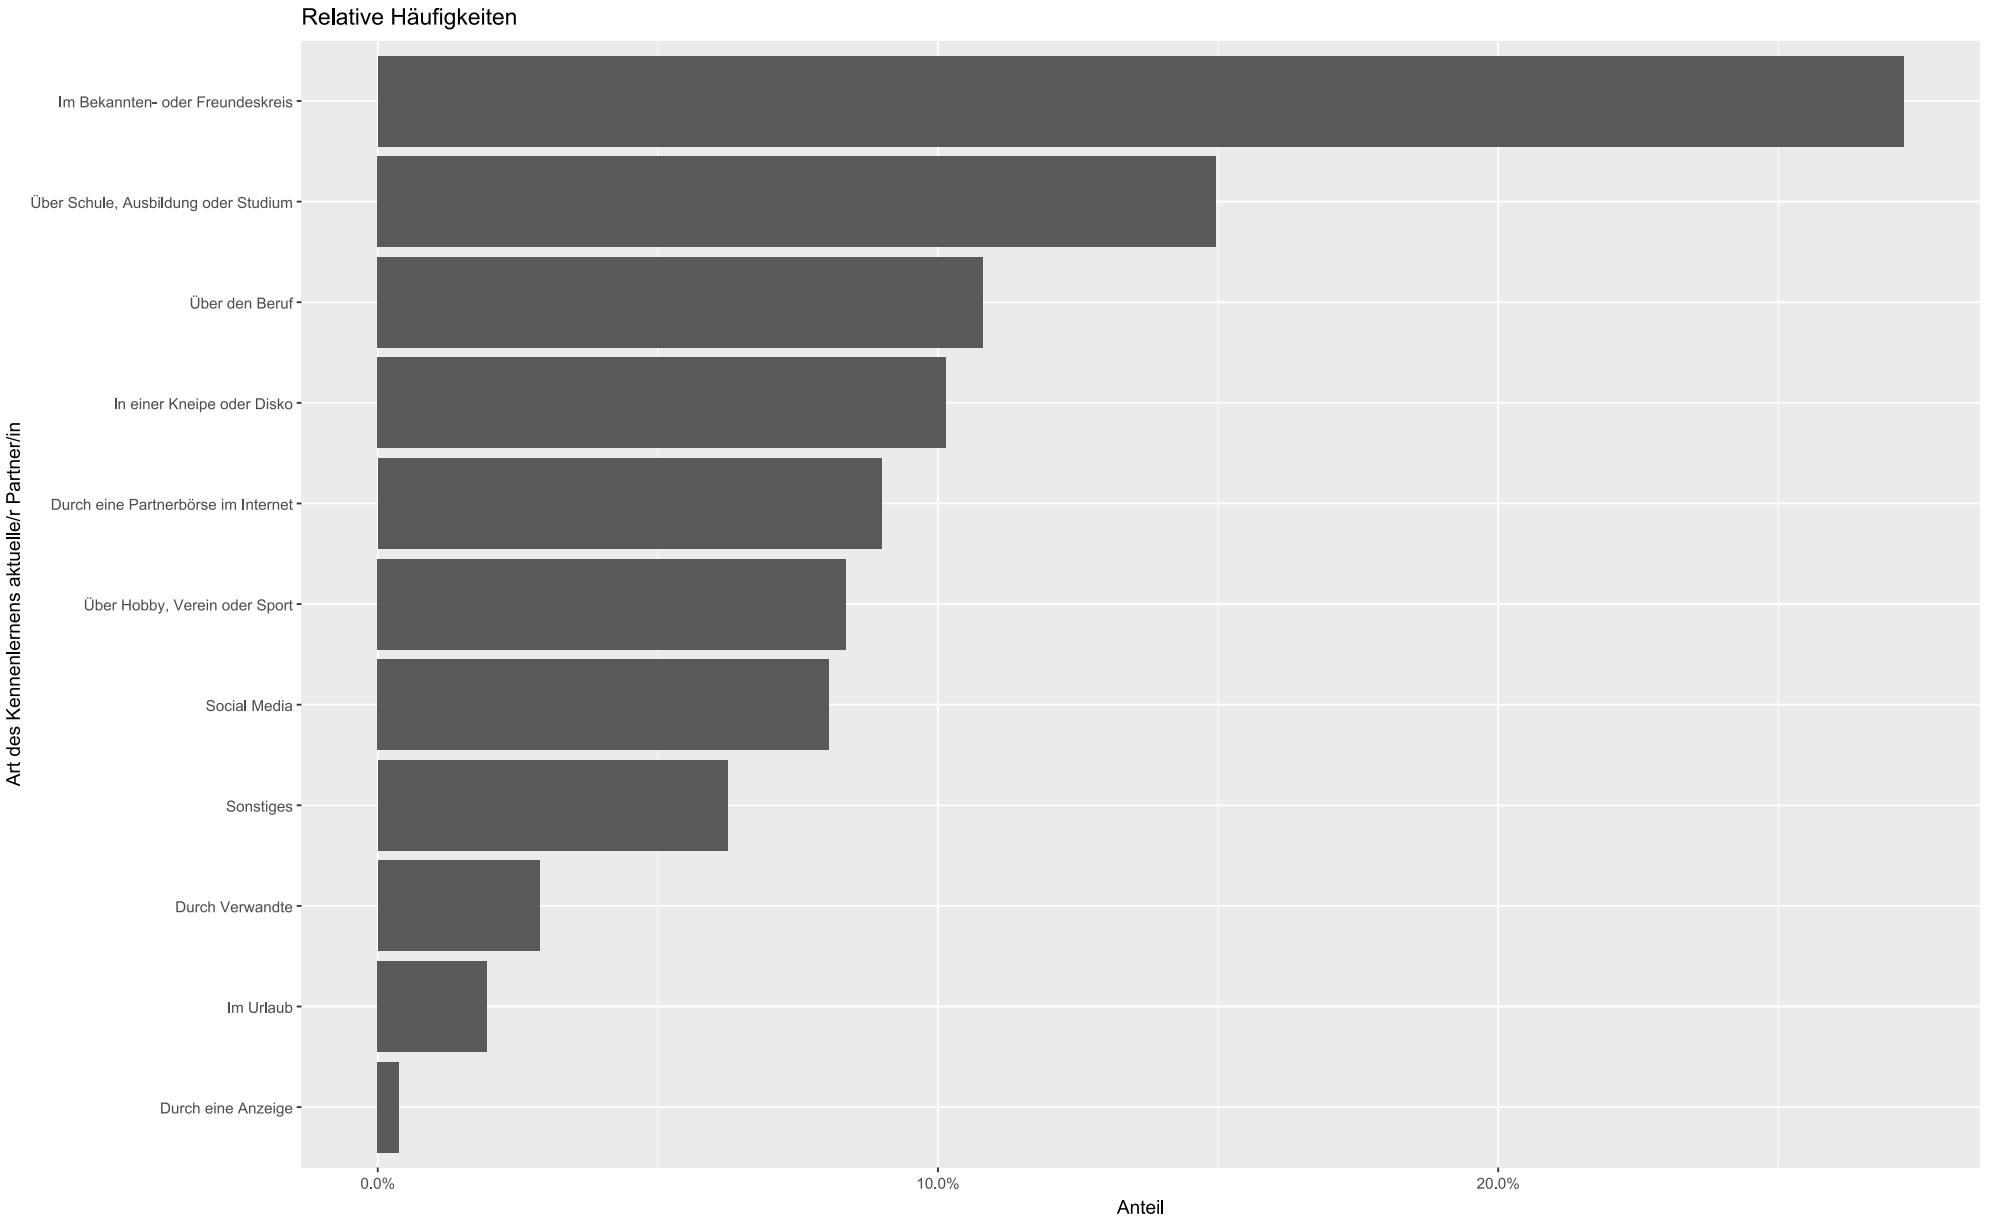
Eine Verteilung der Werte einer Eigenschaft Y gibt an, wie *häufig* diese Werte innerhalb einer (analytischen) Stichprobe vorkommen. Diese Häufigkeit kann in unterschiedlicher Weise angegeben werden:

Diese Häufigkeiten werden auf der Y-Achse (der vertikalen Dimension) grafisch abgetragen. Auf der X-Achse (horizontale Dimension) werden die Ausprägungen abgetragen. Je nach Skalenniveau der gemessenen Eigenschaften sind dies daher Kategorien, Ränge oder Werte in gleichen Intervallen.

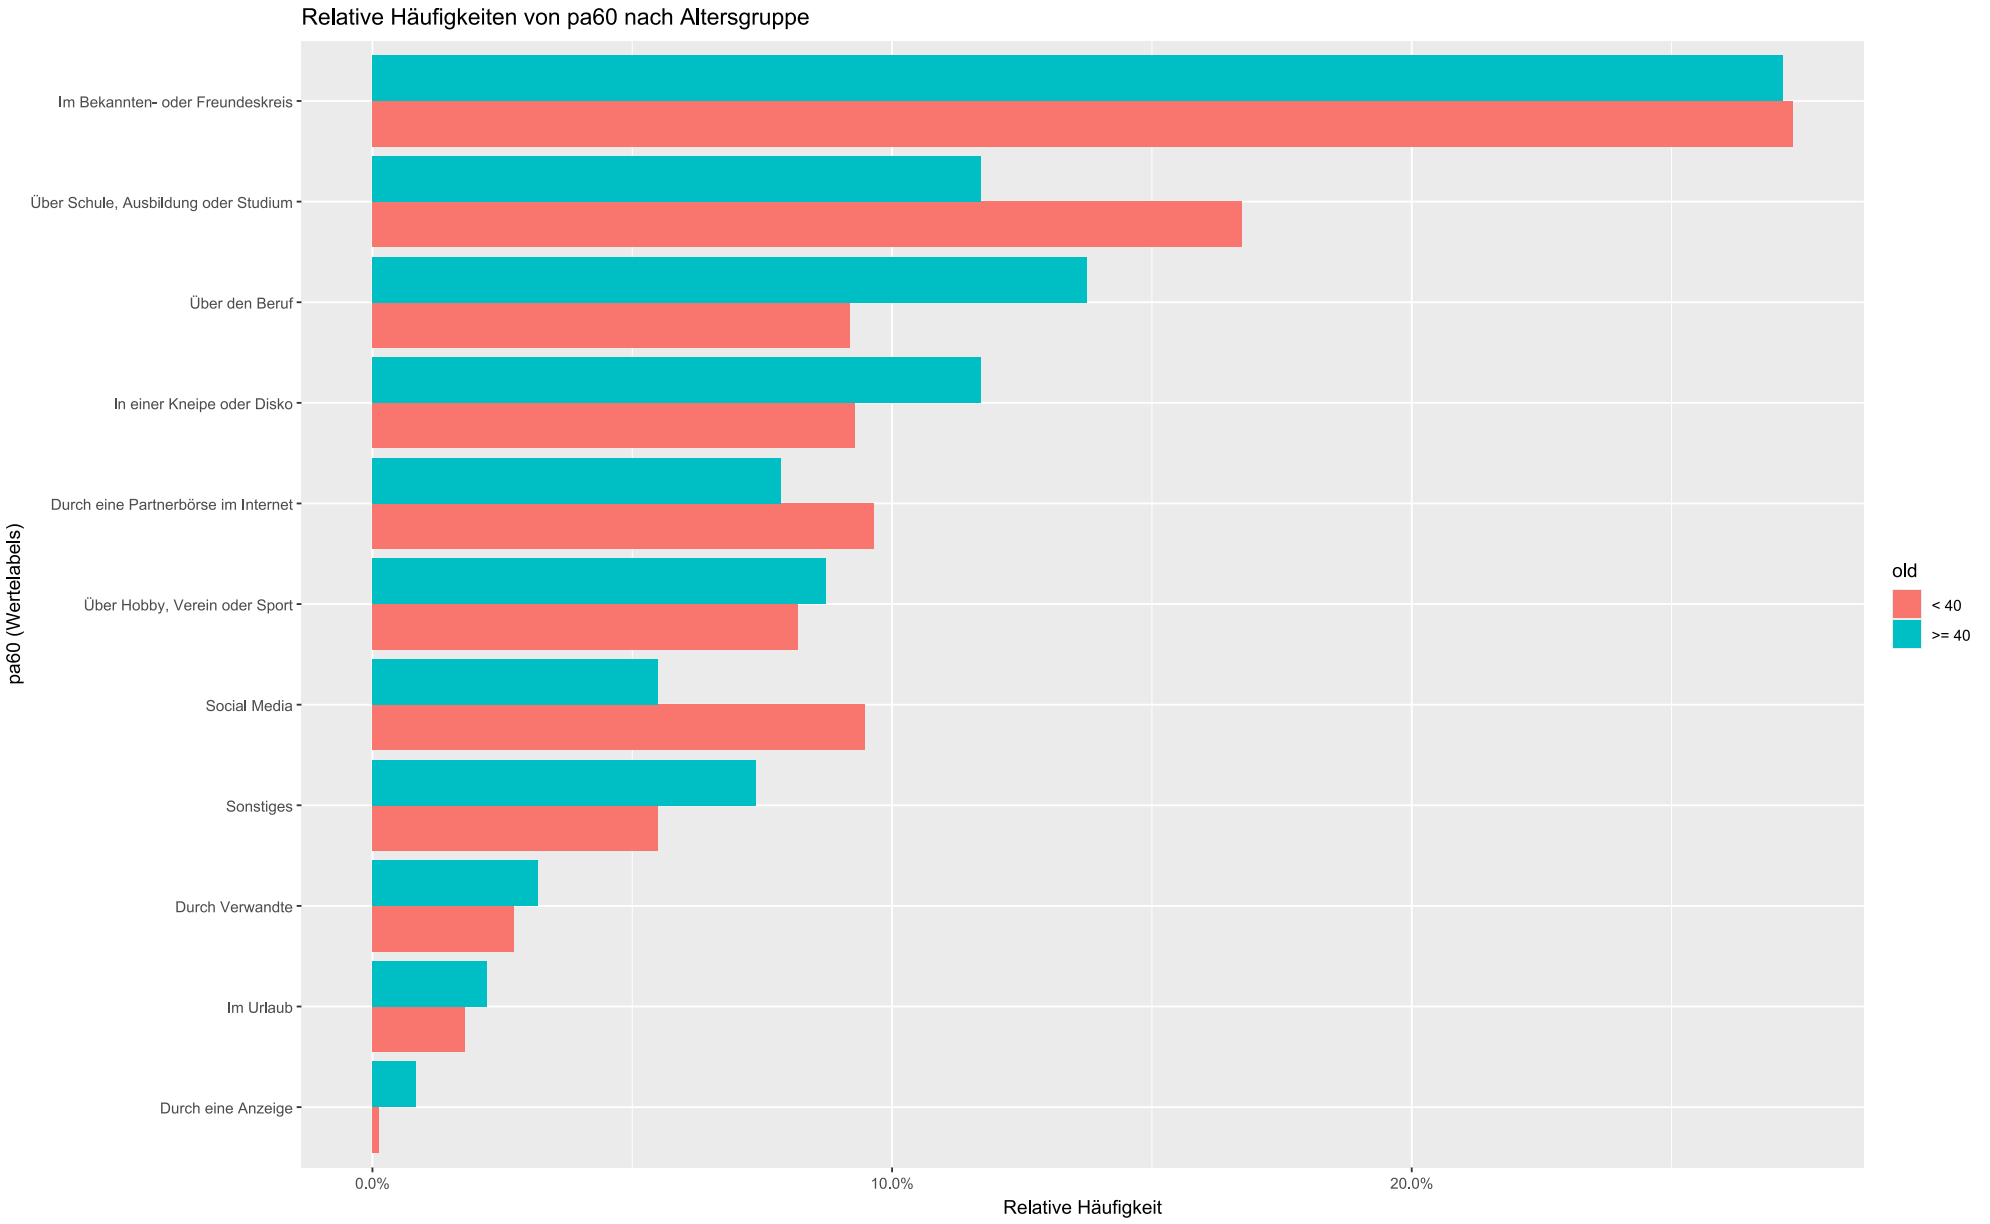
Absolute Häufigkeiten


Absolute Häufigkeiten
Art des Kennenlernens aktuelle/r Partner/in
Im Bekannten- oder Freundeskreis
Über Schule, Ausbildung oder Studium
Über den Beruf
In einer Kneipe oder Disko
Durch eine Partnerbörse im Internet
Über Hobby, Verein oder Sport
Social Media
Sonstiges
Durch Verwandte
Im Urlaub
Durch eine Anzeige
0
2000
4000
6000
Häufigkeit

Relative Häufigkeiten


Relative Häufigkeiten
Art des Kennenlernens aktuelle/r Partner/in
Im Bekannten- oder Freundeskreis
Über Schule, Ausbildung oder Studium
Über den Beruf
In einer Kneipe oder Disko
Durch eine Partnerbörse im Internet
Über Hobby, Verein oder Sport
Social Media
Sonstiges
Durch Verwandte
Im Urlaub
Durch eine Anzeige
0.0%
10.0%
20.0%
Anteil

Differenzen Jung (<40) vs. “Alt” (>=40)


Relative Häufigkeiten von pa60 nach Altersgruppe
Im Bekannten- oder Freundeskreis
Über Schule, Ausbildung oder Studium
Über den Beruf
In einer Kneipe oder Disko
Durch eine Partnerbörse im Internet
Über Hobby, Verein oder Sport
Social Media
Sonstiges
Durch Verwandte
Im Urlaub
Durch eine Anzeige
pa60 (Wertelabels)
0.0%
10.0%
20.0%
Relative Häufigkeit
old
< 40
>= 40

Balken und Dichteverteilungen

Häufigkeiten: Notation & Begriffe

Notation	Bedeutung	Beispiel
N	Absolute Häufigkeit	4.850 Personen gaben in der Stichprobe von 2018 an, 40h arbeiten zu wollen.
$P(y)$	Wahrscheinlichkeit	Mit einer Wahrscheinlichkeit von 0.2872 ziehen wir aus der Stichprobe eine Person, die genau 40h als gewünschte Arbeitszeit angegeben hat.
$P(y) \cdot 100$	relative Häufigkeit	28.72% der Befragten gaben an, 40h arbeiten zu wollen.
$P(y) \mid (X = x)$	Bedingte Wahrscheinlichkeit	Unter der Bedingung, dass wir nur Männer analysieren, ist die Wahrscheinlichkeit, einen Befragten zu ziehen, der 40h arbeiten will, 0.4. Bei Frauen liegt diese Wahrscheinlichkeit bei 0.17

Relative Häufigkeiten drücken Relationen aus!

Wahrscheinlichkeiten oder *relative* Häufigkeiten haben immer eine Bedeutung in Relation zum Nenner. Wenn sich der Nenner ändert, ändert sich auch die Bedeutung der relativen Häufigkeit. Klären Sie daher stets, auf welche *Basis* die relativen Häufigkeiten beziehen. Wir können folgende Relationen grob unterscheiden:

- Relation zur Stichprobengröße
- Relation zu einer bestimmten Gruppe definiert durch Ausprägungen in X
- Relation zu einer bestimmten Gruppe definiert durch Ausprägungen in Y

Die erste Variante wird typischerweise als “Zellenprozent”, die zweite als “Zeilenprozent” und die dritte als “Spaltenprozent” bezeichnet.

Armutsrisiko (Zeilenprozent)

Wie hoch ist die Wahrscheinlichkeit einen Haushalt in Armut zu finden *innerhalb* eines bestimmten Haushaltstyps?

Erwerbskonstellation	Armutsgef. Haushalt: nein	ja	Total
Rentner	84.74	15.26	100.00
Joblose HH	33.51	66.49	100.00
Doppelverdiener	99.61	0.39	100.00
Alleinverdiener	91.42	8.58	100.00
Zuverdiener	97.68	2.32	100.00
Doppelteilzeit	88.03	11.97	100.00
Prekäre HH	52.88	47.12	100.00
Single, Vollzeit	92.24	7.76	100.00
Single, Teilzeit	62.32	37.68	100.00

Zusammensetzung von Armut (Spaltenprozent)

Wie hoch ist die Wahrscheinlichkeit einen bestimmten Haushaltstyp *innerhalb* der armutsbetroffenen Haushalte zu finden?

Erwerbskonstellation	Armutsgef. Haushalt: nein	Armutsgef. Haushalt: ja	Total
Rentner	37.82	33.58	37.10
Joblose HH	2.79	27.30	6.92
Doppelverdiener	10.24	0.20	8.55
Alleinverdiener	7.10	3.28	6.46
Zuverdiener	12.63	1.48	10.75
Doppelteilzeit	1.10	0.74	1.04
Prekäre HH	2.03	8.93	3.20
Single, Vollzeit	21.00	8.72	18.93

Typische Fragen zu typischen Unterschieden

Fragestellung	Vergleich von	Beispiel
Unterscheiden sich Gruppen in ihren typischen Ausprägungen?	Arithmetischen Mitteln, Medianen, Modi, Chancen, Risiken, Wahrscheinlichkeiten	$$\Delta_G = \bar{y}_F - \bar{y}_M$$ Der (unbereinigte) gender wage gap ist die Differenz der durchschnittlichen Bruttostundenlöhne nach Geschlecht.
Unterscheiden sich Gruppen in der typischen Streuung ihrer Ausprägungen?	Varianzen, Standardabweichungen, Diversitäten	$$F = \sigma^2(y_M)/\sigma^2(y_F)$$ Die Streuung der Löhne von Männern ist um den Faktor F größer als die Streuung der Löhne von Frauen.
Unterscheidet sich die Art der Verteilung von Ausprägungen zwischen Gruppen?	Quantilen, Perzentilen, Dezilen	$$\Delta_{Q_G} = (Q_{90\|M}/Q_{90\|F}) - (Q_{10\|M}/Q_{10\|F})$$ Die Lohnverteilung von Frauen ist vor allem im oberen Bereich im Vergleich zu denen der Männer komprimiert (Gläserne Decke).

Typische Werte: Notation & Begriffe

Notation	Bezeichnung	Bedeutung	Beispiel
y_{Mod}	Modalwert	Der Wert mit der höchsten Häufigkeit	Die häufigsten gewünschten Arbeitsstunden waren 40h.
$\tilde{y}$	Median	Der Wert der, die Verteilung in zwei gleich große relative Häufigkeiten teilt	50% der Befragten wünschten sich eine Arbeitszeit von unter 35h und 50% wünschten sich eine Arbeitszeit ab 35h.
$\bar{y}$	Arithmetisches Mittel	Durchschnitt | Das arith. Mittel der gewünschten Arbeitsstunden lag im Jahr 2018 bei 32.8h. |	

Modalwert

Größe in cm
160
165
165
165
173
174
176
180
180
187

Der Modalwert oder Modus ist der **häufigste** Wert einer Verteilung. Es ist daher der Wert mit der größten relativen Häufigkeit.

$$y_{Mod} = 165$$

Median

Größe in cm
160
165
165
165
173
174
176
180
180
187

Der Median, ist der Wert, der 50% der oberen und 50% der unteren Werte eine Verteilung trennt. Der Median $\tilde{y}$ von n **nach der Größe geordneten** Beobachtungen berechnet sich durch:

$$\tilde{y} = \begin{cases} y_{\frac{n+1}{2}} & \text{bei ungerader Anzahl} \\ \\ \frac{y_{\frac{n}{2}} + y_{\frac{n}{2}+1}}{2} & \text{bei gerader Anzahl} \end{cases}$$

n bezeichnet die Anzahl der Beobachtungen. Bei 10 Beobachtungen bezeichnet $y_{\frac{10}{2}} = y_5$ den **Wert** der fünften Beobachtung innerhalb der nach den *Y-Werten geordneten Verteilung*. Sie berechnen daher erst die **Stelle**, wo der Median in der Verteilung liegt

Aritmethisches Mittel / Mittelwert

Größe in cm
160
165
165
165
173
174
176
180
180
187

Der Mittelwert ist das stärkste “Arbeitspferd” der Datenanalyse. Er ist das, was umgangssprachlich als “Durchschnitt” bezeichnet wird und berechnet sich durch:

$$\begin{aligned} \bar{y} &= \frac{\sum y_i}{N} \\ &= \frac{160 + 165 + 165 \cdots + 187}{10} = 172,5 \end{aligned}$$

Im Kern ist das arithmetische Mittel ein “Balance”-Wert. Die Summe aller absoluten Differenzen zum Mittelwert unterhalb und oberhalb des arithmethischen Mittels sind identisch.

Das arithmetische Mittel und gewichtete Werte

Eine alternative Darstellung der Berechnung des Mittelwerts ist auch:

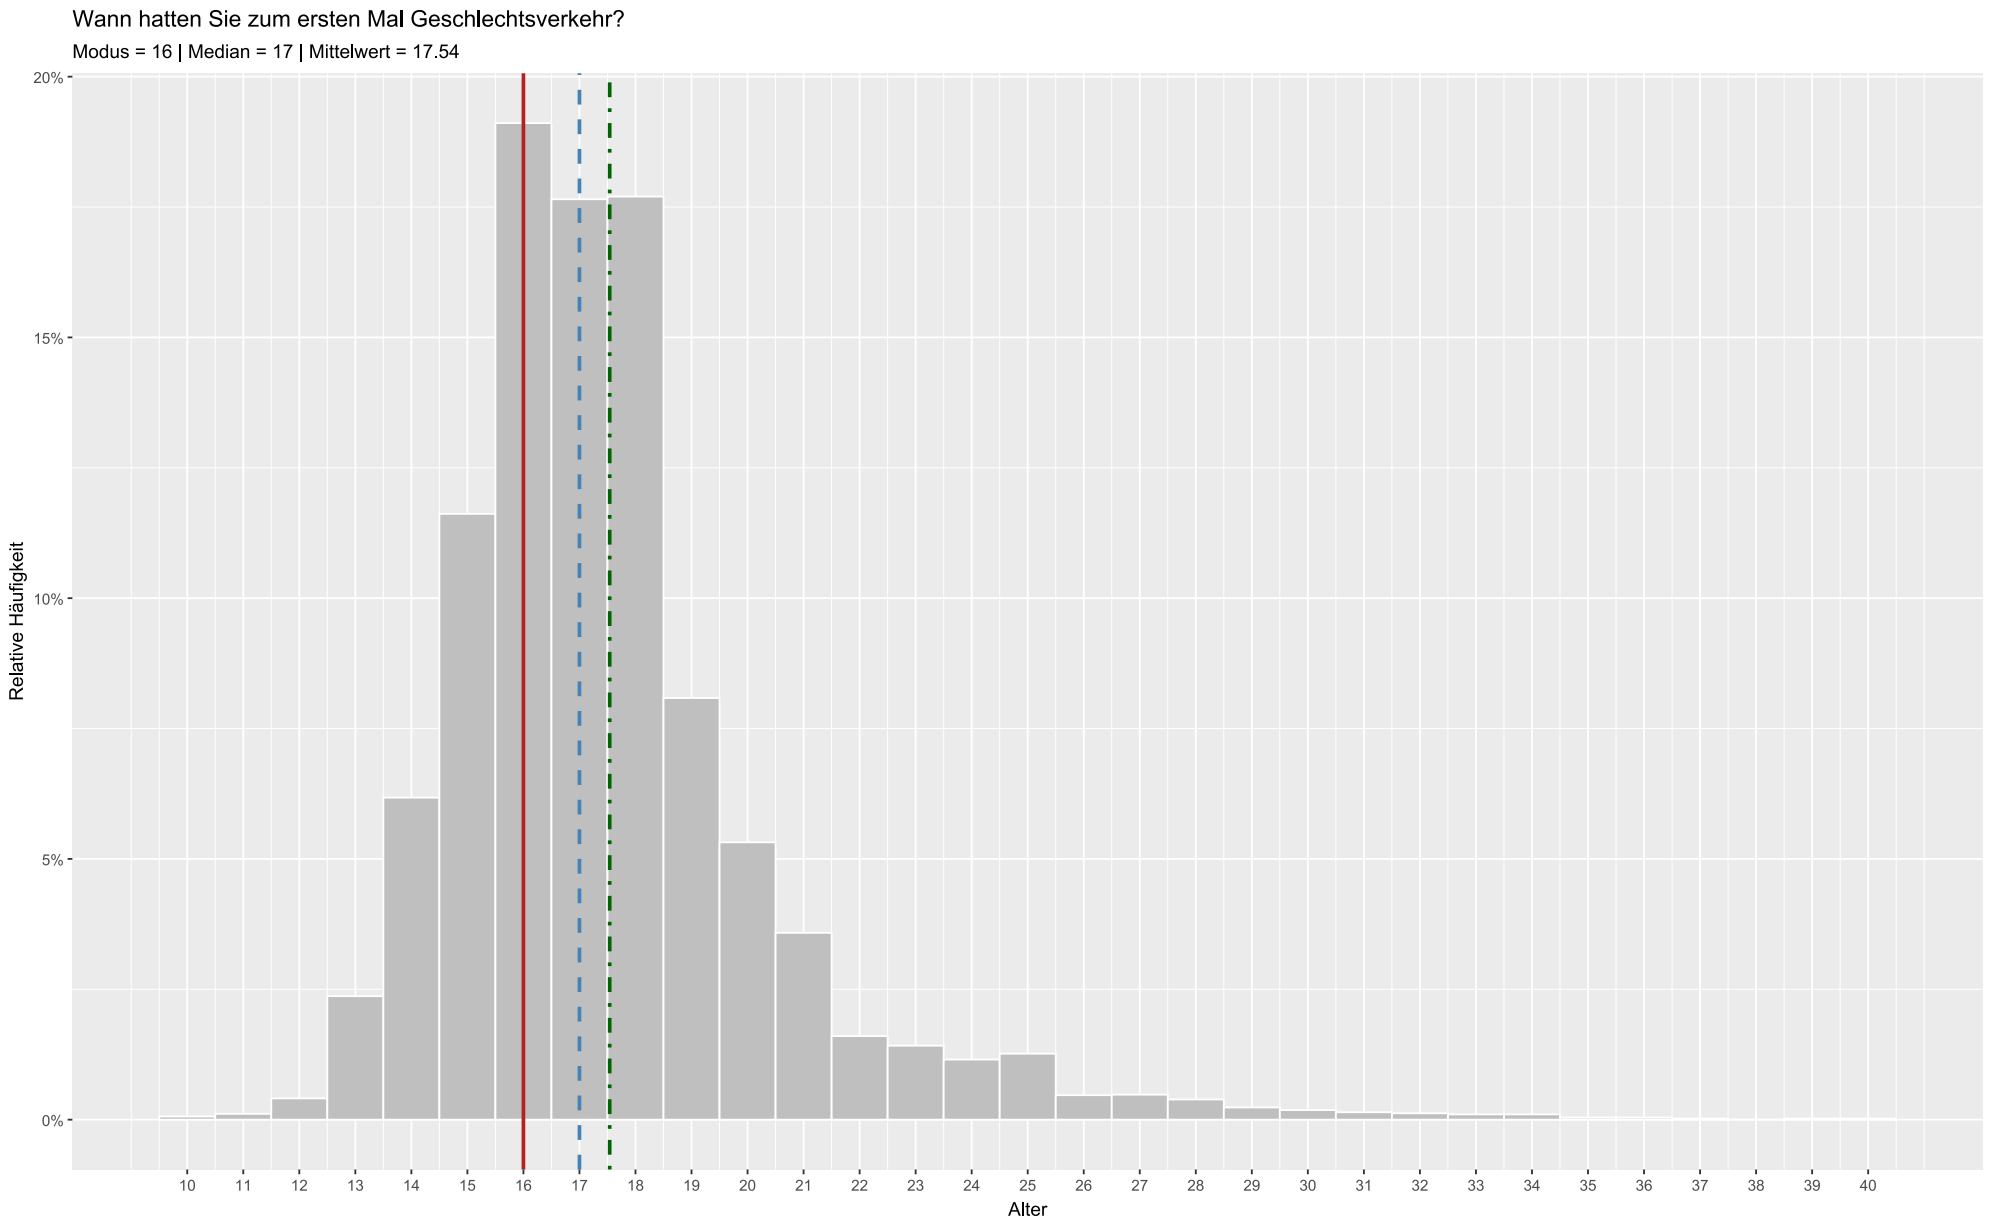
$$\bar{y} = \sum P(y_i) \cdot y_i$$

Er ist gleich der Summe aller Werte, *gewichtet* mit der Häufigkeit ihres Auftretens in der Stichprobe.

Das hat sehr praktische Implikationen. U.a. können wir dadurch den gesamten Mittelwert nach einzelnen Gruppen zerlegen. Im Fall von einer binären Variable X:

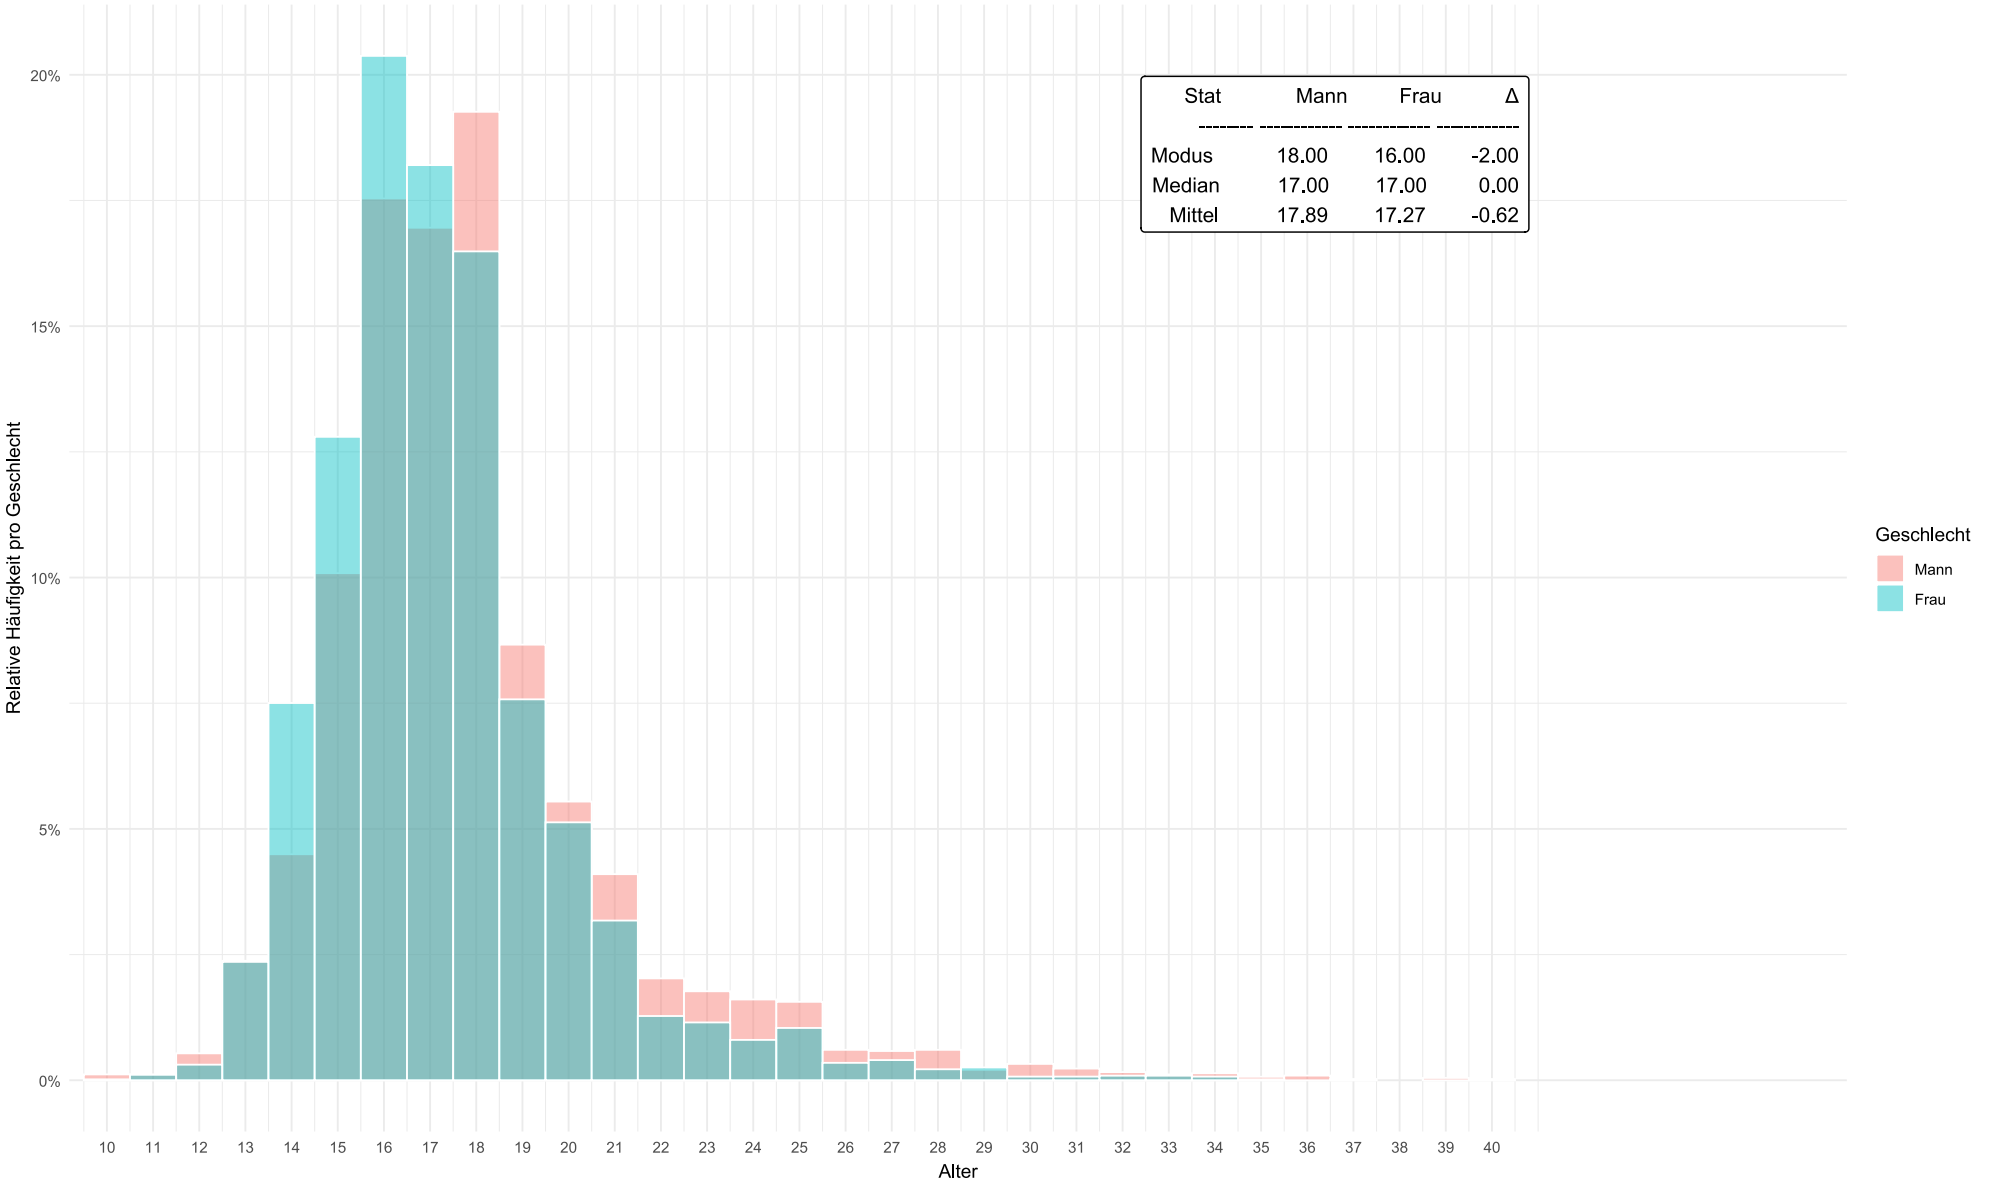
$$\bar{y} = (\bar{y}|X = 0) \cdot P(X = 0) + (\bar{y}|X = 1) \cdot P(X = 1)$$
$$= \left(\sum P(y_i) \cdot y_i|X = 0\right) \cdot P(X = 0) + \left(\sum P(y_i) \cdot y_i|X\right.$$

Was ist das “typische” Alter des ersten Geschlechtsverkehrs?



Alter des ersten Geschlechtsverkehrs nach Geschlecht

Wann hatten Sie zum ersten Mal Geschlechtsverkehr?



Stat	Mann	Frau	Δ
Modus	18.00	16.00	-2.00
Median	17.00	17.00	0.00
Mittel	17.89	17.27	-0.62

Typische Unterschiedlichkeit: Notation & Begriffe

Notation	Bezeichnung	Bedeutung
s^2	Varianz	Die durchschnittliche, quadrierte Abweichung der Werte zum Mittelwert.
s	Standard-abweichung	Die durchschnittliche Abweichung der Werte zum Mittelwert.
D	Diversität	Die Wahrscheinlichkeit zwei Untersuchungseinheiten mit unterschiedlichen Ausprägungen zufällig aus der Stichprobe zu ziehen.

Varianz

Ein Maß für die Unterschiedlichkeit von Werten ist die **Varianz**. Sie ist die *durchschnittliche* quadrierte Abweichung zum arithmetischen Mittel (und damit eine Sonderform des arithmetischen Mittels).

$$s^2 = \frac{\sum (y_i - \bar{y})^2}{n}$$

Varianz

Größe in cm
160
165
165
165
173
174
176
180
180
187

$$s^2 = \frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n}$$

$$= \frac{(160 - 172,5)^2 + (165 - 172,5)^2 \cdots + (18}{10}$$

Standardabweichung

Wir wollen nicht wissen, was die durchschnittliche “quadrierte Differenz” ist, sondern, was die “typischen Unterschiedlichkeit” der Befragten ist. Um eine sinnvolle, inhaltliche Interpretation zu ermöglichen, muss die Wurzel aus der Varianz gezogen werden. Diese Wurzel bezeichnet man als *Standardabweichung*.

$$s = \sqrt{s^2}$$

Da $\sqrt{66,25} \approx 8,14$ ist die typische Abweichung der Körpergrößen zwischen den beobachteten Personen 8,14 cm.

Reminder: Warum ist das relevant?

Diversität

In einigen Fällen ist eine Berechnung eines Mittelwerts nicht sinnvoll.[1] Dennoch möchten wir dann eine Möglichkeit haben, die Unterschiedlichkeit der verteilten Werte auszudrücken. Eine Möglichkeit, diese Unterschiedlichkeit zu messen, besteht in Diversitäts-Maßen, wie dem Simpson Diversitäts Index:

$$D = 1 - \sum_{y}^{Y} P(y)^2$$

y ist eine Ausprägung des Merkmals Y, Y die Anzahl aller Ausprägungen, und N die Gesamtanzahl aller Beobachtungen ist. Der Index drückt die Wahrscheinlichkeit aus, durch eine Ziehung

zwei Beobachtungen zu erhalten. D schwankt zwischen 0 und 1. Ist D = 1, liegt höchste Diversität vor.

1. Das sind vor allem: Verteilungen mit nominalen oder ordinal gemessenen Ausprägungen mit sehr unterschiedlichen Intervallen.

Belastung durch Arbeitsstunden

Wie stark sind Sie durch Ihre Arbeitsstunden belastet?

Belastung	Männer	Frauen	Gesamt
Gar nicht	854	747	1,601
Mäßig	4,033	3,399	7,432
Stark	2,459	2,186	4,645
Sehr stark	588	553	1,141
Gesamt	7,934	6,885	14,819

Die Diversität der Angaben über alle Befragten lässt sich wie folgt berechnen:

$$D = 1 - \left((\frac{1601}{14819})^2 + (\frac{7432}{14819})^2 + (\frac{4645}{14819})^2 + (\frac{1141}{14819})^2 \right)$$

Würden wir zwei Befragte zufällig ziehen, erhielten wir daher mit einer Wahrscheinlichkeit von 63.3% unterschiedliche Angaben. Die Diversität innerhalb von Männern ist 0.628 und innerhalb von Frauen 0.637.