Gute Vergleiche: Vergleichsgegenstände – Akt II

Differenzen entlang von Verteilungen

Jenseits des Mittelwerts

- Manchmal liegen die “interessanten Unterschiede” zwischen Gruppen nicht in der Mitte der Verteilungen sondern ganz oben oder unten.
- Mittelwerte oder Varianzen können diese Unterschiedlichkeit nur sehr begrenzt erfassen.
- Es lohnt sich daher, verschiedene Stellen der Verteilung zu analysieren. Dazu können wir Verteilungen in beliebig viele, gleich große[1] Teile zerlegen.

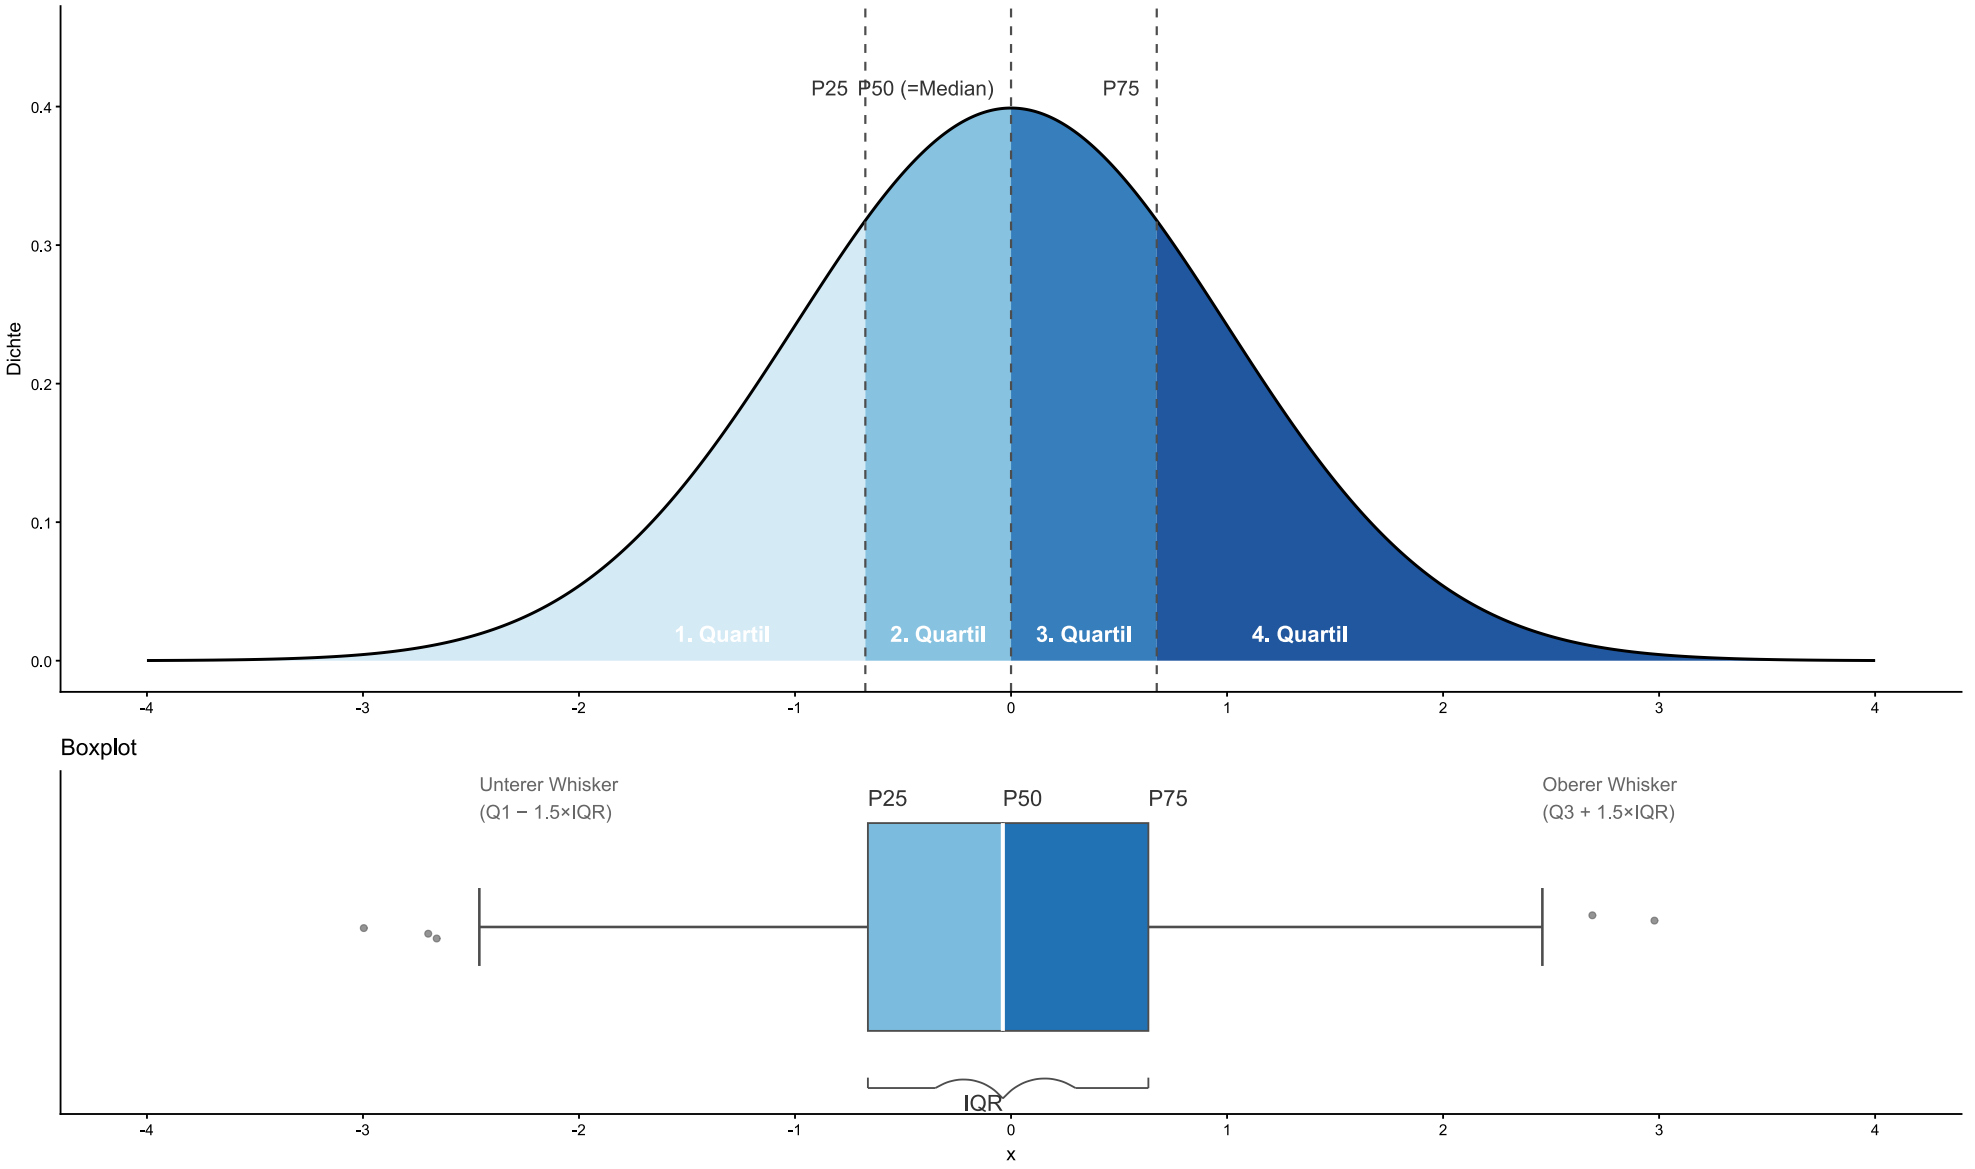
1. Für die Expert:innen: ORs werden mit P(Dinge passieren)/P(Dinge passieren nicht) berechnet. Wir können hier aber das N rauskürzen.

Begrifflichkeiten

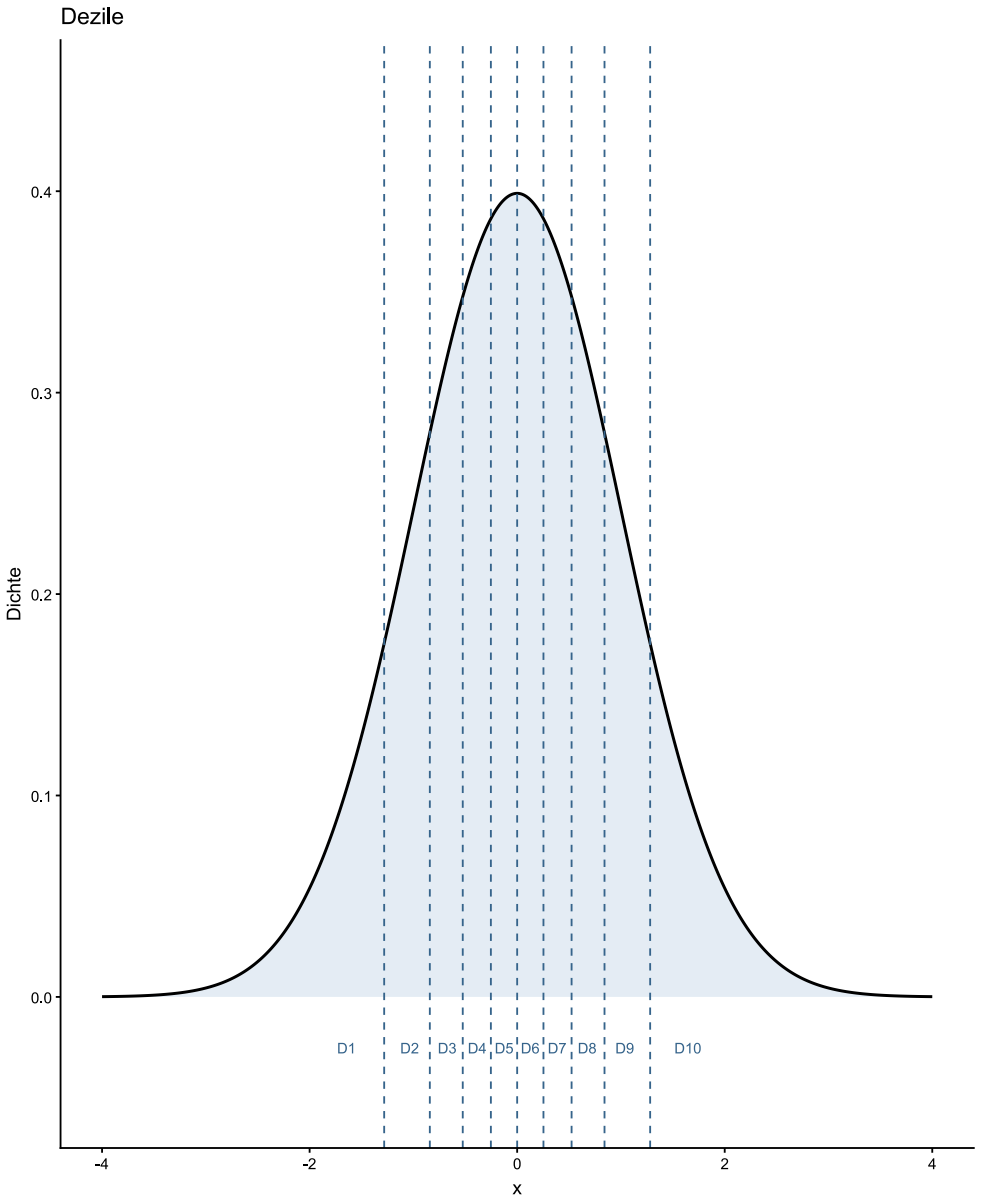
Bezeichnung	Anzahl gleich großer Teile	Abkürzung
Quartil	4	$Q1 \ldots Q4$
Dezil	10	$D1 \ldots D10$
Quantil/Perzentil	100	$P1 \ldots P99$

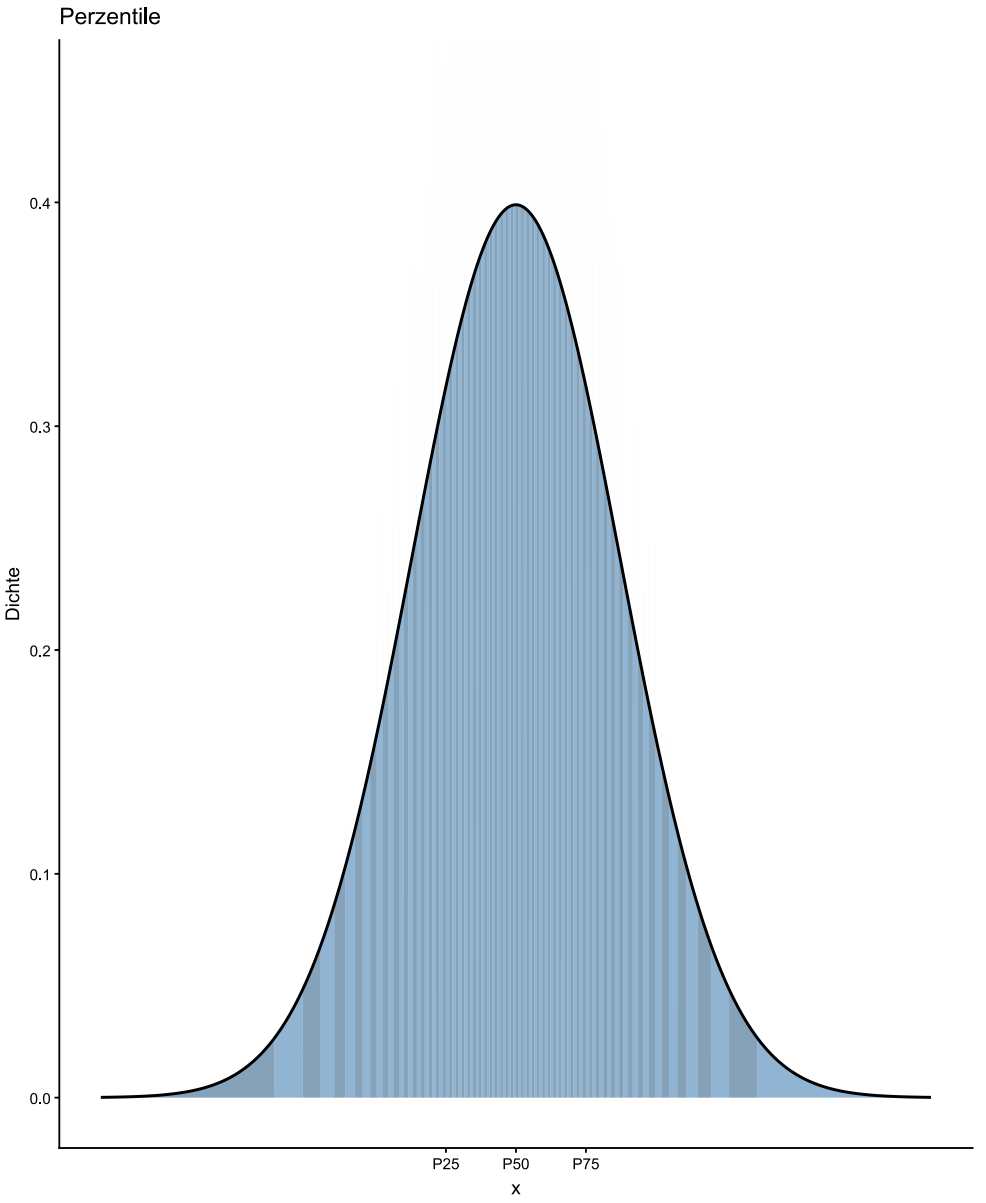
- Quartile und Perzentile können synonym benutzt werden. Der Wertebereich von Quantilen liegt zwischen 0.01 und 0.99, während er bei Perzentilen zwischen 1 und 99 liegt.
- Das 50. Perzentil ist der Median.
- Mit Quartilen und Dezilen werden typischerweise die Abschnitte einer Verteilung bezeichnet.
- Quantile und Perzentile

Quartile und Boxplots


P25
P50 (=Median)
P75
Dichte
0.4
0.3
0.2
0.1
0.0
1. Quartil
2. Quartil
3. Quartil
4. Quartil
-4
-3
-2
-1
0
1
2
3
4
Boxplot
Unterer Whisker
(Q1 − 1.5×IQR)
P25
P50
P75
Oberer Whisker
(Q3 + 1.5×IQR)
IQR
x

Dezile und Perzentile


Dezile
Dichte
0.4
0.3
0.2
0.1
0.0
D1
D2
D3
D4
D5
D6
D7
D8
D9
D10
-4
-2
0
2
4
x


Perzentile
Dichte
0.4
0.3
0.2
0.1
0.0
P25
P50
P75
x

Vertiefung: Wie kummulative Häufigkeiten und Perzentile zusammenhängen

Wir können bei ordinalen oder metrischen Ausprägungen die relativen Häufigkeiten laufend aufsummieren und erhalten auf diese Art “kummulative Häufigkeiten”. Kummulative Häufigkeiten geben an, wie viel Prozent der Beobachtungen einen bestimmten Wert **oder** einen kleineren Wert haben.

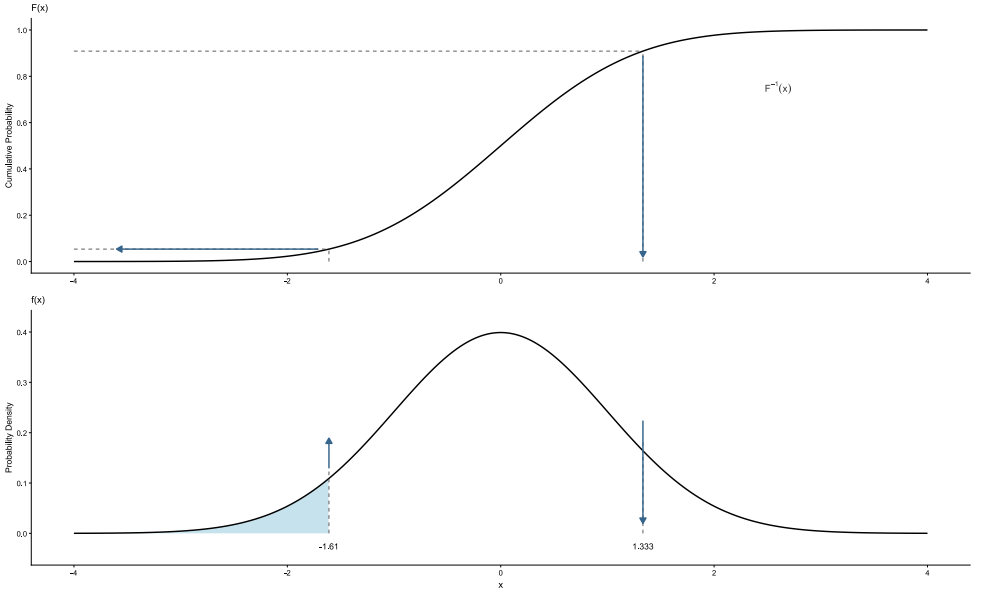
Beilegung von Meinungsverschiedenheiten (Streiten/laut werden)

Wert	Kategorie	n	Rel. Häufigkeit	Kum. Häufigkeit
1	Nie	4827	28,0%	28,0%

Wert	Kategorie	n	Rel. Häufigkeit	Kum. Häufigkeit
2	Selten	7136	41,4%	69,4%
3	Manchmal	3858	22,4%	91,8%
4	Oft	1241	7,2%	99,0%
5	Sehr oft	181	1,0%	100,0%

Vertiefung: Wie kummulative Häufigkeiten und Perzentile zusammenhängen

Jede stetige Verteilung lässt sich mit einer Verteilungsfunktion (unten) und einer kummulativen Verteilungsfuntion (oben) darstellen. Perzentile/Quantile sind die Werte, die kummulative Häufigkeiten in beiden Verteilungen abtrennen.



Vermögensverteilung in Deutschland (2023)

Verteilung von Brutto- und Nettovermögen	Bruttovermögen (€)	Nettovermögen (€)
5. Perzentil	900	−800
10. Perzentil	2.900	800
20. Perzentil	10.100	7.100
30. perzentil	22.300	19.100
40. Perzentil	55.200	49.300
50. Perzentil	125.300	103.200
60. Perzentil	237.000	196.100
70. Perzentil	366.900	326.200
80. Perzentil	520.400	473.500
90. Perzentil	856.900	779.500
95. Perzentil	1.338.500	1.227.900

Vermögensverteilung in Ost- und Westdeutschland

	West	Ost
	2012	2012
Mittelwert	93 790	41 138
Median	21 200	8 080
90. Perzentil	239 300	111 580
95. Perzentil	363 980	171 359
99. Perzentil	876 050	399 820
Negatives oder kein Vermögen in %	26,9	30,8
90/50-Dezilverhältnis	11,30	13,81

Die Daten-Spielwiese (ALLBUS 2018)

Differenzen von einzelnen Ausprägungen, Ereignissen, Kategorien

Wahrscheinlichkeiten, Chancen, Risiko

- Wir interessieren uns oft dafür, wie wahrscheinlich es ist, dass Personen zu einer bestimmten Gruppe gehören (Mieter vs. Eigentümer; Studium vs. Ausbildung; genesen vs. nicht genesen).
- Soziale Prozesse beeinflussen diese Wahrscheinlichkeiten, sodass es zu Differenzen über verschiedene Gruppen kommt.
- In vielen Fällen ist es sinnvoll, diese Differenzen als Wahrscheinlichkeiten auszudrücken, allerdings sind wir oft auch an Veränderungen in den *Verhältnissen zwischen Gruppen* interessiert.

Notationen

Abkürzung	Bedeutung
P(Y)	Wahrscheinlichkeit von Y
$P(Y\|X)$	Wahrscheinlichkeit von Y unter der Bedingung, dass X vorliegt
RR_Y	Risikoverhältnis (oder Risk Ratio) einer (Referenz)Gruppe auf Y gegenüber einer anderen Gruppe
Odd_Y	Chance auf Y (im Gegensatz zu “Nicht Y”)

Abkürzung	Bedeutung
$Odd_{Y\|X}$	Chance auf Y unter der Bedingung, dass X vorliegt
OR_Y	Chancenverhältnis von Y von Gruppe A in Referenz auf Gruppe B

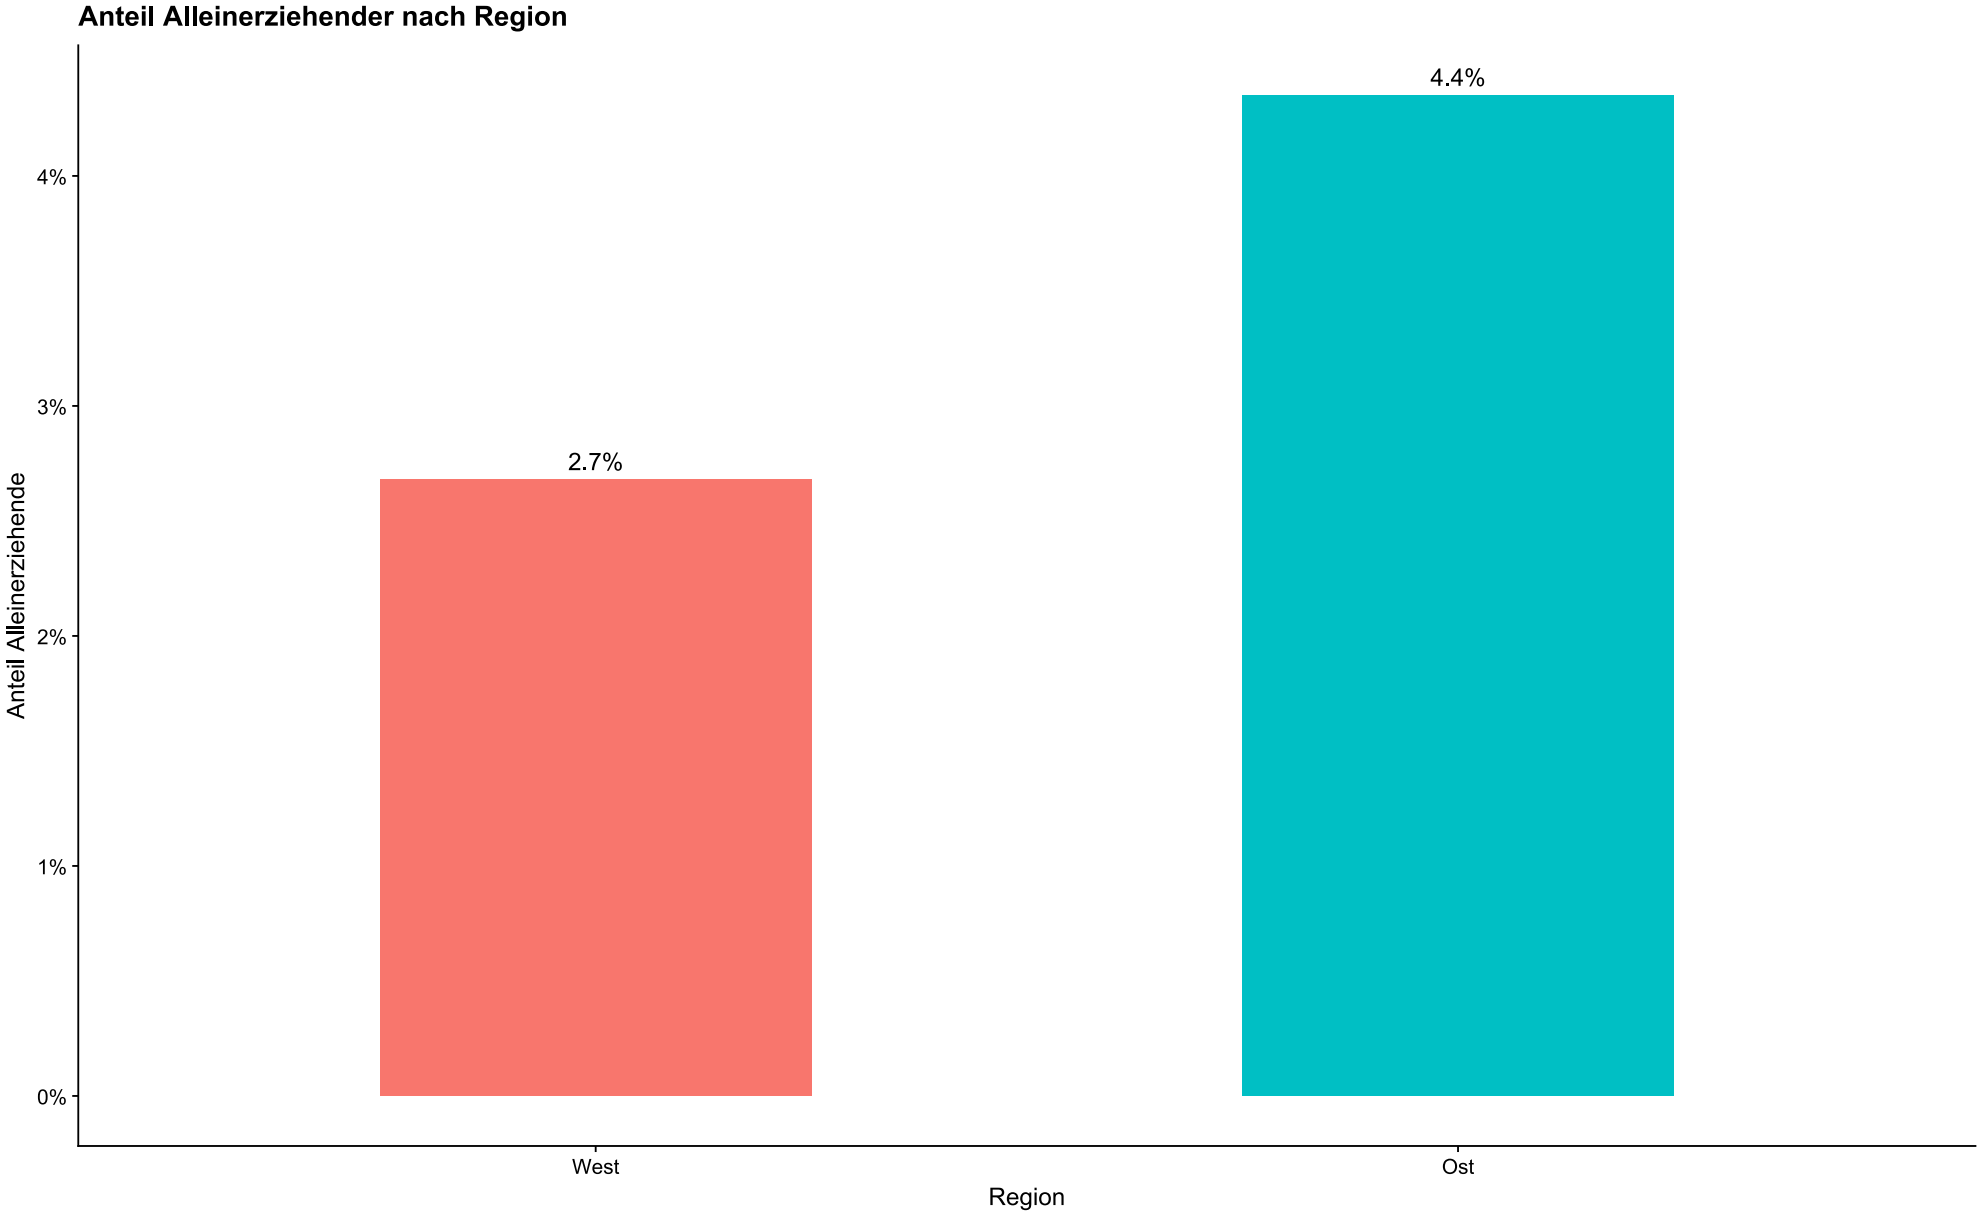
Alleinerziehende

Relative Anzahl von Alleinerziehenden pro Anzahl von Kindern im Haushalt

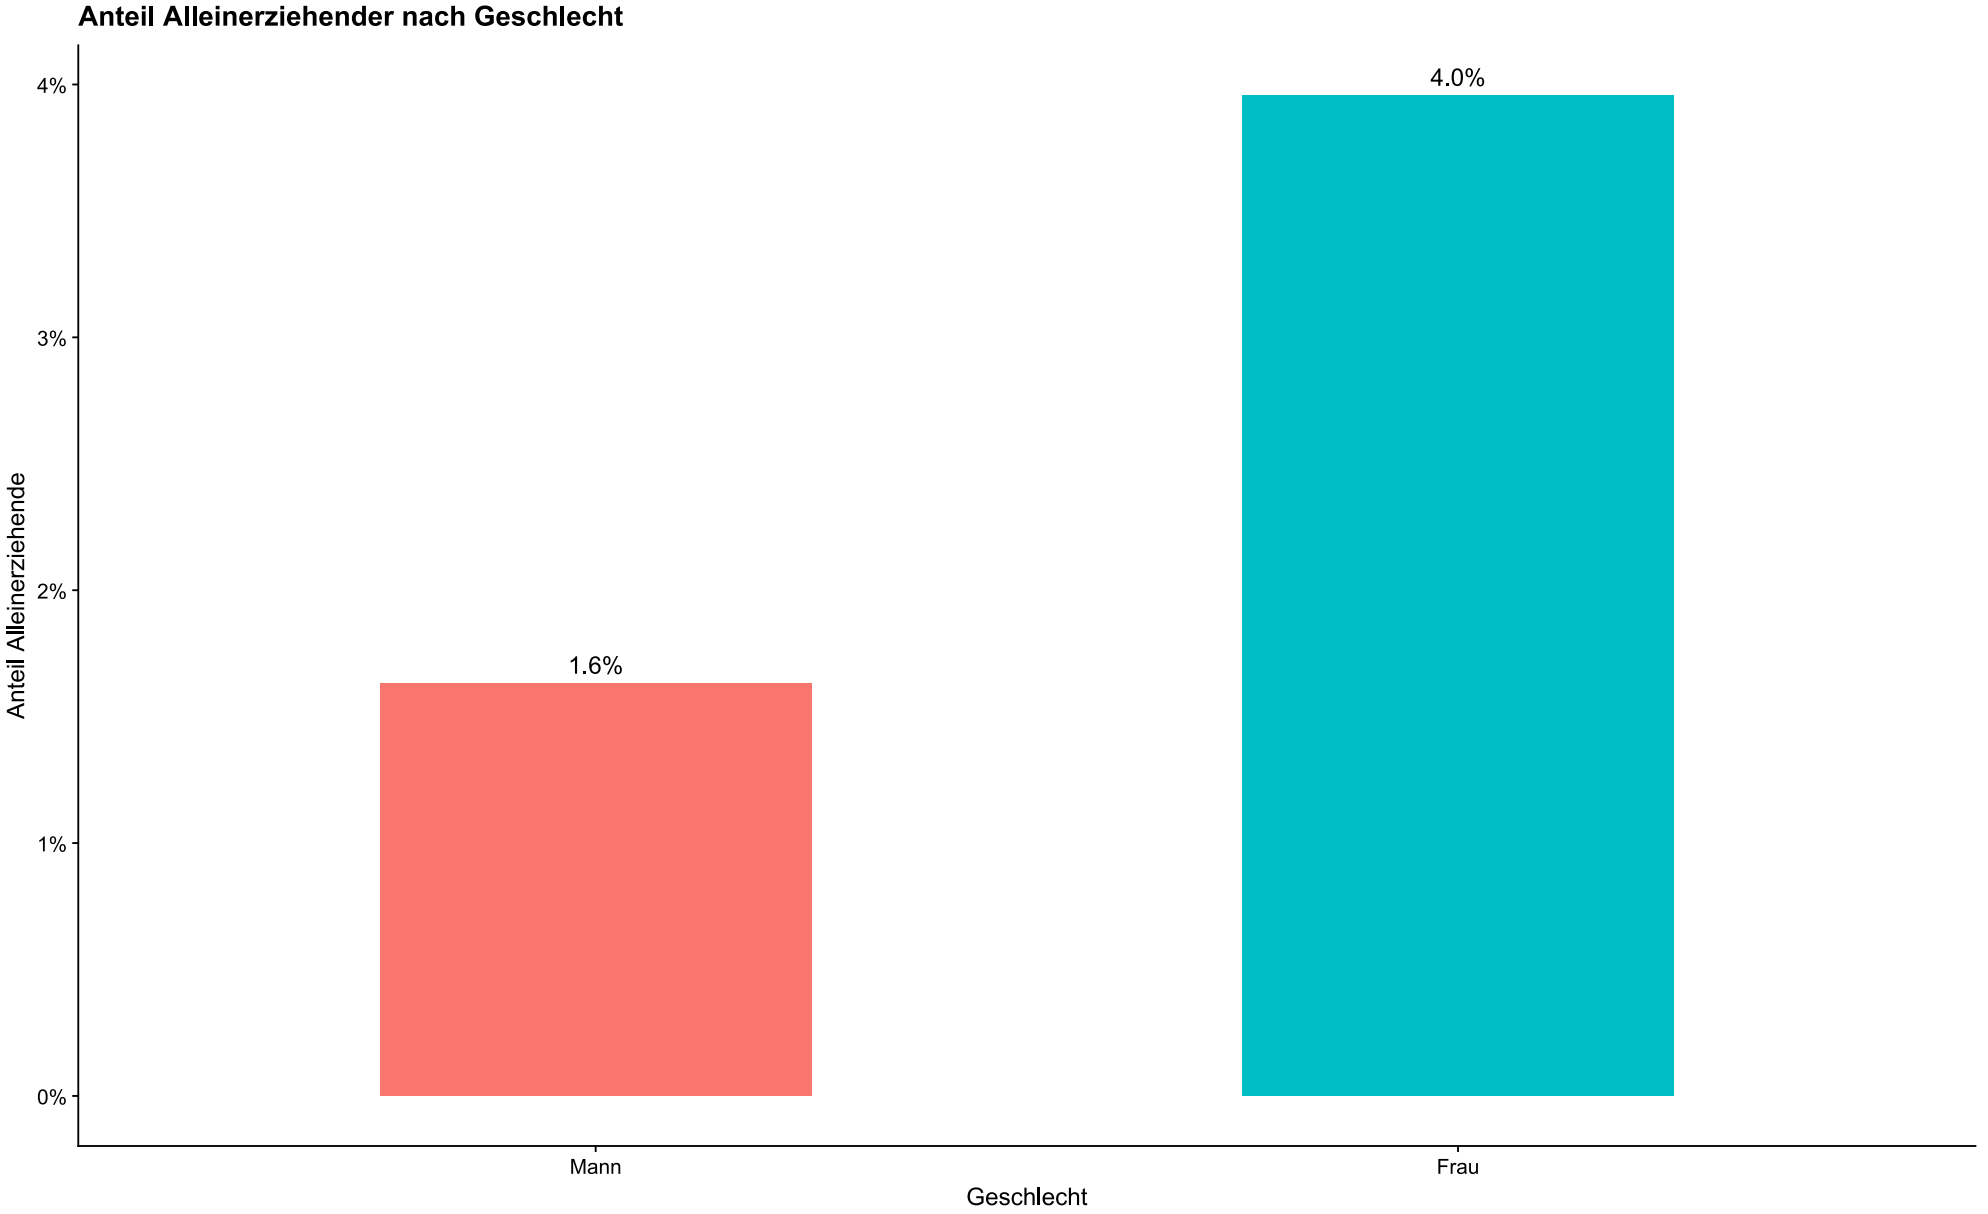
nkidsliv_c	Hat keine/n Partner/in	Hat Partner/in
1	544 (9,1%)	5420 (90,9%)
2	350 (5,0%)	6704 (95,0%)
3	74 (4,0%)	1795 (96,0%)
4 or more children	24 (4,4%)	521 (95,6%)

Die unbedingte Wahrscheinlichkeit, als Elternteil alleinerziehend zu sein liegt bei 6.4%.

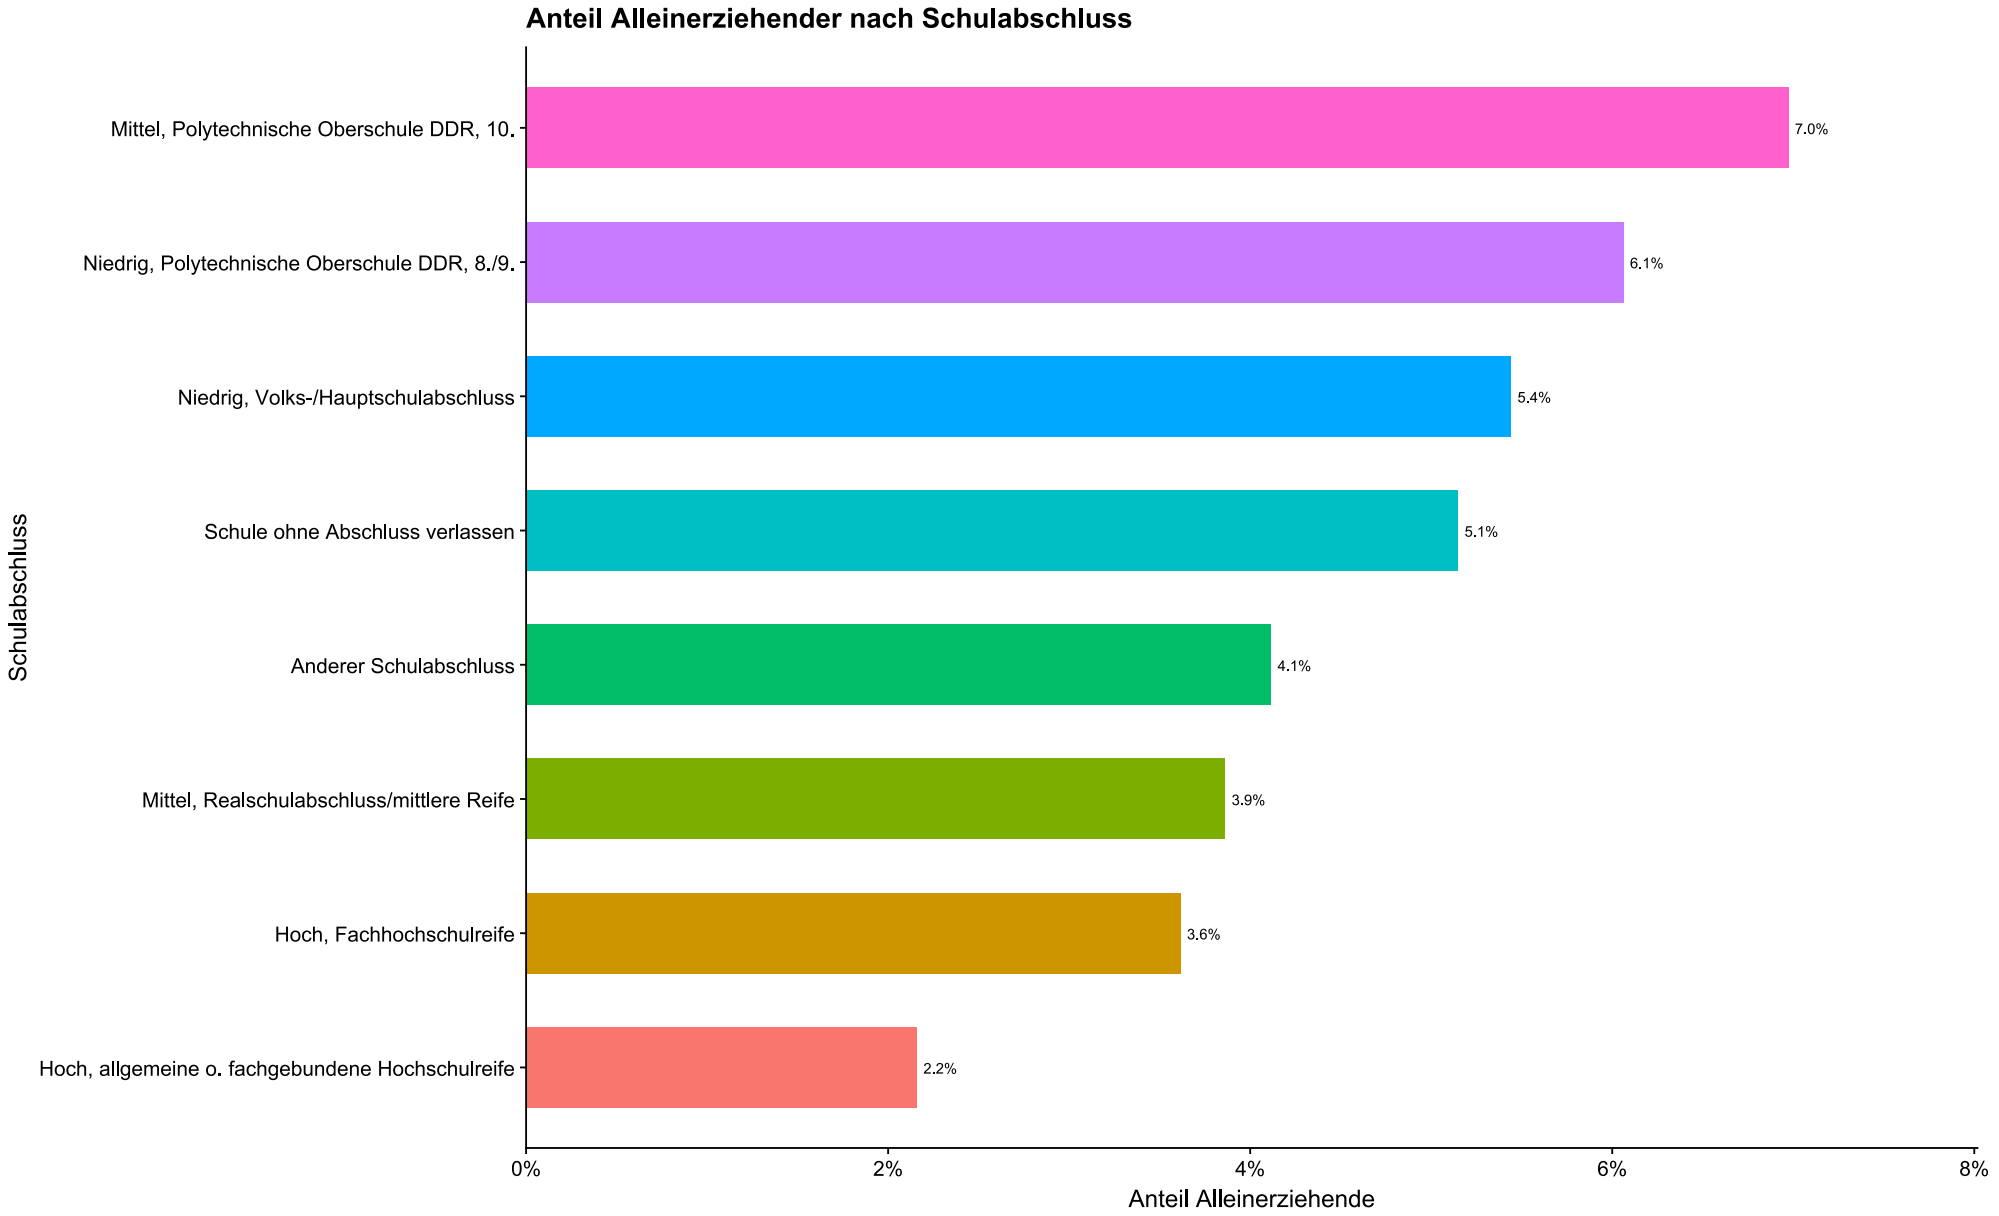
“Risiken” für Alleinerziehnde: Region


Anteil Alleinerziehender nach Region
4.4%
2.7%
4%
3%
2%
1%
0%
Anteil Alleinerziehende
West
Ost
Region

“Risiken” für Alleinerziehnde: Geschlecht


Anteil Alleinerziehender nach Geschlecht
4%
3%
2%
1%
0%
Anteil Alleinerziehende
1.6%
4.0%
Mann
Frau
Geschlecht

“Risiken” für Alleinerziehnde: Bildungsabschluss


Anteil Alleinerziehender nach Schulabschluss
Schulabschluss
Mittel, Polytechnische Oberschule DDR, 10.
Niedrig, Polytechnische Oberschule DDR, 8./9.
Niedrig, Volks-/Hauptschulabschluss
Schule ohne Abschluss verlassen
Anderer Schulabschluss
Mittel, Realschulabschluss/mittlere Reife
Hoch, Fachhochschulreife
Hoch, allgemeine o. fachgebundene Hochschulreife
7.0%
6.1%
5.4%
5.1%
4.1%
3.9%
3.6%
2.2%
0%
2%
4%
6%
8%
Anteil Alleinerziehende

Odds & Relatives Risiko

X_0 ist die “Referenzgruppe” - d.h., die Gruppe auf der wir eine andere Gruppe mit einer anderen Ausprägung von X vergleichen ($X = x$).

$$RR_Y = \frac{P(Y|X = x)}{P(Y|X_0)}$$

$$Odd_Y = \frac{P(Y)}{1 - P(Y)}$$

$$OR_Y = \frac{Odd_{Y|X=x}}{Odd_{Y|X_0}}$$

Odds & Relatives Risiko

Positive vs. negative Ereignisse innerhalb Gruppe A und B.

Gruppe A	Gruppe B
+	+
+	+
-	+
-	+
-	-
-	-
-	-
-	-

Wahrscheinlichkeiten

Gruppe A: $P(+) = 0.2$

Gruppe B: $P(+) = 0.4$

Ausgedrückt als bedingte Wahrscheinlichkeiten
$P(+|A) = 0.2 \,\&\, P(+|B) = 0.4$

Odds (Chancen)

$$Odd_{+|A} = \frac{0.2}{1-0.2} = \frac{1}{4} = 1{:}4$$

$$Odd_{+|B} = \frac{0.4}{1-0.4} = \frac{2}{3} = 2{:}3$$

Odds Ratio & Relatives Risiko

$$OR_{+} = \frac{2/3}{1/4} = 2.6667$$

Das geschlechtsspezifische Risiko, alleinerziehend zu sein

Ausgehend von den geschlechtsspezifischen Wahrscheinlichkeiten alleinerziehend zu sein, können wir Odds, Odds Ratios und Relative Risiken berechnen.

sex_c	Alleinerziehend	Nicht alleinerziehend
Mann	242 (1,6%)	14585 (98,4%)
Frau	748 (4,0%)	18155 (96,0%)

$$Odd_F = \frac{4.0}{96.0} = 0.042$$

$$Odd_M = \frac{1.6}{98.4} = 0.016$$

$$OR_{F/M} = \frac{0.042}{0.016} = 2.625$$

$$RR_{F/M} = \frac{4.0}{1.6} = 2.5$$

Der Unterschied zwischen Odds Ratios und Relativen Risiken

Der Unterschied zwischen OR und RR ist kein Zahlenspielchen sondern eine Frage der Wissenschaftskommunikation. Rein technisch müssen Sie auf zwei Dinge achten, die am einfachsten im Rahmen eines klassichen Experiments deutlich werden.

	Dinge passieren	**Dinge passieren nicht**
Versuchsgruppe	N_a	N_b
Kontrollgruppe	N_c	N_d

Der Unterschied zwischen Odds Ratios und Relativen Risiken

Bei RR berechnen wir eine Relation von Wahrscheinlichkeiten, dass Dinge passieren in Bezug auf die Wahrscheinlichkeit auf alle Ereignisse (= Dinge passieren + Dinge passieren **nicht**):

$$RR = \frac{N_a}{N_a + N_b} / \frac{N_c}{N_c + N_d}$$

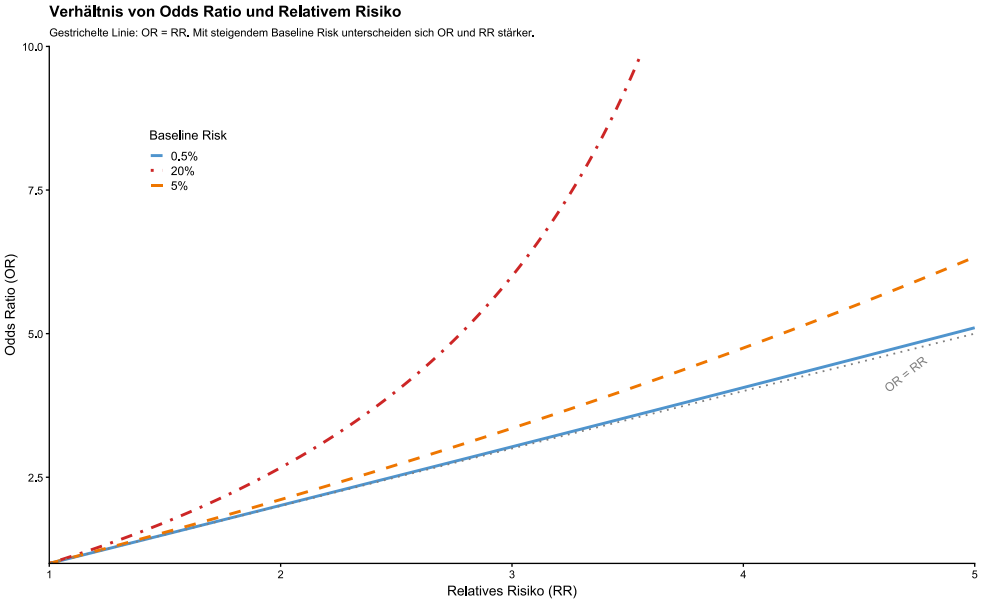
Bei Odds Ratios berechnen wir für jede Gruppe die Relation, dass Dinge passieren oder nicht[1] und setzen diese Relation dann zueinander ins Verhältnis:

$$OR = \frac{N_a}{N_b} / \frac{N_c}{N_d}$$

1. Für die Expert:innen: ORs werden mit P(Dinge passieren)/P(Dinge passieren nicht) berechnet. Wir können hier aber das N rauskürzen.

Der Unterschied zwischen Odds Ratios und Relativen Risiken

RR und OR sind nahezu identisch, wenn die Wahrscheinlichkeit, dass in der “Kontrollgruppe” Dinge **passieren** gering ist (=“Baseline Risk”). Je höher diese Wahrscheinlichkeit ist, desto stärker divergieren OR und RR.



Formal besteht zwischen RR und OR folgendes Verhältnis (mit P_{BL} als Baseline Risiko):

$$RR = \frac{OR}{1 - P_{BL} + OR \cdot P_{BL}}$$

Sind Männer konservativer?

Behauptung: Kinder unter 6 Jahren leiden, wenn die Mutter erwerbstätig ist.

	Männer (%)	Männer kum. (%)	Frauen (%)	Frauen kum. (%)
Stimme überhaupt nicht zu	25.5	25.5	39.8	39.8
Stimme eher nicht zu	32.4	57.8	32.5	72.4
Weder noch	18.9	76.8	14.2	86.6
Stimme eher zu	18.3	95.1	10.5	97.1
Stimme voll zu	4.9	100.0	2.9	100.0

Sind Männer konservativer?

Wir setzen die Frauen als “Kontroll-/Referenzgruppe” und nehmen “stimme eher zu” und “stimme voll zu” als “Ereignis *Zustimmung*”. Dann können wir berechnen:

$$RR = \frac{23.2}{13.4} = 1.73$$

Das “Risiko” auf diese Frage zuzustimmen ist bei Männern um das 1.7-fache höher.

$$OR = \frac{23.2}{76.8} / \frac{13.4}{86.6} = 1.96$$

Die Chance, dass ein Mann zustimmt anstatt “nicht zustimmt”, ist

um das 1.96-fache höher.