Gute Vergleiche: Isolation von Einflüßen - Part 2

Klemmbausteine für datenanalytische Modelle

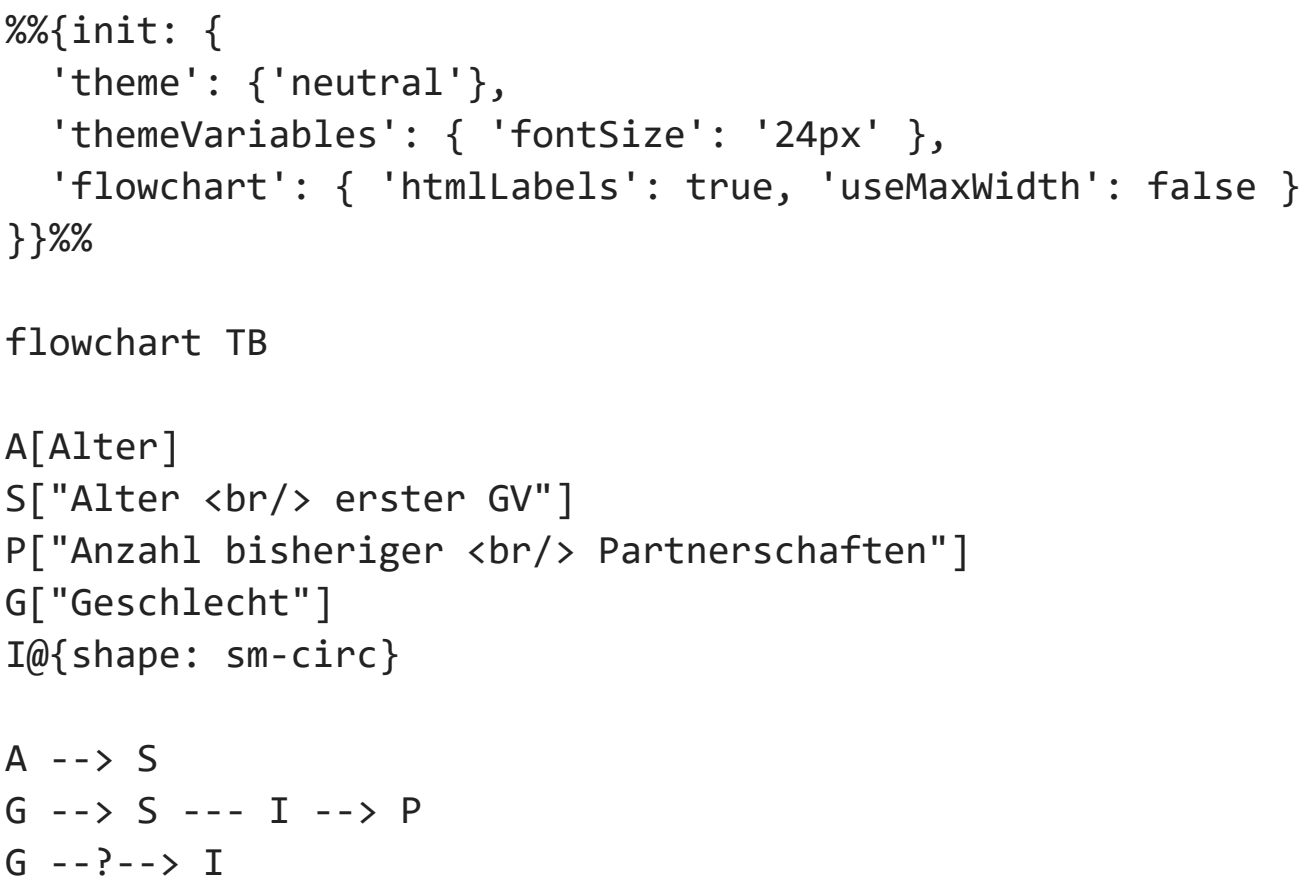
1. **Korrelationen**: Statistische Modelle korrelieren Ausprägungen von Variablen miteinader.

2. **Residualvarianz**: Sie bilden ihre Parameter so, dass die Abstände zwischen *vorhergesagten Werten* und *beobachteten Werten* so gering wie möglich ist.

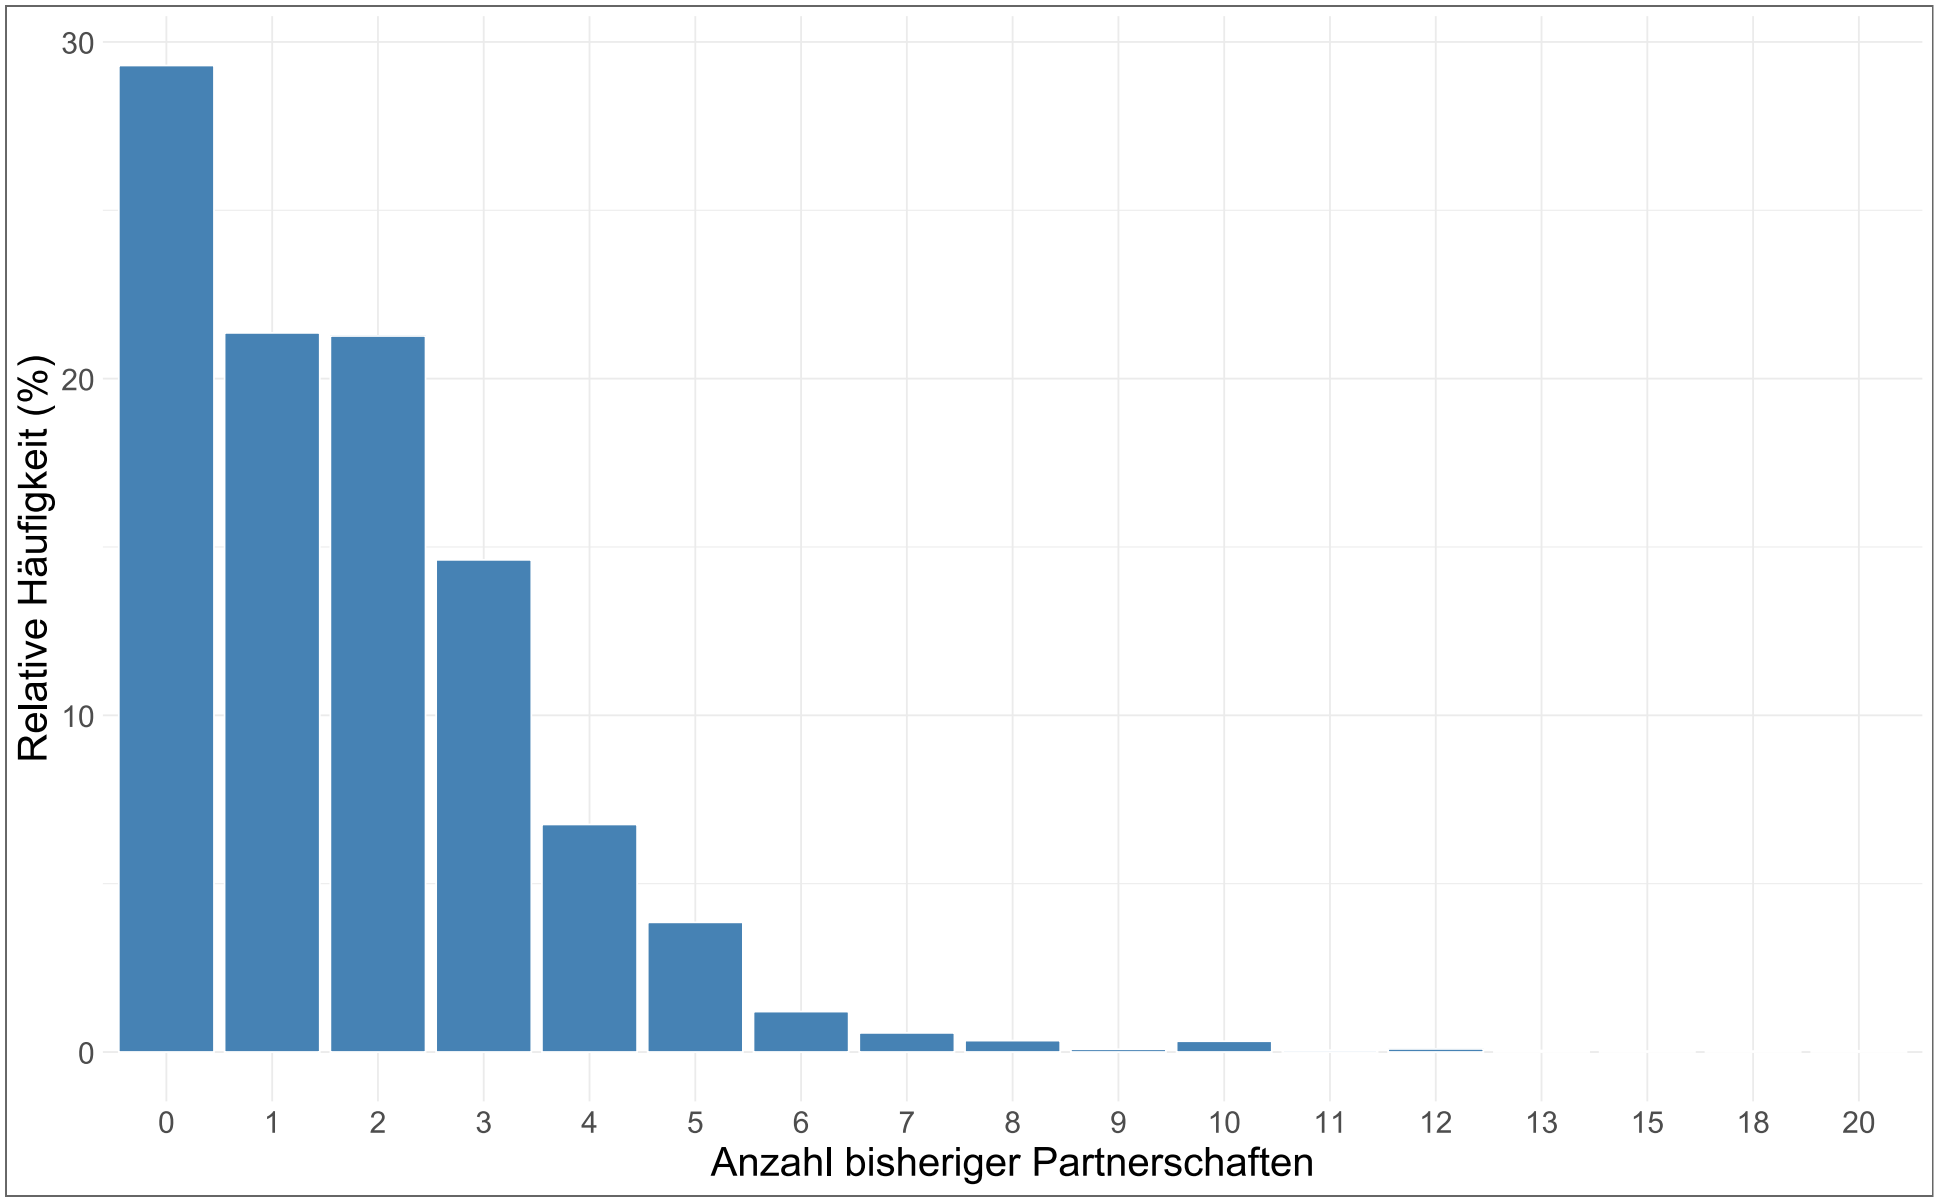
3. **partielle Korrelationen**: Diese Modelle isolieren Einflüsse, indem sie die Korrelation zwischen dem Treatment und anderen Eigenschaften, die *sowohl* mit dem Treatment als *auch* mit dem Outcome verbunden sind, voneinander trennen.

Born to be wild?

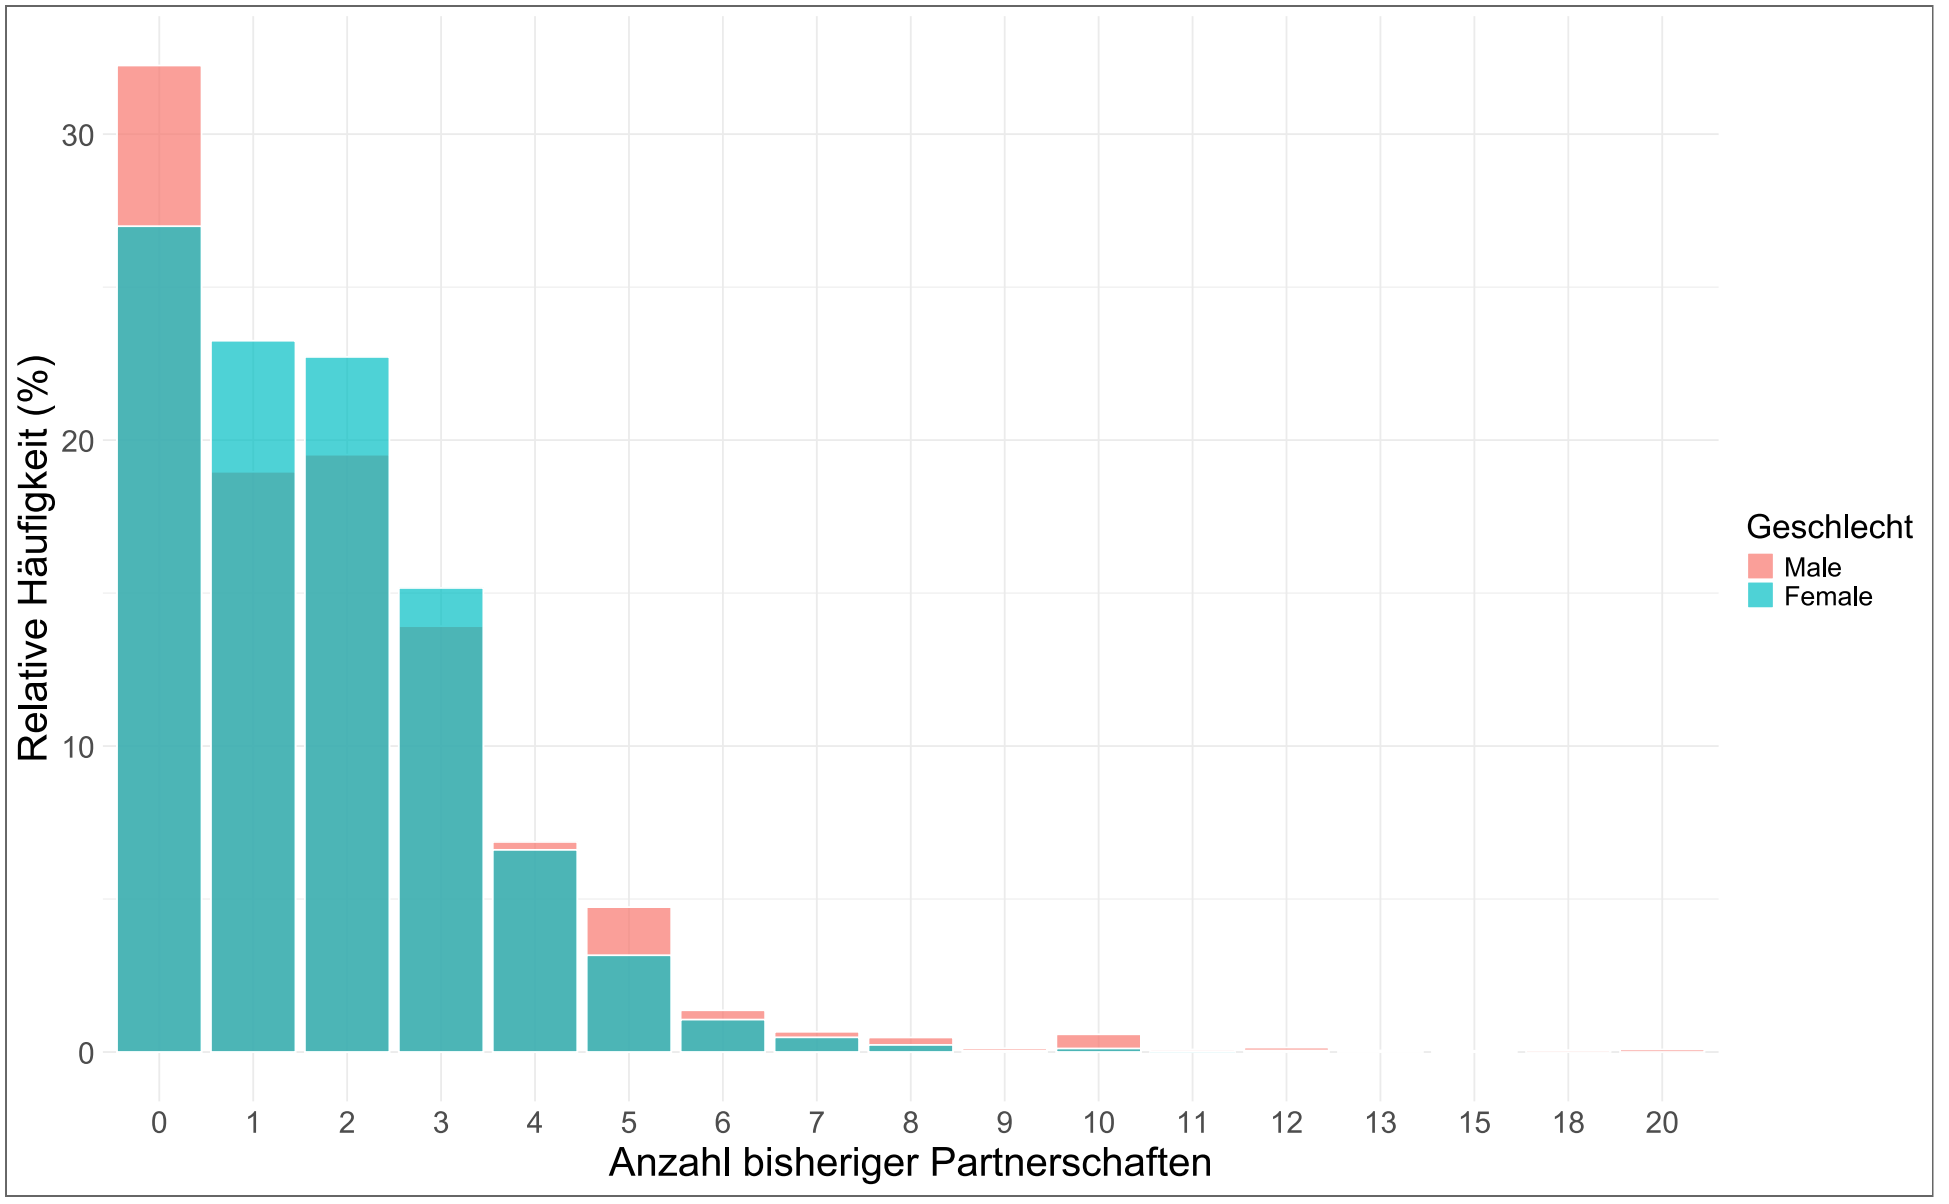
Hypothese: Je früher das Alter des ersten Geschlechtsverkehrs war, desto höher ist die Anzahl bisheriger Partnerschaften zum Erhebungszeitpunkt.



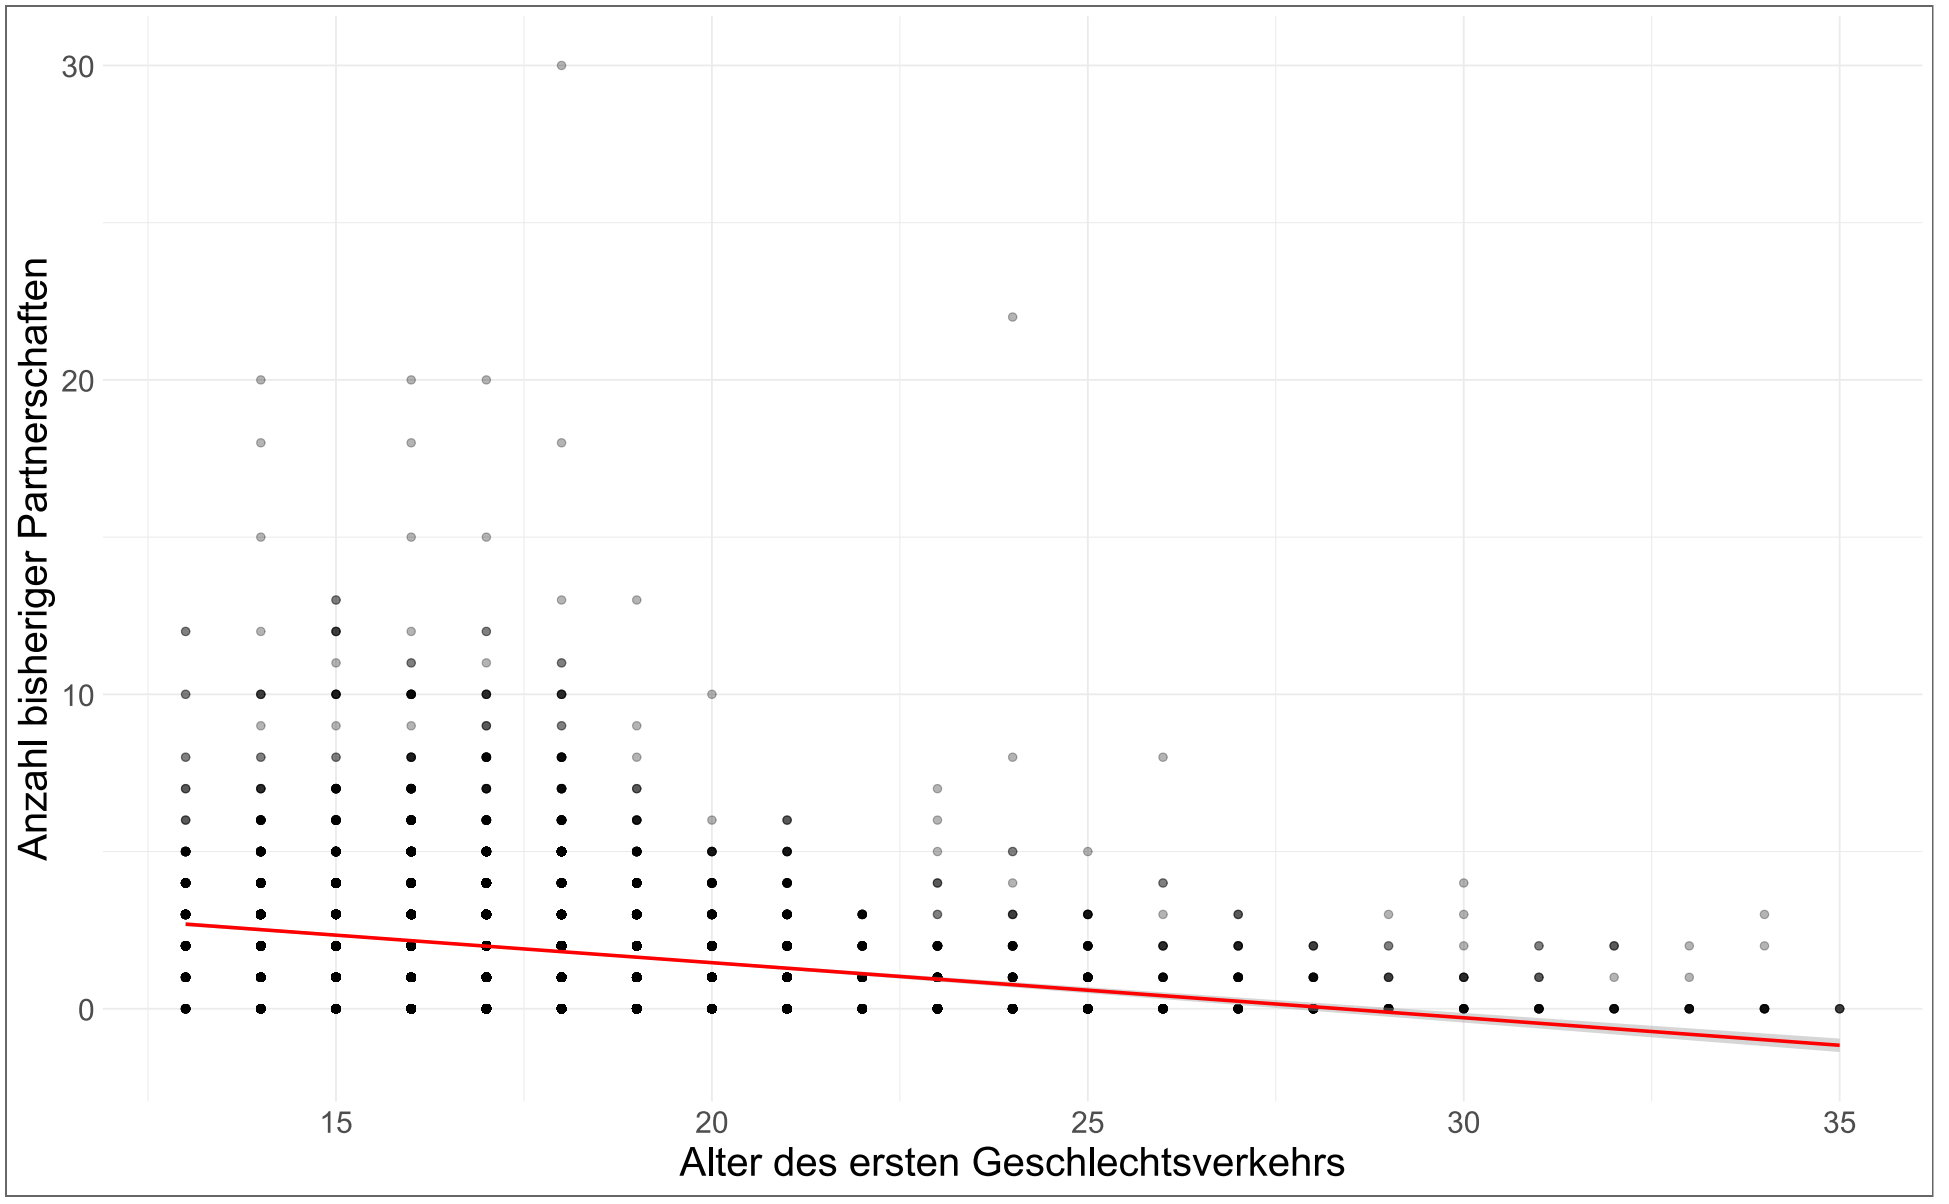
Was sagen uns die FREDA Daten?


30
20
10
0
Relative Häufigkeit (%)
0
1
2
3
4
5
6
7
8
9
10
11
12
13
15
18
20
Anzahl bisheriger Partnerschaften

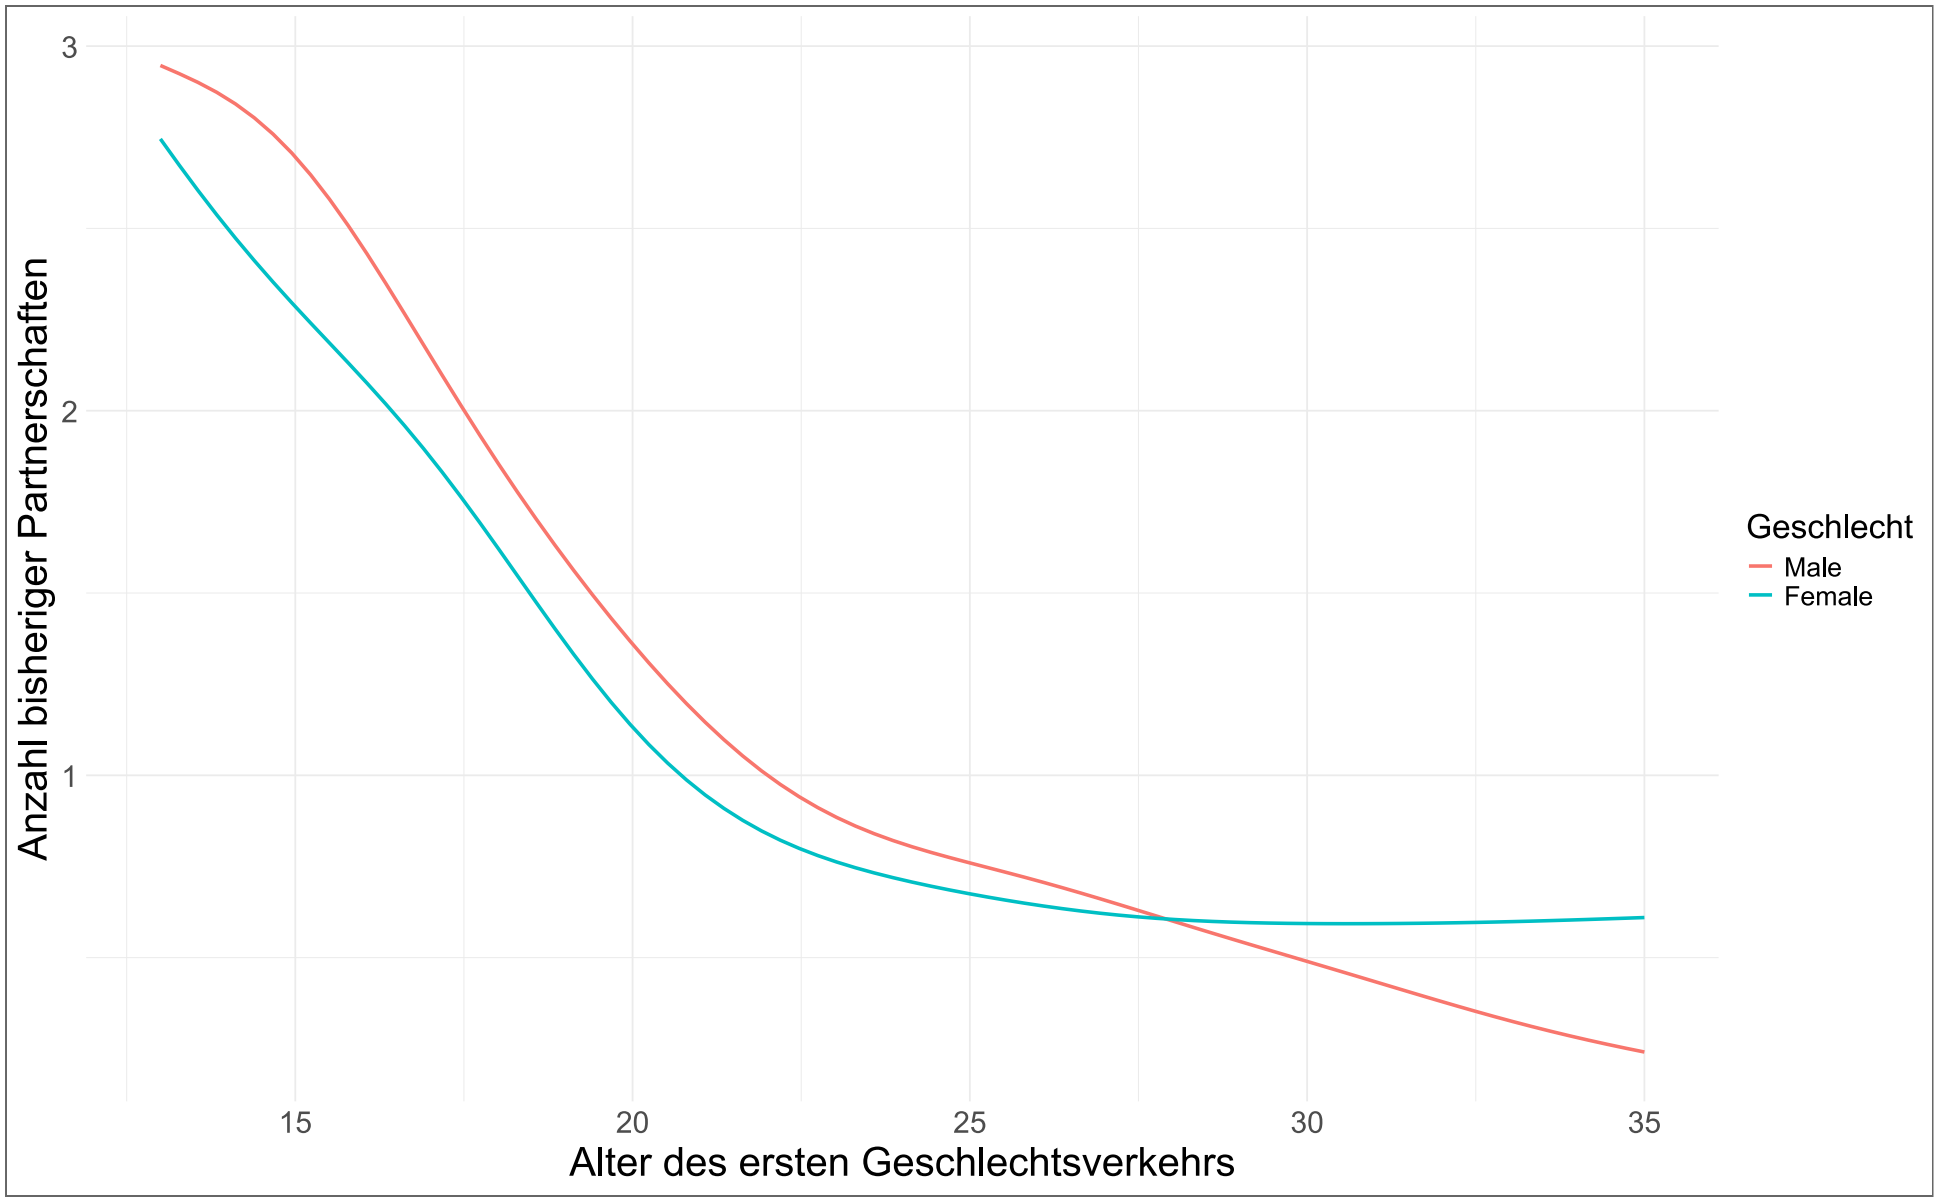
Was sagen uns die FREDA Daten?


Relative Häufigkeit (%)
30
20
10
0
0
1
2
3
4
5
6
7
8
9
10
11
12
13
15
18
20
Anzahl bisheriger Partnerschaften
Geschlecht
Male
Female

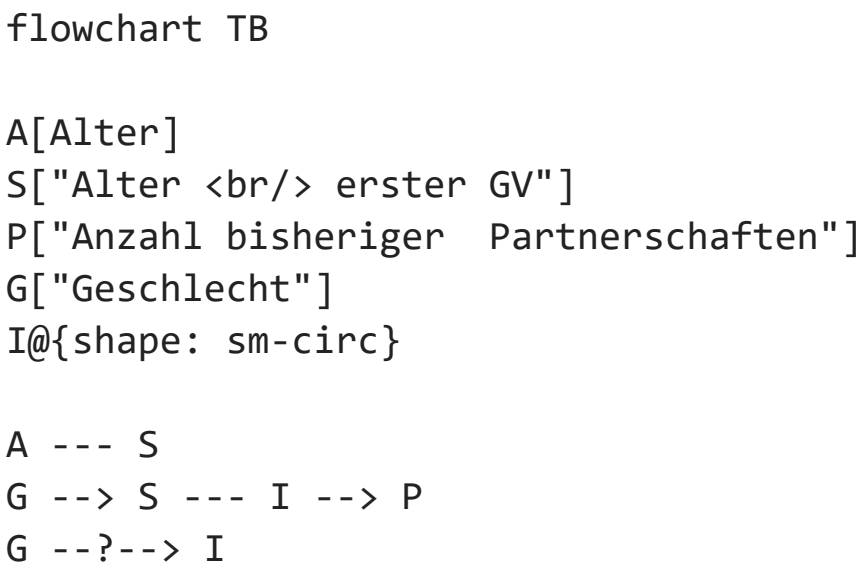
Zusammenhänge


Anzahl bisheriger Partnerschaften
30
20
10
0
15
20
25
30
35
Alter des ersten Geschlechtsverkehrs

Flexiblere Modellierung (No-Golem-Policy!)


Anzahl bisheriger Partnerschaften
3
2
1
15
20
25
30
35
Alter des ersten Geschlechtsverkehrs
Geschlecht
Male
Female

Was macht ein (Regressions)-Modell?



- Regressionsmodelle sind Werkzeuge zur - Erfassung der Größenordnung von Einflüssen - und zur Isolation von Einflüssen.
- Ein typisches Regressionsmodell bezieht sich immer auf **direkte** Einflüsse auf **ein** Outcome.[1]
- Es werden daher diejenigen “Pfeile” untersucht, die direkt auf eine Box abzielen.

- Wir können aber so tun, als ob bestimte “Boxen” nicht vorkommen, um damit “direkte” Pfeile herzustellen
  - Modelle, die mehrere Outcomes gleichzeitig haben sind u.a.: Strukturgleichungsmodelle, Seemingly Unrelated Regression, Joint Models

Regressionsmodelle drücken erwartete Differenzen aus

Jedes Regressionsmodell nimmt einen statistischen Kennwert und berechnet Differenzen dieses Kennwerts über verschiedene Gruppen.

Regressionsmodell	Differenzen in
Lineare Regression	Mittelwerte
Lineares Wahrscheinlichkeitsmodell	Wahrscheinlichkeiten
Logistische Regression	Odds Ratios
Variance Function Regression	Varianzen
Quantil Regression	Quantilwerte

Was ist eine gute Schätzung - Kausaltheoretisch?

- Die (soziale) Welt wirkt auf uns **systematisch** über verschiedene Prozesse.
- Im Rahmen dieser Bedingungen entwickeln wir dennoch ein hohes Maß an Individualität, d.h.: kleinere oder größere **Abweichungen** zu den “Typen”, die das Resultat sozialer Prozesse sind.
- Wenn wir alle systematischen Einflüsse auf ein Outcome erfasst haben, kann der Rest nur noch **unsystematisch*** und damit **zufällig** sein.
- Eine lineare Regression soll die systematischen “Typen” hinsichtlich eines Outcomes als eine **Nievauverschiebung** erfassen.
- *Falls* dies eine korrekte Erfassung der Wirkung der studierten sozialen Prozesse ist, sind die individuellen Abweichungen zum Niveau der eigenen Gruppe unsystematisch / zufällig.

Dieser Gedanke in “Kunstform”


Je mehr Alkohol konsumiert wird,
desto asozialer wird das Verhalten.
ASOZIALES VERHALTEN (NIVEAU)
hoch
niedrig
REGRESSIONSGERADE (DURCHSCHNITTLICHER VERLAUF)
RESIDUUM (ABWEICHUNG)
POSITIVES RESIDUUM (MEHR ASOZIAL ALS ERWARTET)
NEGATIVES RESIDUUM (WENIGER ASOZIAL ALS ERWARTET)
KEIN ALKOHOL
ALKOHOLKONSUM
MAXIMALER ALKOHOL

Niveauverschiebung in der Regression

Regression-Visualisierung

beta_0

-2 0.9 3

-2 -1.5 -1 -0.5 0 0.5 1 1.5 2 2.5 3

beta_1

-2 0.65 2

-2 -1.6 -1.2 -0.8 -0.4 0 0.4 0.8 1.2 1.6 2

sigma

0.05 0.55 2

0.05 0.25 0.45 0.65 0.85 1.05 1.25 1.45 1.65 1.85 2

Anzeige

both

Error: An error has occurred. Check your logs or contact the app author for clarification.

Die Niederungen der Einzelheiten

$$\underbrace{y_i}_{\substack{\text{individ. Anzahl} \\ \text{bisheriger Partner}}} = \underbrace{\hat{\alpha}}_{\substack{\text{durchschn. Anzahl} \\ \text{Basisgruppe}}} + \underbrace{\hat{\beta} \cdot x_i}_{\substack{\text{systematische} \\ \text{Gruppenunterschiede}}} + \underbrace{\epsilon_i}_{\substack{\text{individuelle} \\ \text{Abweichung} = \text{Residuum}}}$$

Abkürzung	“sprich”	Bedeutung
y_i		Gemessener Wert der Anazhl bisheriger Beziehungen für Person i
$\hat{\alpha}$ / $\hat{\beta}_0$	alpha / beta null	Durchschnittliche Anzahl bisheriger Beziehungen für die Referenzgruppe
$\hat{\beta} x_i$	beta	Differenz in der durchschnittlichen Anzahl bisheriger Beziehungen, wenn wir Personen vergleichen, die sich im Alter ihres ersten GVs um ein Jahr unterscheiden
ϵ_i	epsilon	(zufällige) Differenz zwischen der beobachteten Anzahl bisheriger Beziehungen für Person i zum Durchschnitt für Personen, die im gleichen Alter wie Person i ihren ersten GV hatten

Von individuellen Werten zur Schätzung von Einflüssen

- Unser altes Problem: Wir können Einflüsse nicht auf Individualebene schätzen.
- Wir müssen Einflüsse durch den Vergleich von Untersuchungseinheiten erfassen, die sich im Hinblick auf das Treatment um eine Einheit unterscheiden (und deren sonstige Unterschiede ignorierbar sind).
- Die Modellparameter einer Regression beziehen sich daher auf Unterschiede zwischen Gruppen.

$$\underbrace{\hat{y}_i}_{\substack{\text{erwartete Anzahl} \\ \text{bisheriger Partner}}} = \underbrace{\hat{\alpha}}_{\substack{\text{durchschn. Anzahl} \\ \text{Basisgruppe}}} + \underbrace{\hat{\beta} \cdot x_i}_{\substack{\text{systematische} \\ \text{Gruppenunterschiede im Durchschnitt}}}$$

Was ist eine gute Schätzung eines Einflusses - Statistisch?



Johann Carl Friedrich Gauß, der Typ von der Normalverteilung

Behauptung des alten Gauß: Diejenige Schätzung eines Regressionsmodells ist am Besten, die die kleinst mögliche Summe der (quadrierten) Abstände zwischen den tatsächlichen und den geschätzten Werten (=Regressionsgerade) generiert.

- Die Residuen werden quadriert, weil sich negative und positive Abweichungen von der Schätzung nicht wegsummieren sollen. Wir möchten das “Gesamtpaket” aller Residuen haben.

- Schätzungen, die hohe einzelne Abweichungen verursachen, erhalten durch die Quadrierung ebenfalls eine schlechtere Bewertung, weil hohe quadrierte Abweichungen die Gesamtsumme aller quadrierten Residuen stark beeinflussen.

Methode der kleinsten (Residual)quadrate

- Denken Sie daran, dass $\hat{y}_i$ eine **Schätzung** der Ausprägung eines Typen ist, die **lediglich** durch systematische Prozesse bedingt werden.
- Eine lineare Regression setzt “soziale Prozesse” mit *Niveauverschiebungen* gleich.
- Eine Niveauverschiebung wird als Differenz von geschätzten Ausprägungen nach Typen behandelt und die Residuen als “Zufallsstreuung” angesehen.
- **Zentrale Behauptung**: Systematische Prozesse sind stets stärker als zufällige Prozesse.[1] Daher ist die Methode am besten geeignet systematische von unsystematischen Einflüssen sauber zu trennen, die die kleinste Summe der “Zufallsstreuung” erfassen kann.
- Die Schätzmethode heißt deswegen **O**rdinary-**L**east-**S**quares - die Minimerung der Residualquadrate.
- Etwas muss über den “Placebo-Effekt” hinaus gehen, um als wirkungsvoll angesehen zu werden.

Wie minimiert man die Summe der Residuen?

$$\begin{aligned}\min &= \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^{n}(y_i - (\hat{\alpha} + \hat{\beta}x_i))^2\end{aligned}$$

Mathematisch lösbar durch: Ableitung nach $\hat{\alpha}$ und $\hat{\beta}$ und diese beiden ersten Ableitungen auf 0 setzen und nach $\hat{\alpha}$ oder $\hat{\beta}$ auflösen.

Berechnung von OLS-Parametern

Daraus erhält man (für den Fall von **einer** genutzten Variablen):

$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$

Die Schätzung von $\hat{\alpha}$ verdeutlicht, dass dies ein Mittelwert von y ist, aus dem alle anderen durch x bedingten systematischen Unterschiede herausgerechnet wurden. Es ist der Durchschnittswert derjenigen Gruppe, aus der die Unterschiede zu allen anderen Gruppen - die zum Vergleichen genutzt werden - entfernt wurde. Diese Gruppe nennen wir “Basisgruppe”.

$$\hat{\beta} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{\sum x_i y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum x_i^2 - n \cdot \bar{x}^2}$$

Der $\hat{\beta}$-Koeffizient drückt ein Verhältnis der Covarianz von x und y in Relation zur Variation der x-Variable aus. Oder: Um wieviel erhöhen/verringern sich Y-Werte im Durchschnitt, wenn sich die X-Werte um eine Einheit ändern.

Übung macht die Meisterin

Papier ist geduldig...

Anz. Partnerschaften	Alter erster GV - 17	Geschlecht (0=F, 1=M)
0	8	0
8	0	1
0	0	1
0	5	0
3	1	0
2	1	1
1	2	1
0	0	0
5	0	0
0	1	1

Anz. Partnerschaften	Alter erster GV - 17	Geschlecht (0=F, 1=M)
Ø 1.9	Ø 1.8	Ø 0.5

Berechnung

$$\hat{\beta} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{-27.2}{63.6} = -0.428$$

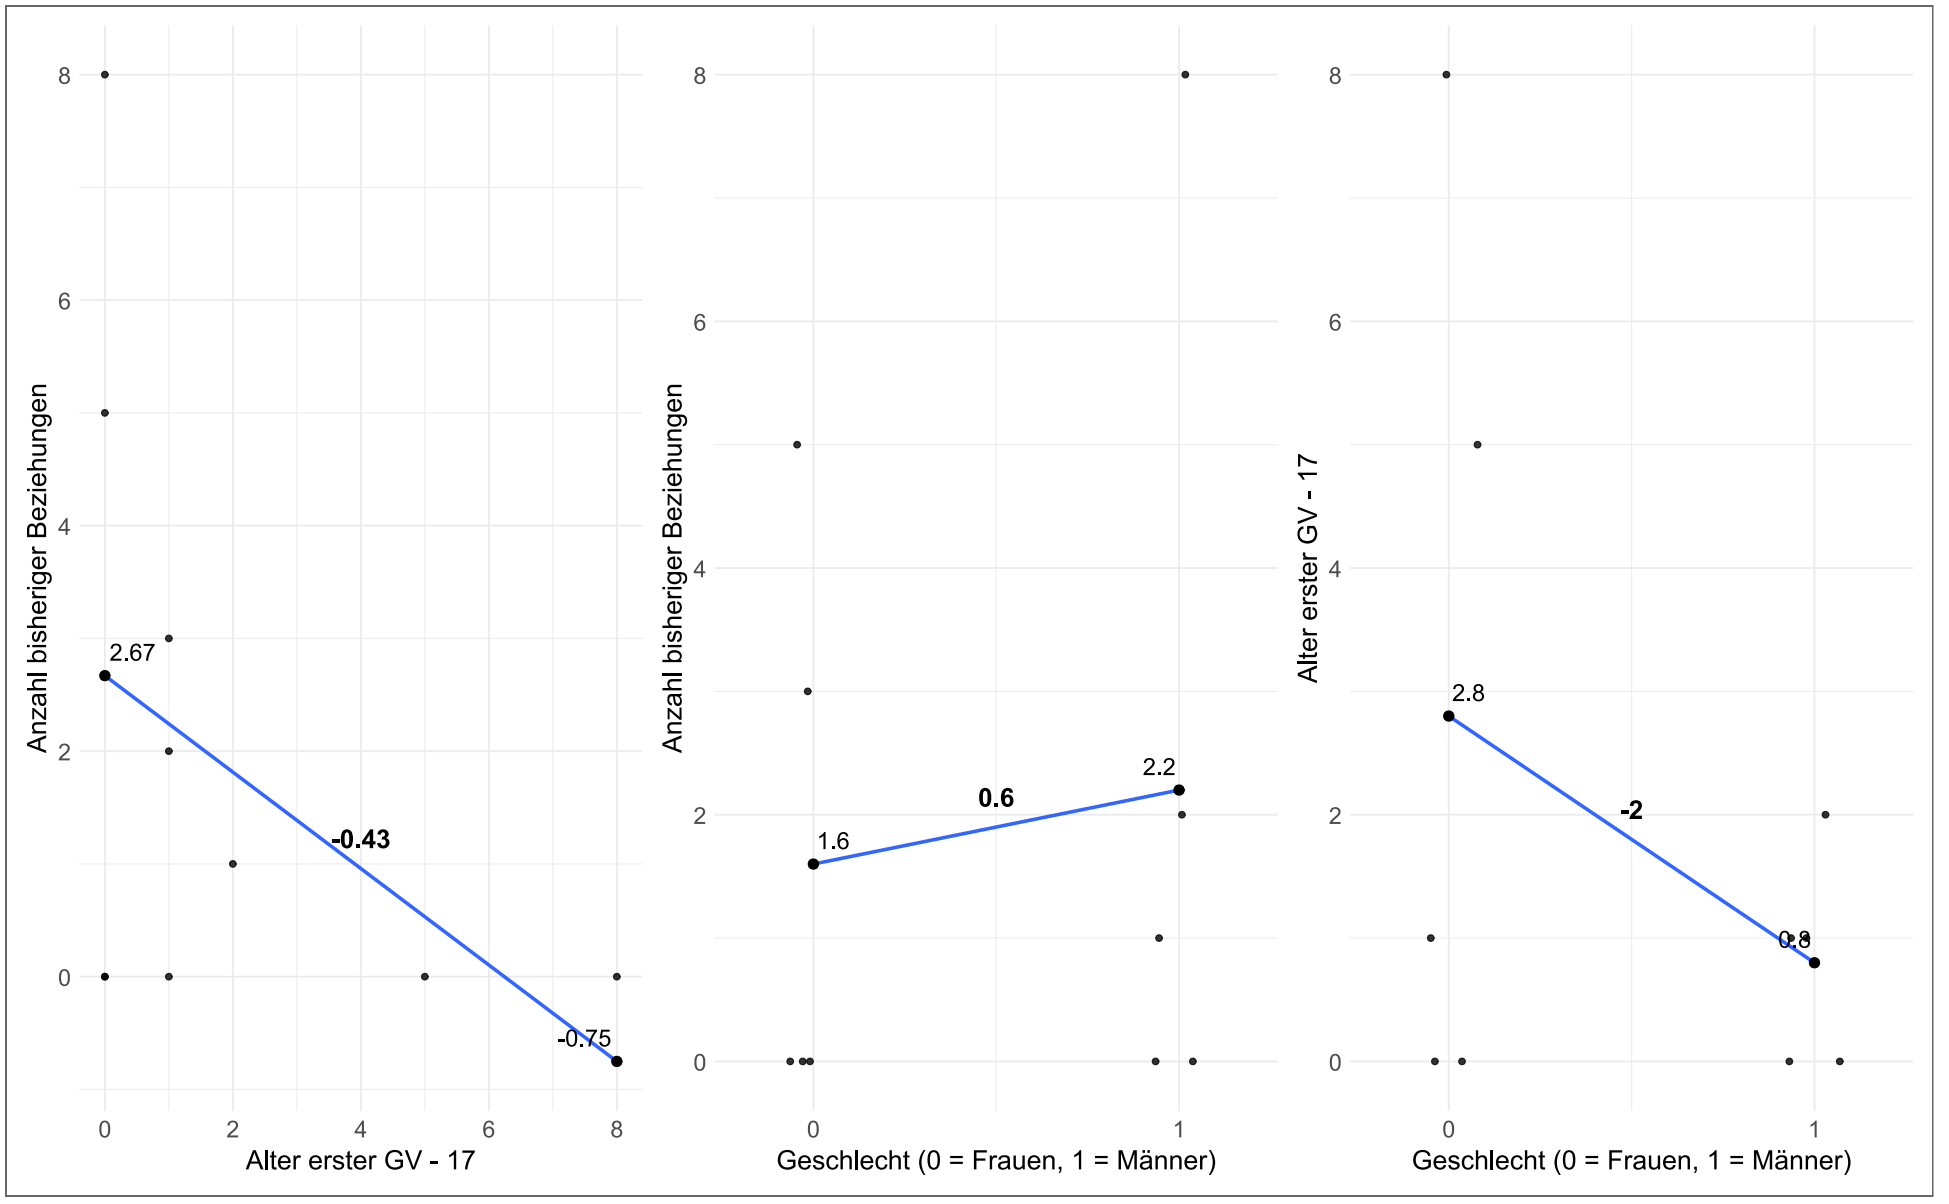
- Die durchschnittliche Anzahl bisheriger Partnerschaften sinkt um 0.43 Partner*innen für jedes Jahr, in dem der erste GV später als 17 statt fand und 0.43 für jedes Jahr, in dem der erste GV früher als 17 statt fand.
- Alternativ: Vergleicht man Personen, deren GV ein Jahr später als die Vergleichsgruppe stattfand, ist deren durchschnittliche Anzahl bisheriger Partner um 0.43 geringer.

  $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} = 1.9 - (-0.428) * 1.8 = 2.67$
  Die Basisgruppe sind in diesem Modell Personen, die mit 17 das erste Mal GV hatten. Wir erwarten daher für diese Gruppe, eine durchschnittliche Anzahl von 2.67 bisherigen Partner:innen.

Was ist das für ein Voodoo?

α +	$\beta \cdot$	Alter erster GV - 17	= $\hat{y}_i$
2.67	-0.428	-3	3.954
2.67	-0.428	-2	3.526
2.67	-0.428	-1	3.098
2.67	-0.428	0	2.67
2.67	-0.428	1	2.242
2.67	-0.428	2	1.814
2.67	-0.428	3	1.386
2.67	-0.428	4	0.958
2.67	-0.428	5	0.53
2.67	-0.428	6	0.102

Wie sieht das in unserem Beispiel aus?


Anzahl bisheriger Beziehungen
Alter erster GV - 17
2.67
-0.43
-0.75
Anzahl bisheriger Beziehungen
Geschlecht (0 = Frauen, 1 = Männer)
1.6
0.6
2.2
Alter erster GV - 17
Geschlecht (0 = Frauen, 1 = Männer)
2.8
-2
0.8

Was ist mit nicht-metrischen Variablen?

OLS behandelt alles als metrisch! Deswegen können Sie die gleichen Formeln über andere Daten bügeln (**Golem-Alarm**).
Wenn wir eine Regression der Anzahl bisheriger Partnerschaften auf das Geschlecht (0 = Frauen, 1 = Männer) durchführen, ergibt sich:

$$\hat{\beta} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{1.5}{2.5} = 0.6$$

Wenn sich das Geschlecht um eine Einheit (Frau = 0 $\rightarrow$ Mann = 1) erhöht, dann erhöht sich die durchschnittliche Anzahl bisheriger Partner:innen um 0.6.

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} = 1.9 - (0.6) * 0.5 = 1.6$$

Die Basisgruppe in diesem Modell sind die Frauen, da der Einfluss von “Mann-sein” in Relation zu “Frau-sein” erfasst wird. Daher erwarten wir für Frauen im Durchschnitt 1.6 bisherige Partner:innen.

Speaker notes