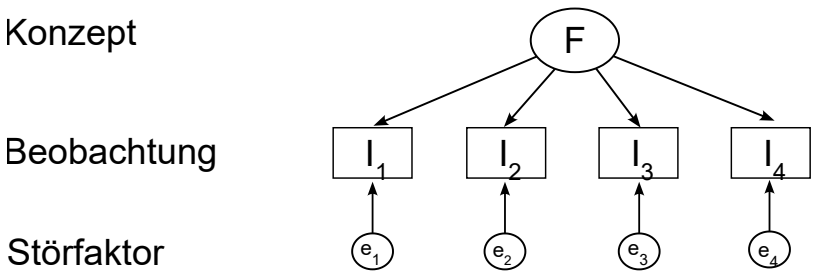
Komplexe datengenerierende Prozesse - Teil 2

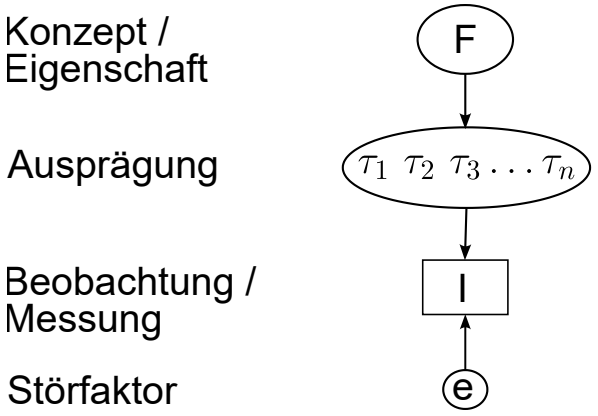
Aus dem Archiv: Die Messung latenter Eigenschaften



Annahmen:

- Die die Ausprägungen in systematischen Zusammenhang miteinander und zu der latenten Eigenschaft stehen.
- Die Störfaktoren sind voneinander unabhängig und treten zufällig auf.

Aus dem Archiv: Überall Fehler

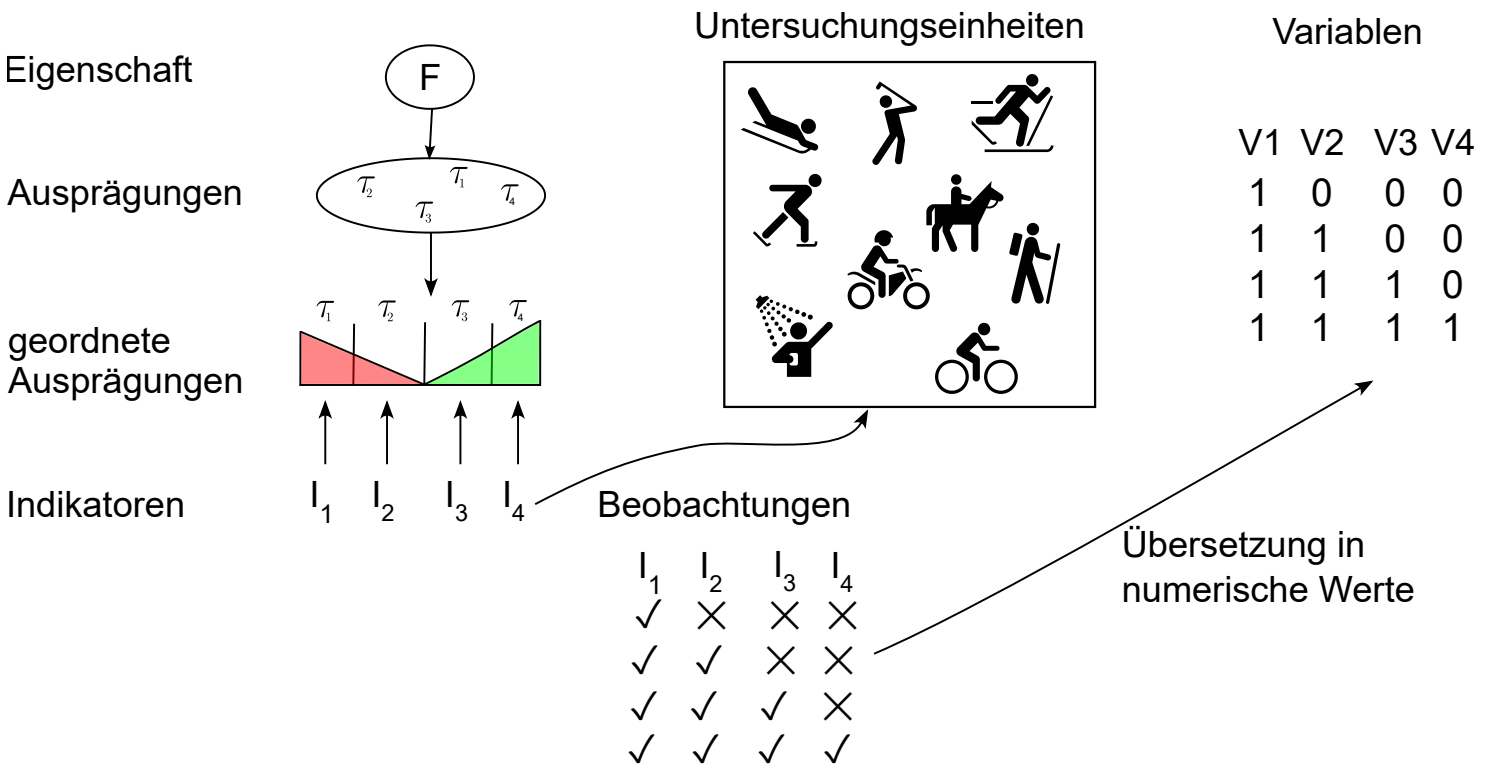


Das Messergebnis y_i (= Beobachteter Wert der Variable Y einer Untersuchungseinheit i) wird mindestens von zwei Komponenten bestimmt:

1. die (wahre) Ausprägung eines Merkmals τ (sprich: tau) sowie
2. einen Störfaktor ϵ (sprich: epsilon), den wir zunächst als zufällig betrachten.

Wir gehen davon aus, dass sich beide Komponenten *additiv* verhalten und damit gilt: $y_i = \tau_i + \epsilon_i$

Aus dem Archiv: Ausprägungen und Indikatoren



Items und latente Eigenschaften

Wenn die Ausprägungen einer latenten Eigenschaft f, die zugrunde liegende Neigung zur Reaktion τ eines Items q_1 beeinflusst, können wir das auch so ausdrücken:

$$\tau_{q_1} = \underbrace{\lambda_{q_1}}_{\text{Niveauverschiebung durch } f} \cdot \underbrace{f_i}_{\text{Ausprägung der Eigenschaft } f}$$

Wir können dann diese Information nutzen, um für jede Person i einen Messwert für ein Item zu modellieren, von dem wir ausgehen, dass er sich additiv aus einer zugrunde liegenden

Neigung und einem (zufälligen) Messfehler zusammensetzt:

$$\underbrace{y_{q_1 i}}_{\text{Messwert für Item } q_1 \text{ für Person i}} = \underbrace{\lambda_{q_1}}_{\text{Niveauverschiebung in der Reaktion auf } q_1} \cdot \underbrace{f_i}_{\text{Ausprägung der Eigenschaft } f \text{ für Person i}} + \underbrace{\epsilon_{q_1 i}}_{\text{Messfehler für Item } q_1 \text{ für Person i}}$$

Gemessenes, Latentes und Unsystematisches

Wenn wir eine Item-Batterie mit vier Items entwickeln und davon ausgehen, dass *ein* latenter Faktor die Reaktion auf die Items beeinflusst, dann können wir dies folgendermaßen ausdrücken:

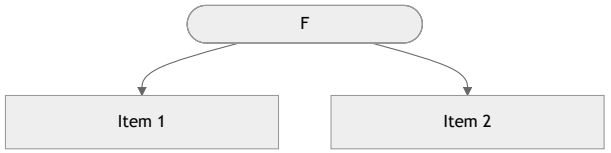
$$
\begin{aligned}
y_{q_1 i} &= \lambda_{q_1} f_i + \epsilon_{q_1 i} \\
y_{q_2 i} &= \lambda_{q_2} f_i + \epsilon_{q_2 i} \\
y_{q_3 i} &= \lambda_{q_3} f_i + \epsilon_{q_3 i} \\
y_{q_4 i} &= \lambda_{q_4} f_i + \epsilon_{q_4 i}
\end{aligned}
$$

Wir können das verallgemeinern zu:

$$y_{q_k i} = \lambda_{q_k} f_i + \epsilon_{q_k i}$$

Wir kennen die Werte von $y_{q_k i}$ als Reaktionen auf die Items. Unser Ziel ist, es nun, $\lambda_{q_k} f_i$ so zu bestimmen, dass $\epsilon_{q_k i}$ nur noch unsystematische Variation enthält.

Was ist das für ein datenanalytisches Problem?



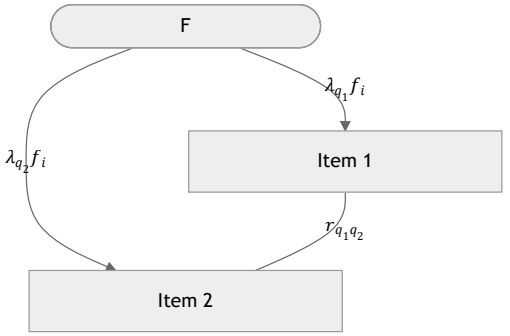
- Die zugrunde liegende Struktur bei einem latenten Faktor, der auf die Reaktion von Items wirkt, können wir auch als “Scheinkorrelation” zwischen den Faktoren beschreiben.
- Bei einer Regression haben wir dies so beschrieben:

Wenn $r_{xy} = r_{xz} \cdot r_{zy}$

$$\hat{\beta}_x = \frac{r_{yx} - r_{yz} \cdot r_{xz}}{1 - r_{xz}^2} \cdot \frac{s_y}{s_x}$$

dann

Was ist das für ein datenanalytisches Problem?



- Übertragen auf den Fall eines latenten Faktors, können wir diese Struktur aus der Regression umformulieren:

$$r_{q_1 q_2} = \lambda_{q_1} f_i \cdot \lambda_{q_2} f_i$$

- Wir suchen nun ein Produkt, dass die Korrelation der Reaktionen auf die Items abbildet.
- Wenn der latente Faktor **perfekt** für die Reaktionen verantwortlich wäre, dann gilt:

$$r_{q_1 q_2} - \lambda_{q_1} f_i \cdot \lambda_{q_2} f_i = 0$$

- Dies ist aber empirisch nie der Fall. Es bestehen immer Messfehler und erratische

Gemeinsame Varianz und Residuen

- Pearsons r ist eine standardisierte Covarianz: $r_{xy} = \frac{Cov_{xy}}{s_x \cdot s_y}$.
- Daher können wir das Problem der Isolierung von systematischen und erratischen Zusammenhängen von Reaktionen auf Varianzen und Covarianzen zurückführen:

$$\underbrace{Cov(q_k q_l)}_{\substack{\text{Covarianz} \\ \text{aller Reaktionen}}} = \underbrace{Cov(\lambda_{q_k} f_i \cdot \lambda_{q_l} f_i)}_{\substack{\text{systematische Varianz} \\ \text{der Reaktionen durch } f}} + \underbrace{Cov(\epsilon q_k \epsilon q_l)}_{\substack{\text{zufällige Covarianz} \\ \text{von Reaktionen}}}$$

- Die datenanalytische Aufgabe ist es, eine Covarianz des latenten Faktors mit den Reaktionen auf die Items, die eine möglichst kleine Summe an (quadrierten) Fehlern erzeugt:

$$\min \sum \left[Cov(q_k q_l) - Cov(\lambda_{q_k} f_i \cdot \lambda_{q_l} f_i) \right]^2$$

Was heißt das konkret?

137 **Die folgenden Fragen beziehen sich auf die Rollen von Männern und Frauen.**

☞ *Bitte wählen Sie für jede Frage eine Antwort aus.*

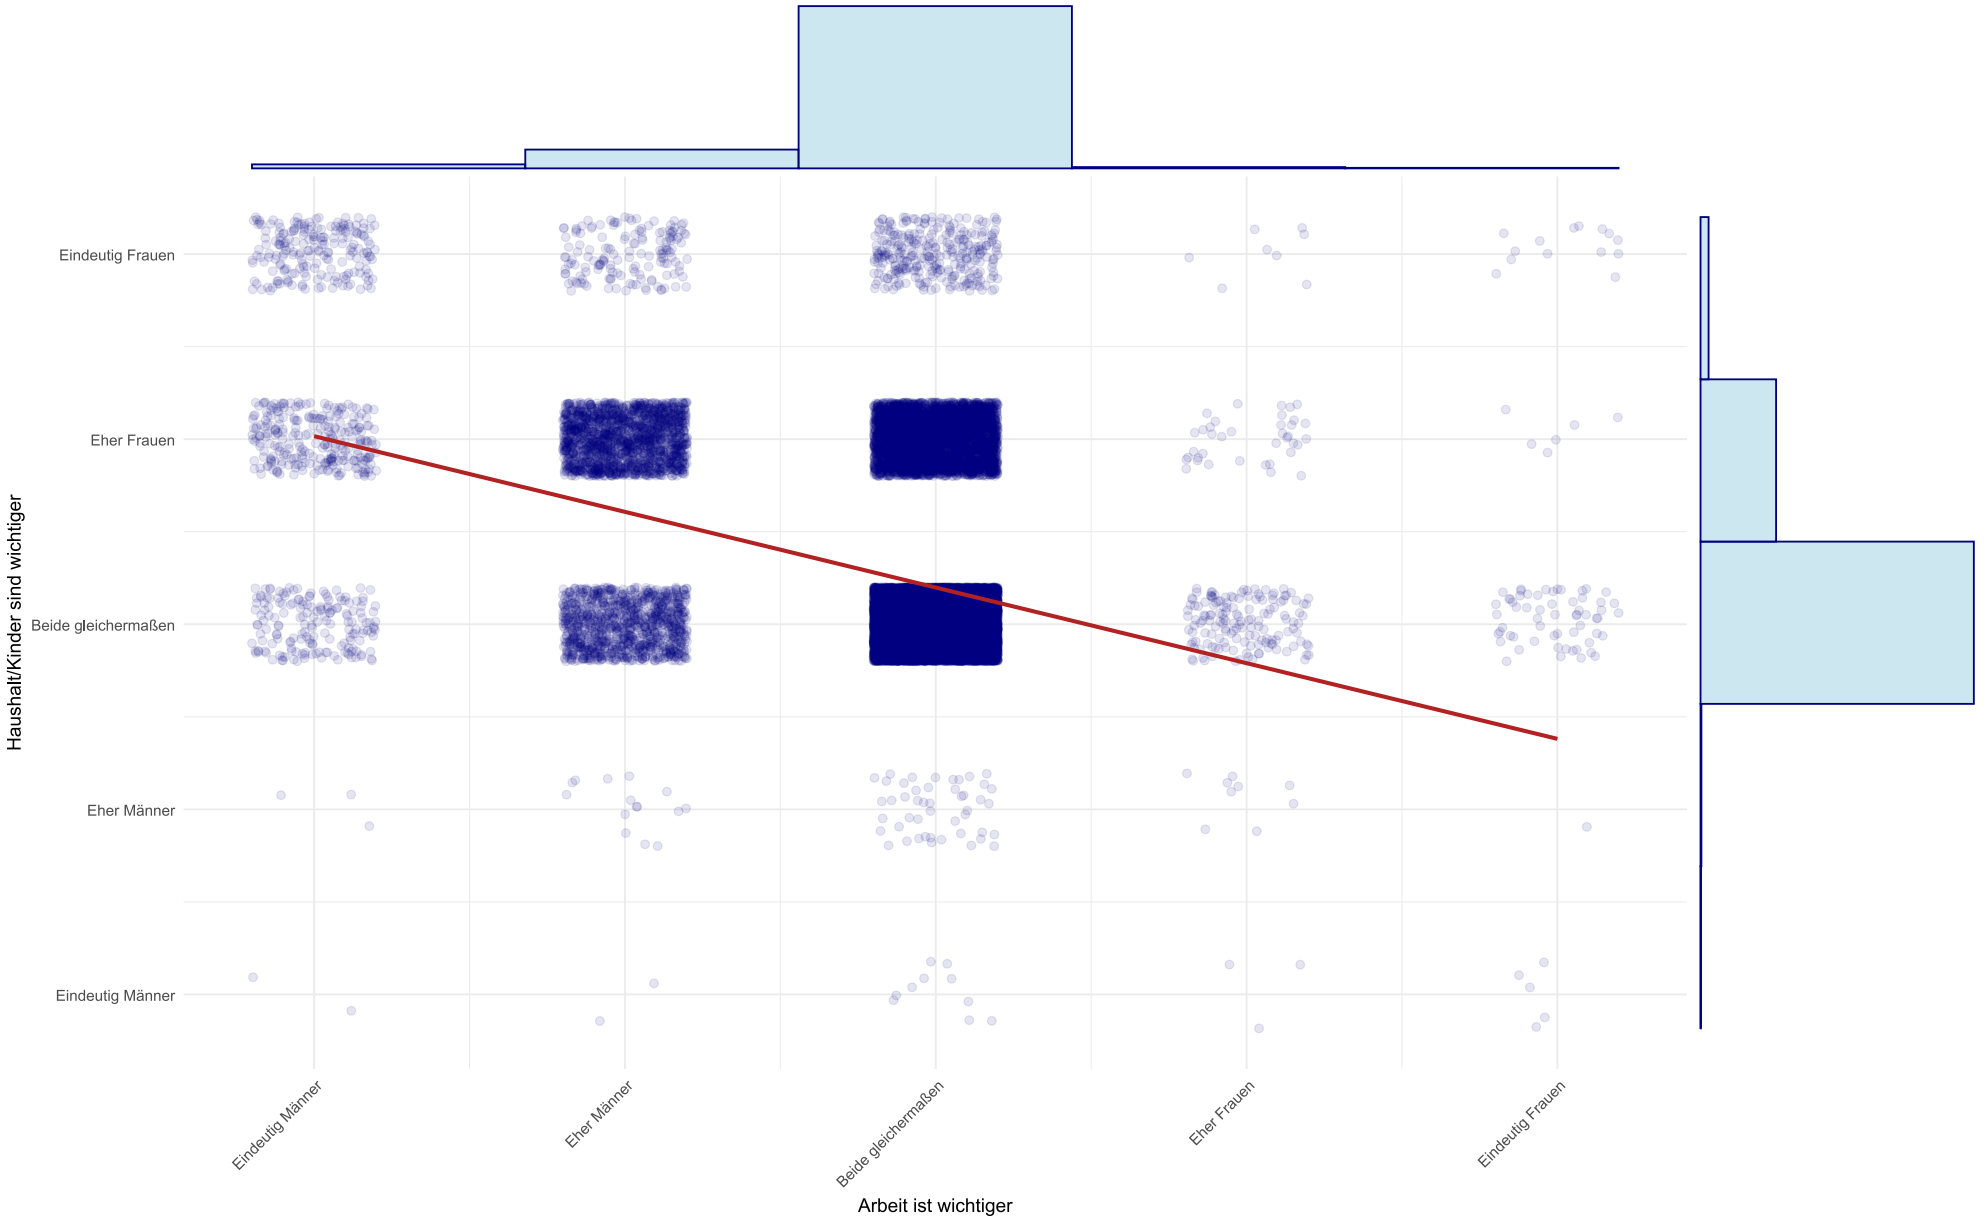
	Eindeutig Männer 1	Eher Männer 2	Beide Geschlechter gleichermaßen 3	Eher Frauen 4	Eindeutig Frauen 5
Im Allgemeinen, wer würde eine bessere politische Führungsperson abgeben, Männer oder Frauen?	☐	☐	☐	☐	☐
Für wen ist eine universitäre Ausbildung wichtiger, für Männer oder für Frauen?	☐	☐	☐	☐	☐
Für wen ist es wichtiger, eine Arbeit zu haben, für Männer oder für Frauen?	☐	☐	☐	☐	☐
Für wen ist es wichtiger, sich um den Haushalt und die Kinder zu kümmern, für Männer oder für Frauen?	☐	☐	☐	☐	☐
Wer ist besser darin, sich um kleine Kinder zu kümmern, Männer oder Frauen?	☐	☐	☐	☐	☐

Verteilung von Antworten

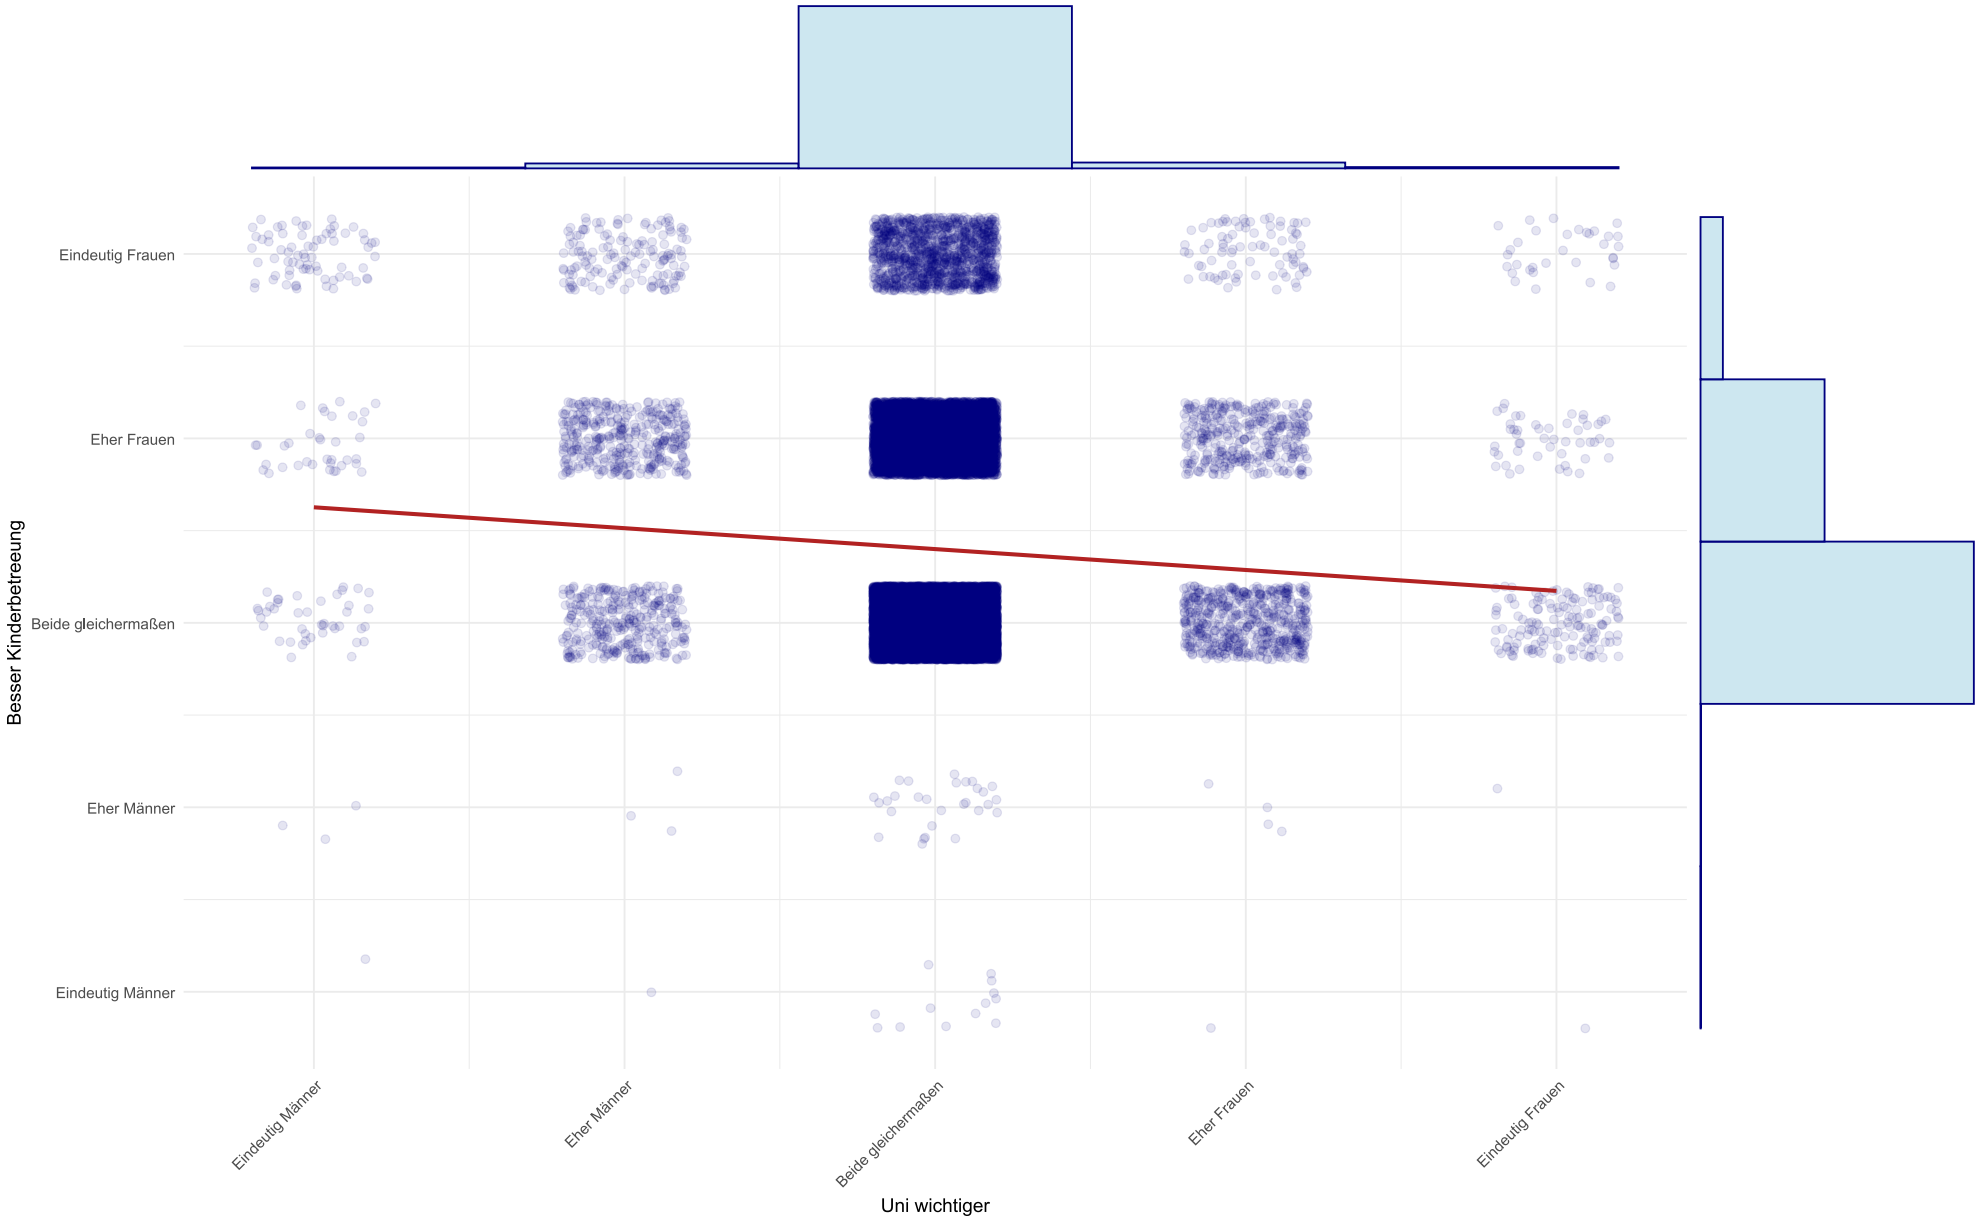
Relative Häufigkeiten der Antworten pro Item (%)

Item	Antwortkategorien				
Item_Name	Eindeutig Männer	Eher Männer	Beide gleichermaßen	Eher Frauen	Eindeutig Frauen
Politische Führung	1.6	5.4	81.6	9.0	2.4
Uni ist wichtiger	0.5	2.8	92.6	3.3	0.7
Arbeit ist wichtiger	2.1	10.0	86.8	0.7	0.3
Haushalt/Kinder sind wichtiger	0.1	0.2	76.4	21.1	2.2
Besser Kinderbetreuung	0.1	0.1	65.0	29.5	5.3

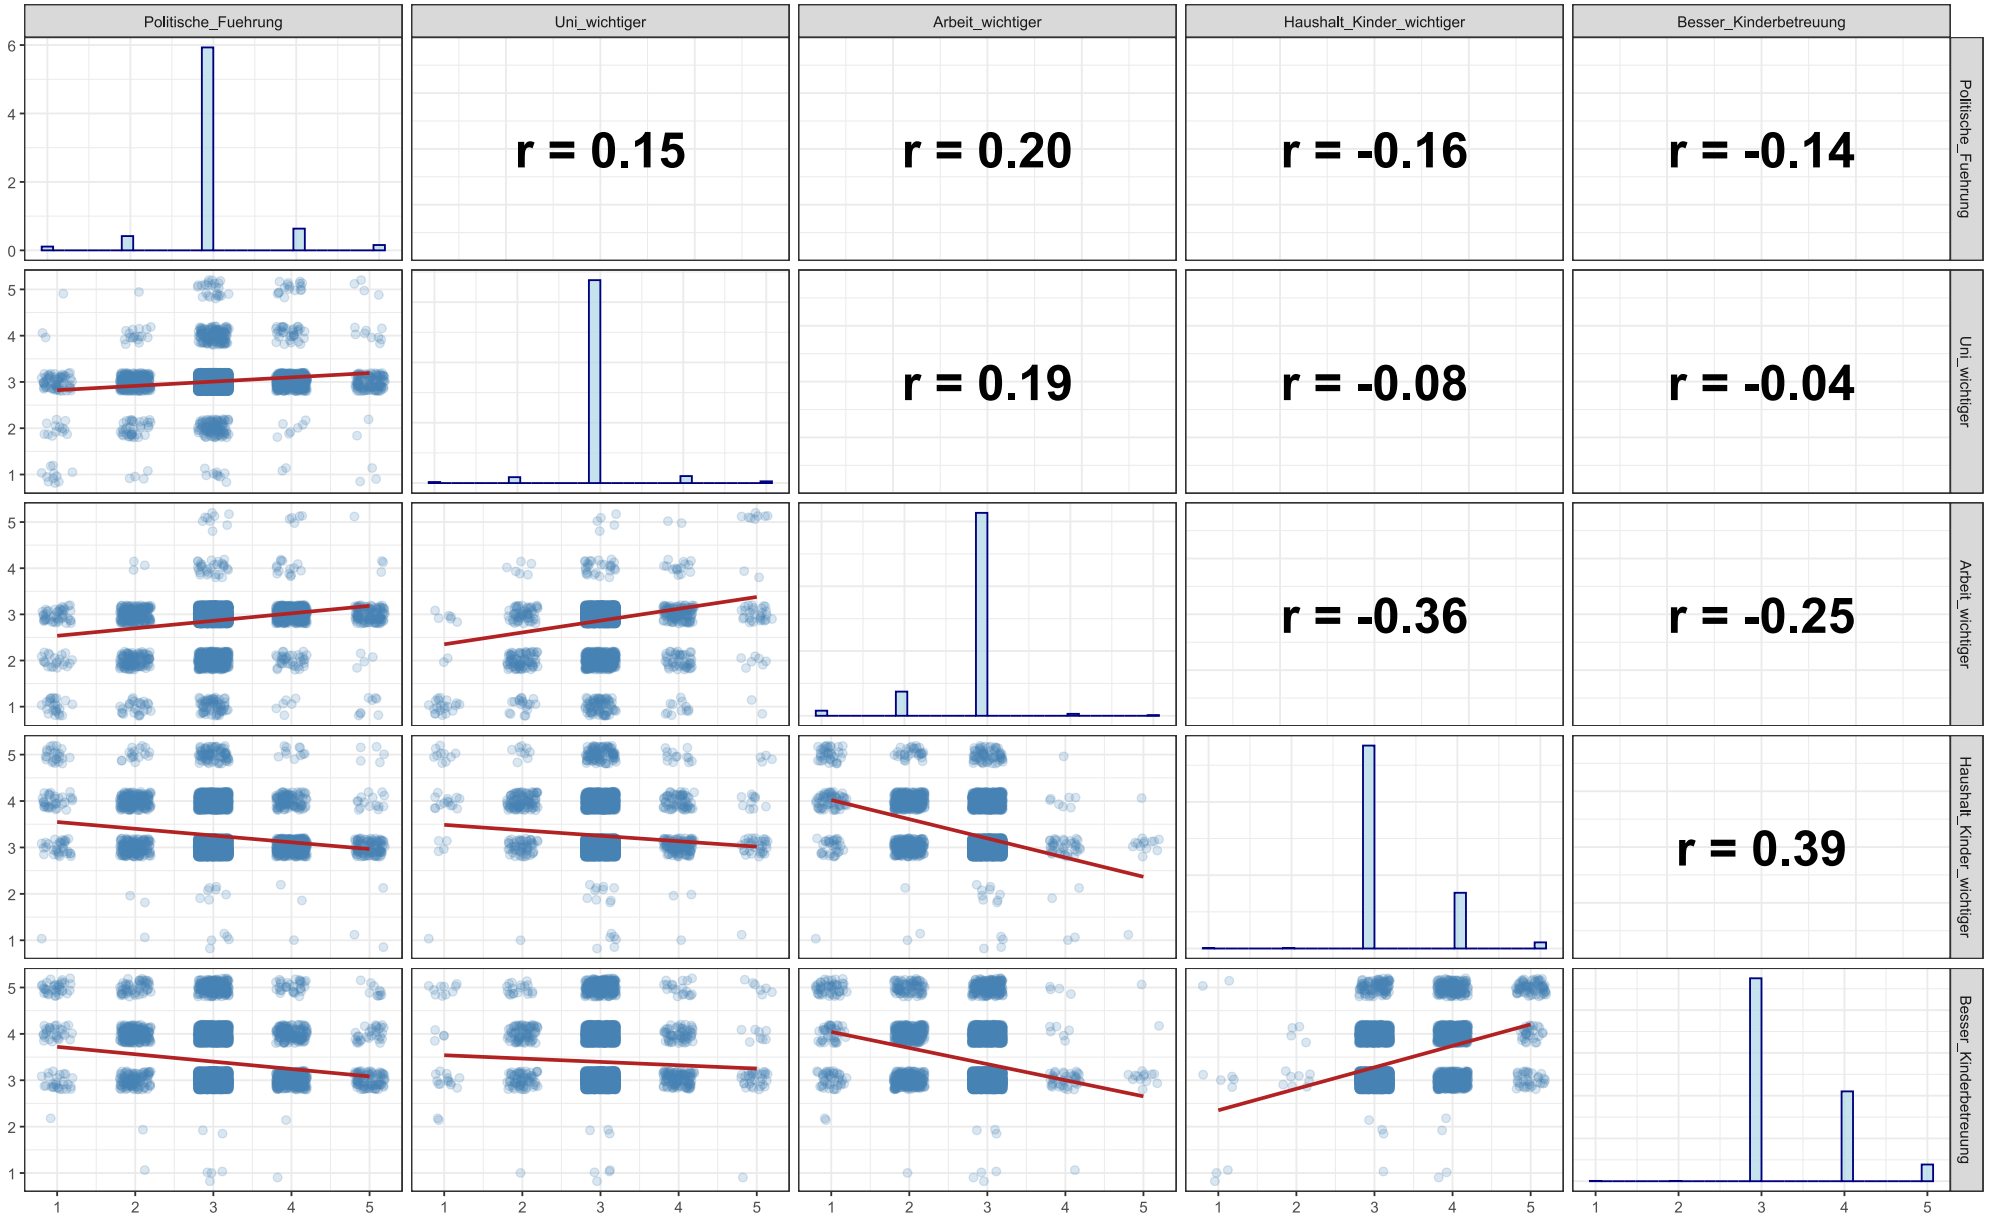
Systematische Covarianz der Reaktionen


Haushalt/Kinder sind wichtiger
Eindeutig Frauen
Eher Frauen
Beide gleichermaßen
Eher Männer
Eindeutig Männer
Eindeutig Männer
Eher Männer
Beide gleichermaßen
Eher Frauen
Eindeutig Frauen
Arbeit ist wichtiger

Systematische Covarianz der Reaktionen


Besser Kinderbetreuung
Eindeutig Frauen
Eher Frauen
Beide gleichermaßen
Eher Männer
Eindeutig Männer
Eindeutig Männer
Eher Männer
Beide gleichermaßen
Eher Frauen
Eindeutig Frauen
Uni wichtiger

Alles in einer Matrix

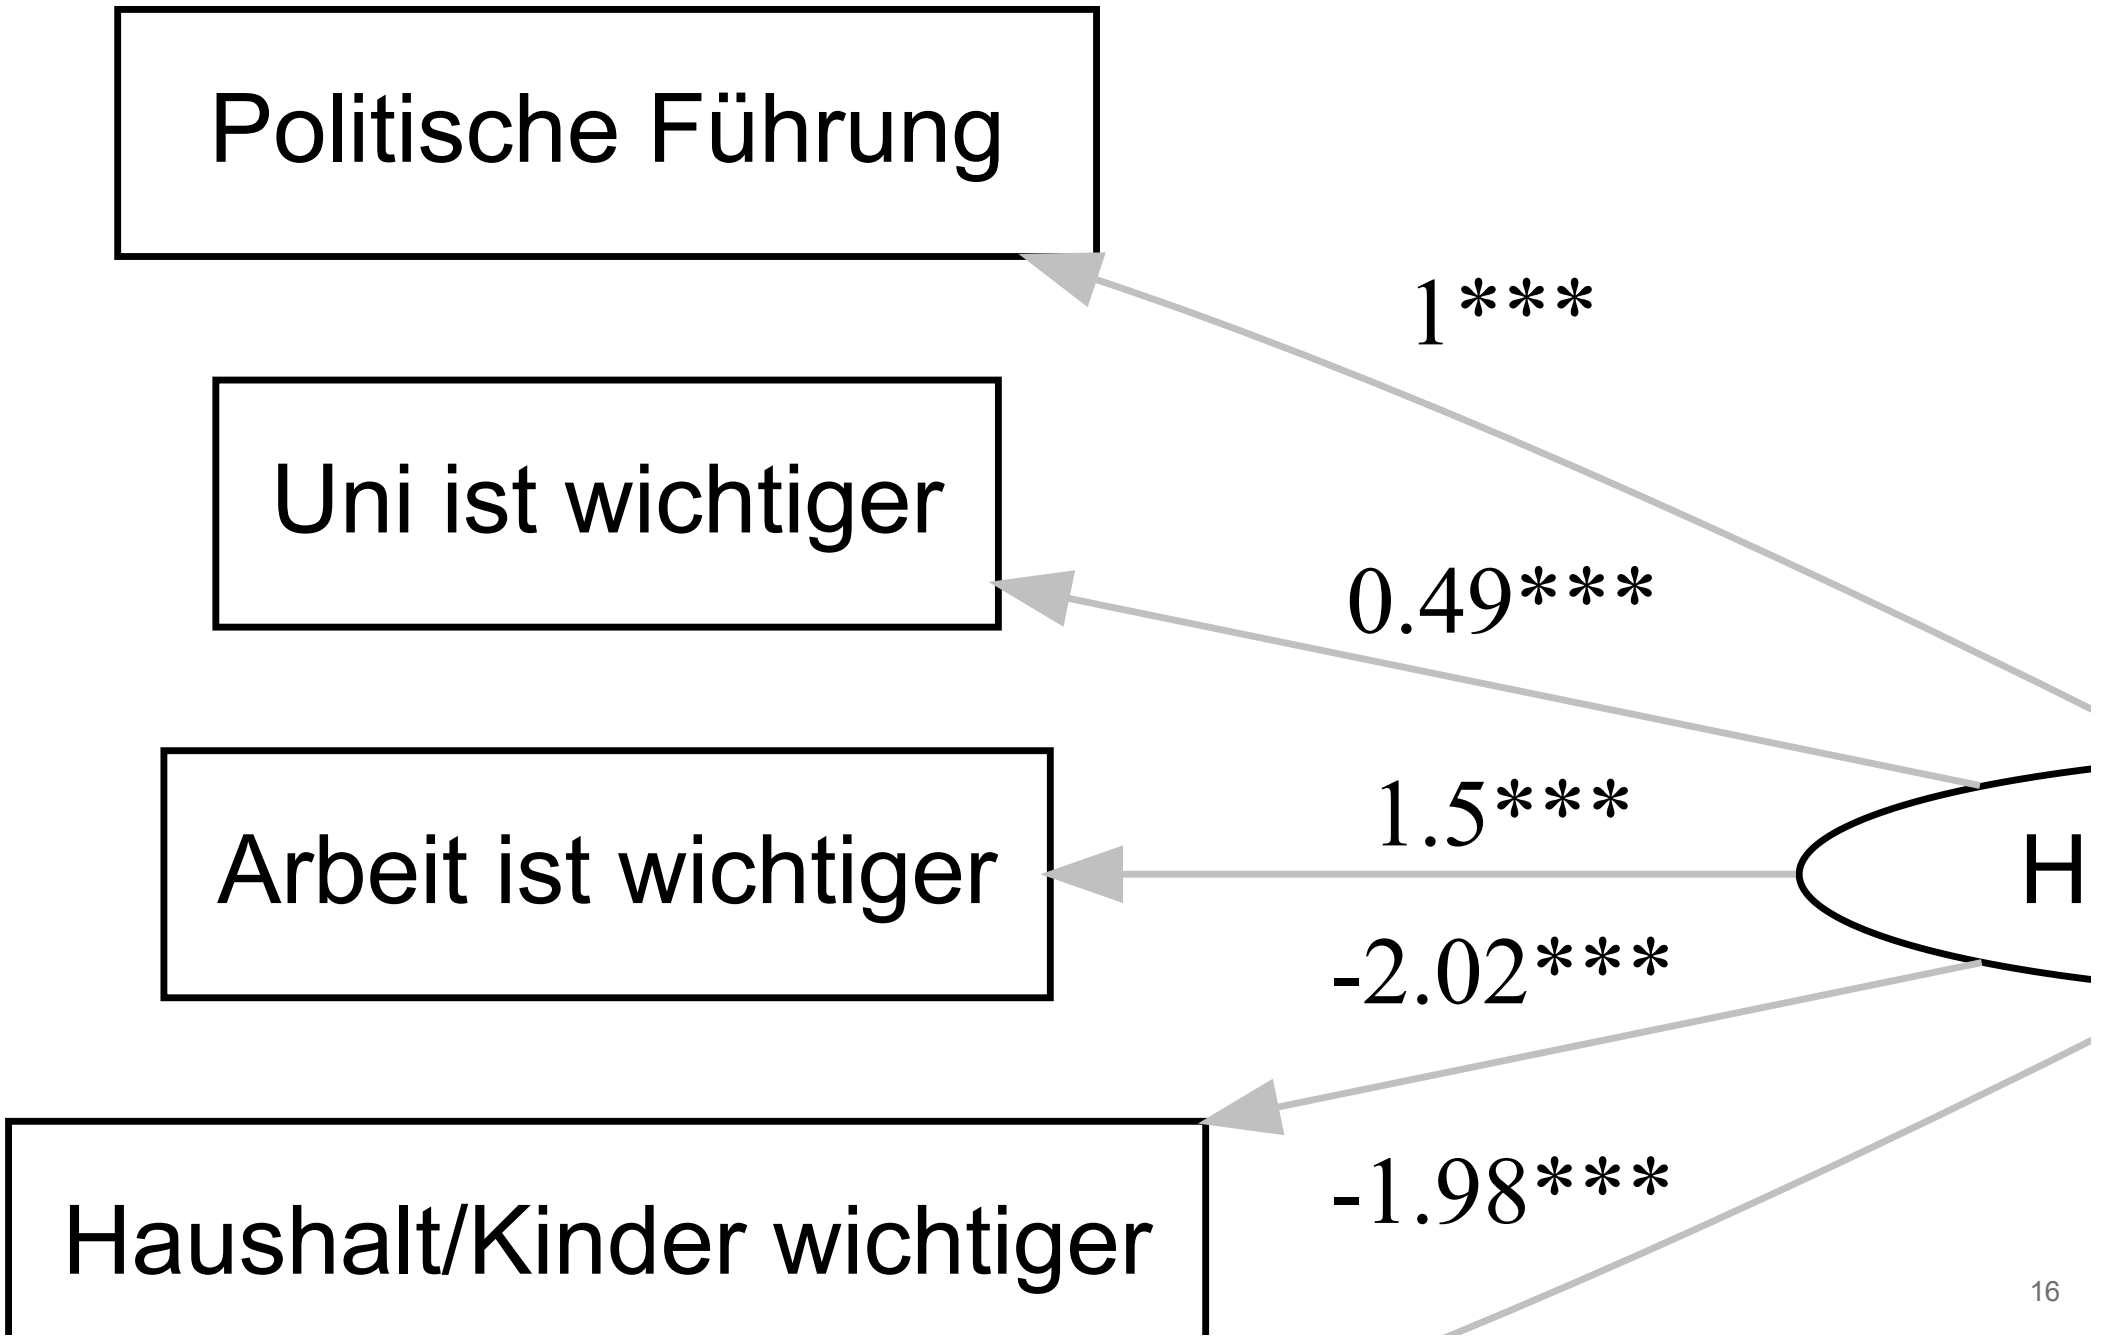

Politische_Fuehrung
Uni_wichtiger
Arbeit_wichtiger
Haushalt_Kinder_wichtiger
Besser_Kinderbetreuung
r = 0.15
r = 0.20
r = -0.16
r = -0.14
r = 0.19
r = -0.08
r = -0.04
r = -0.36
r = -0.25
r = 0.39

Wie geht das (Intuition)?

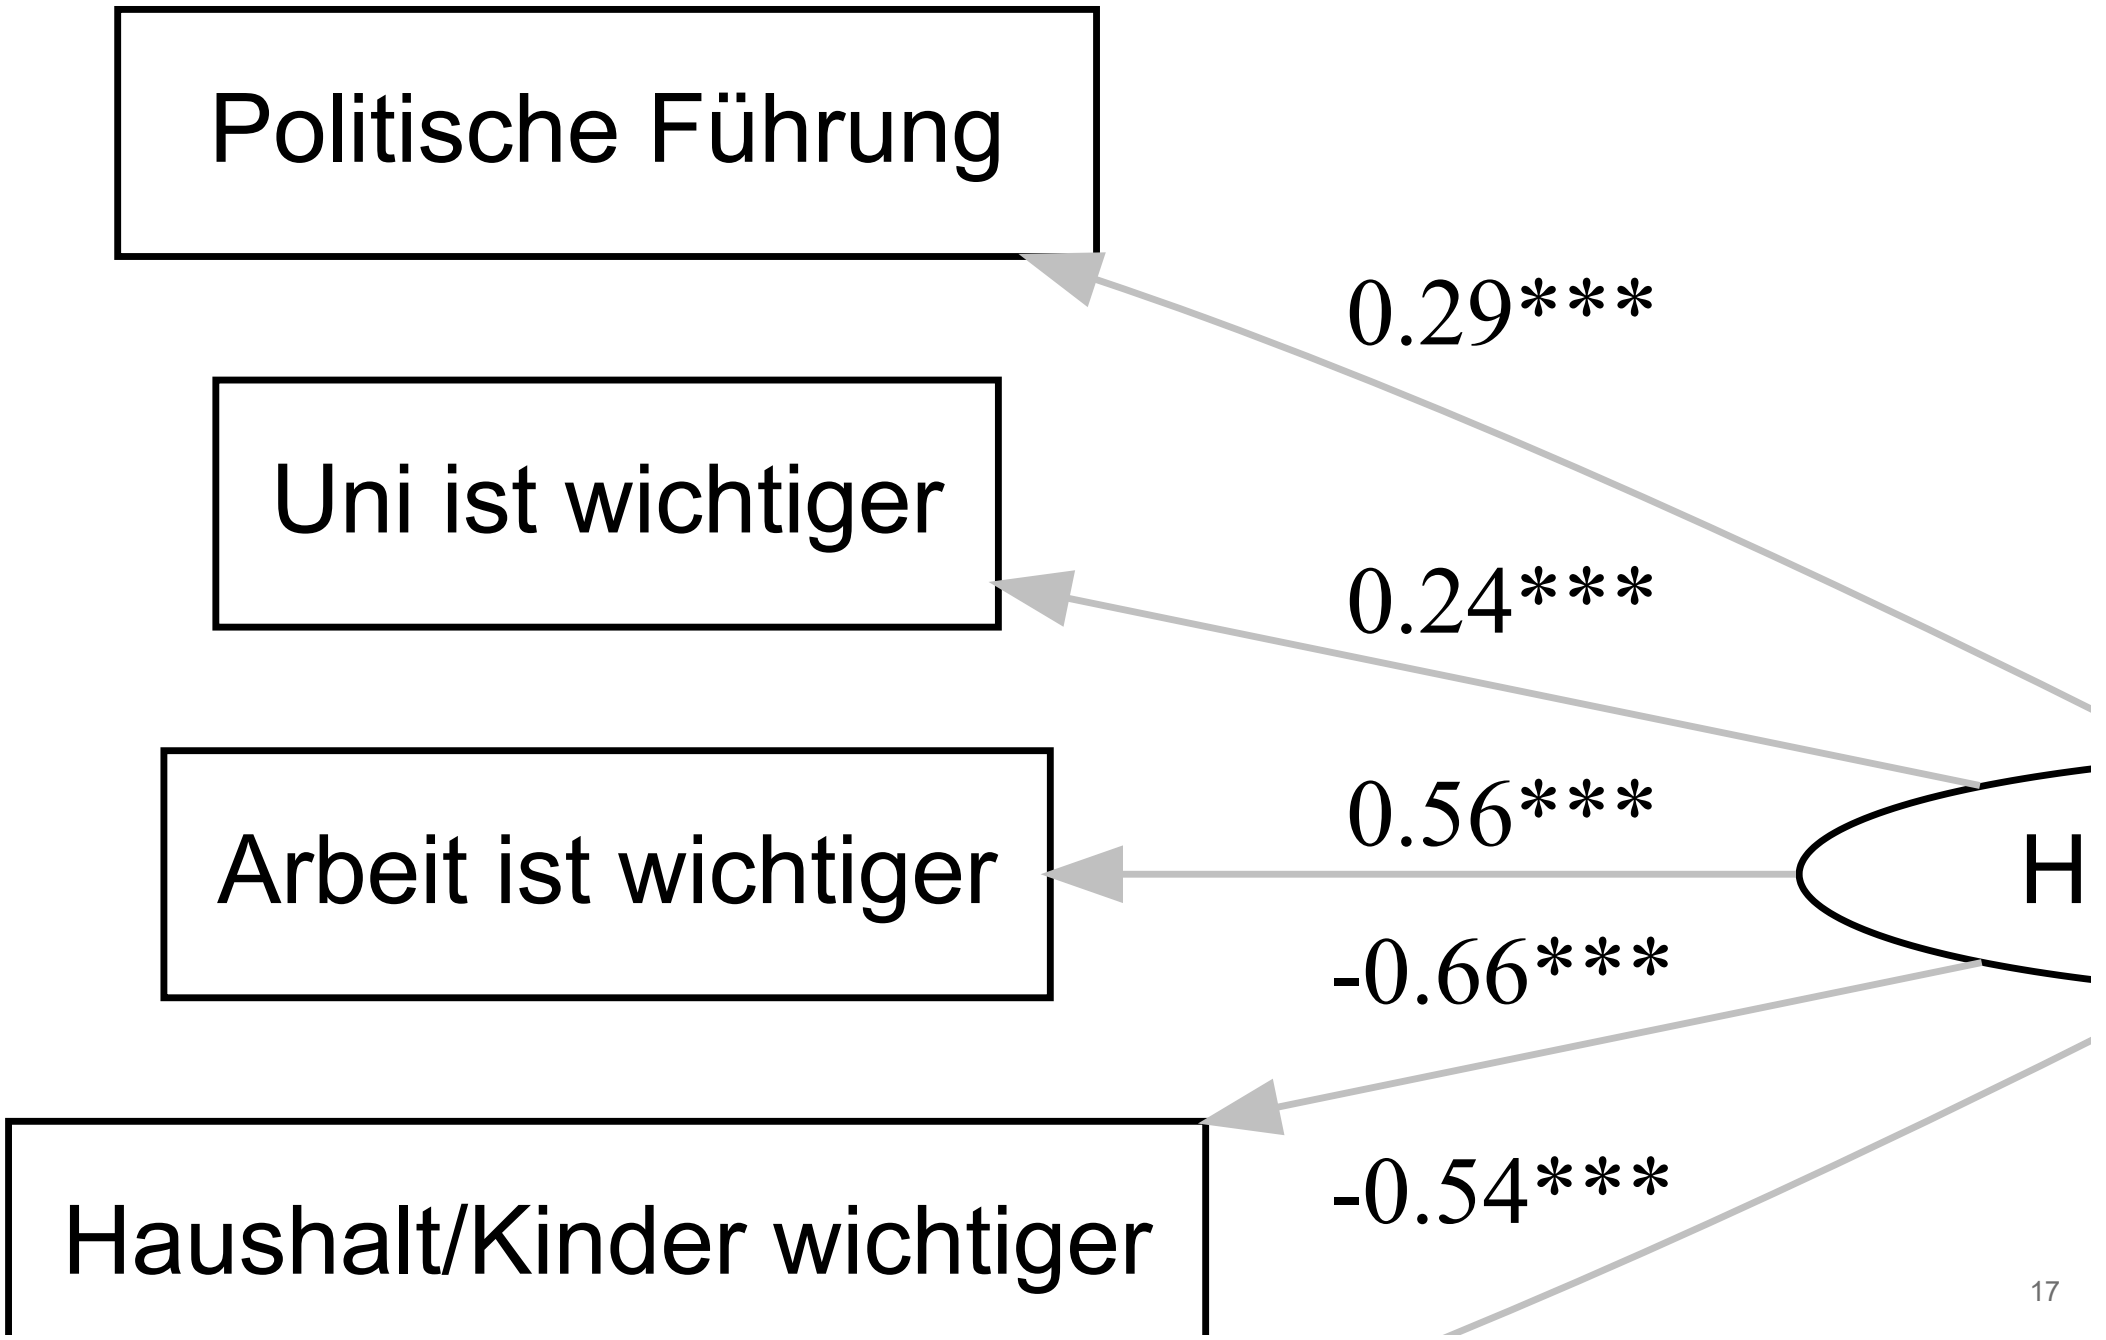
- Alle latenten Faktoren erhalten den Mittelwert von 0 und (zunächst) eine Standarabweichung von 1.[1]
- Alle Beziehungen zwischen den latenten Faktoren und den Items werden auf 0 gesetzt - mit Ausnahme von einer, bei der die Beziehung auf “1” gefixt werden muss.
- Das ist eine Simulation des “Zufalls im Hintergrund”.
- Es wird nun solange mit Werten für $\lambda_{q_k} f_i \cdot \lambda_{q_l} f_i$ “itereriert”, bis eine “optimale Lösung” gefunden wird, die sich hinreichend vom Zufallsmodell unterscheidet.
- Diese Lösung kann theoretisch falsch sein.
- Diese Lösung kann empirisch nicht gut an die Daten angepasst sein. Sie ist lediglich die “optimale Lösung” für die Passung von einem Modell zu einem analytischen Sample.

1. Das ist eine ziemlich fragile Annahme über die Normalverteilung latenter Faktoren. Die muss man nicht treffen, aber dadurch wird es erst einmal leichter.

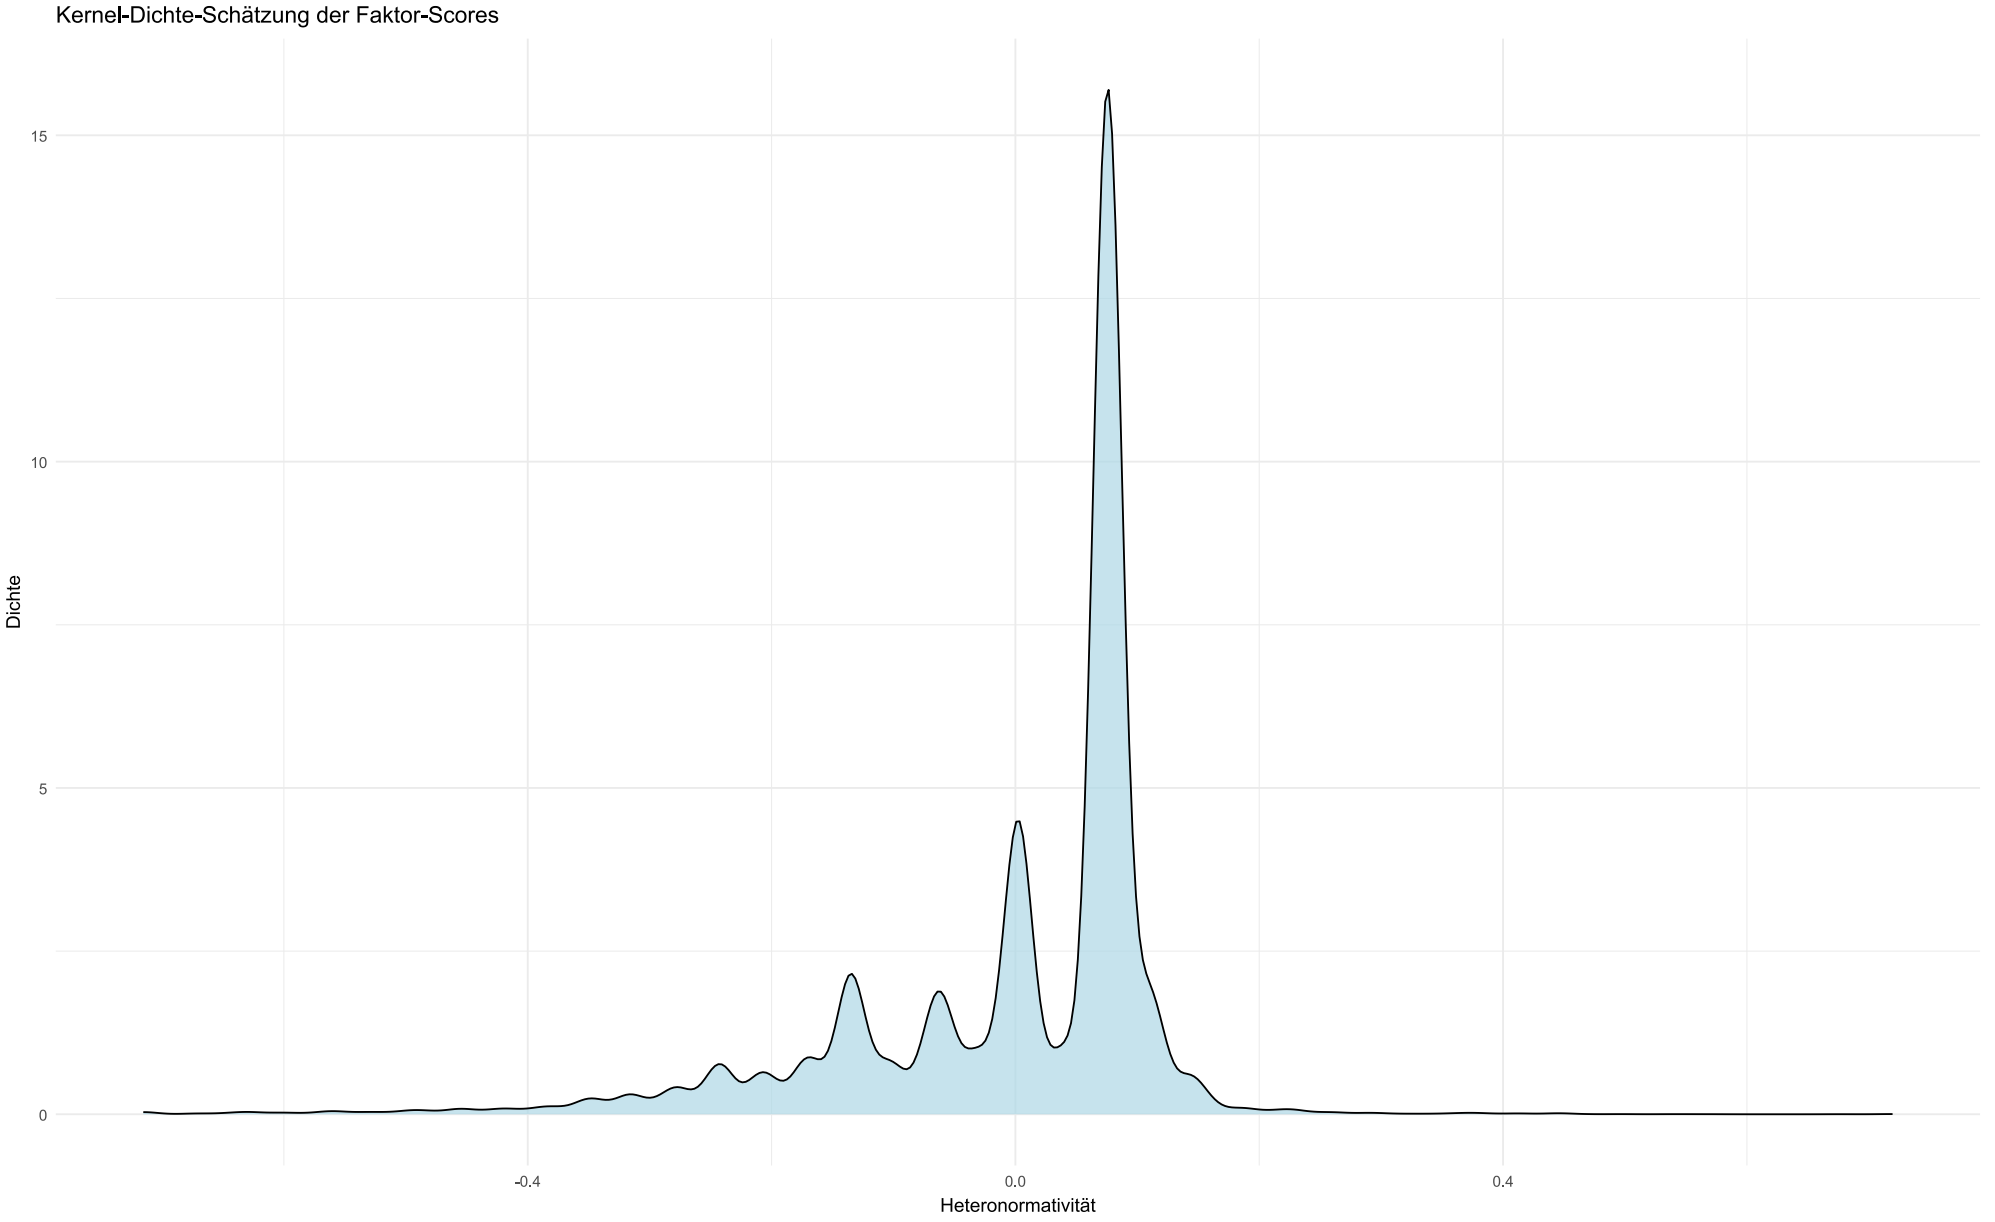
Unstandardisierte Faktorladungen


Politische Führung
Uni ist wichtiger
Arbeit ist wichtiger
Haushalt/Kinder wichtiger
1***
0.49***
1.5***
-2.02***
-1.98***
H

Standardisierte Faktorladungen

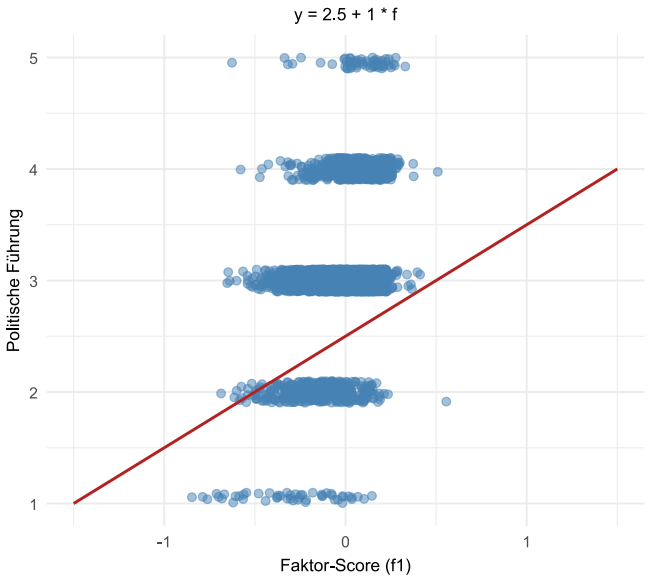

Politische Führung
Uni ist wichtiger
Arbeit ist wichtiger
Haushalt/Kinder wichtiger
0.29***
0.24***
0.56***
-0.66***
-0.54***
H

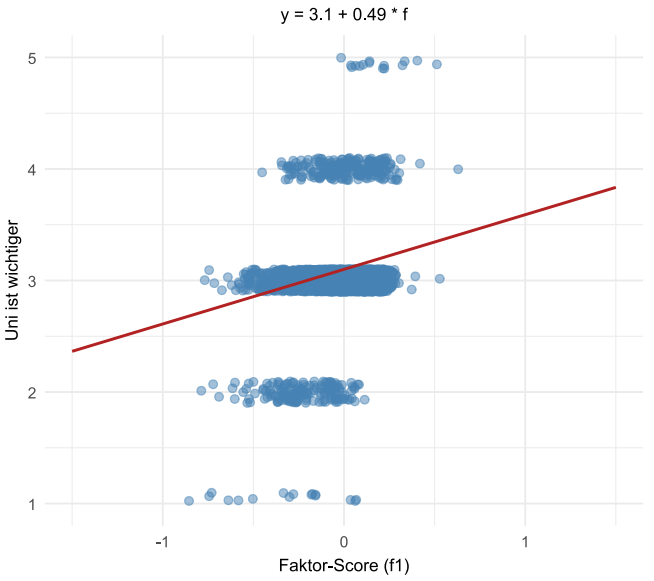
Was ist da passiert?

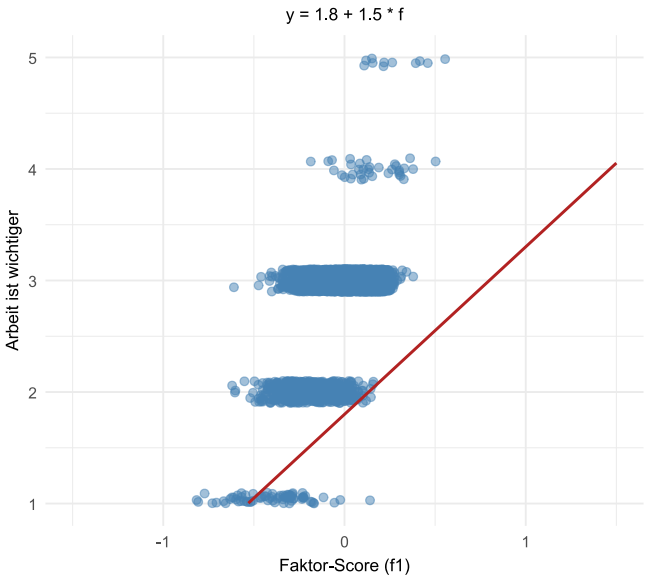

Kernel-Dichte-Schätzung der Faktor-Scores
15
10
5
0
Dichte
-0.4
0.0
0.4
Heteronormativität

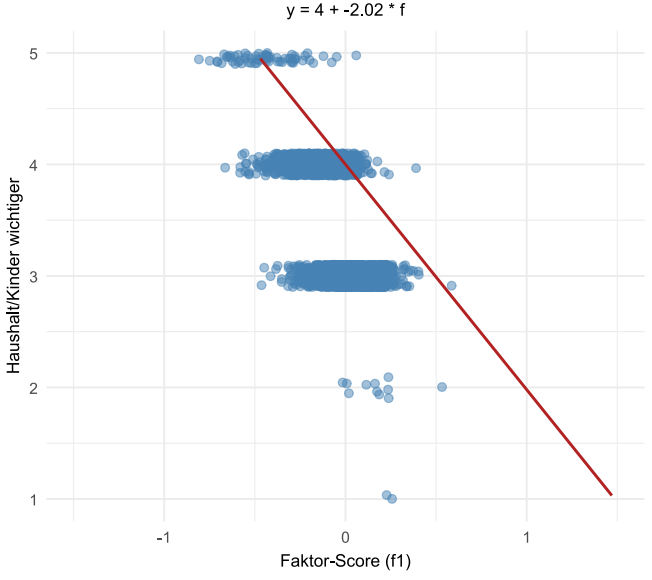
Was sind Faktorladungen?

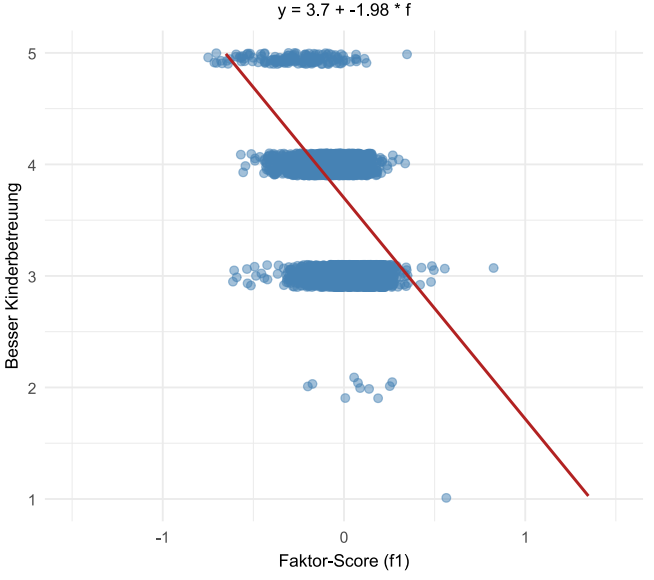
CFA Indikator-Plots (20% Stichprobe)











Was ist da passiert?

Parameter der Faktor-Analyse

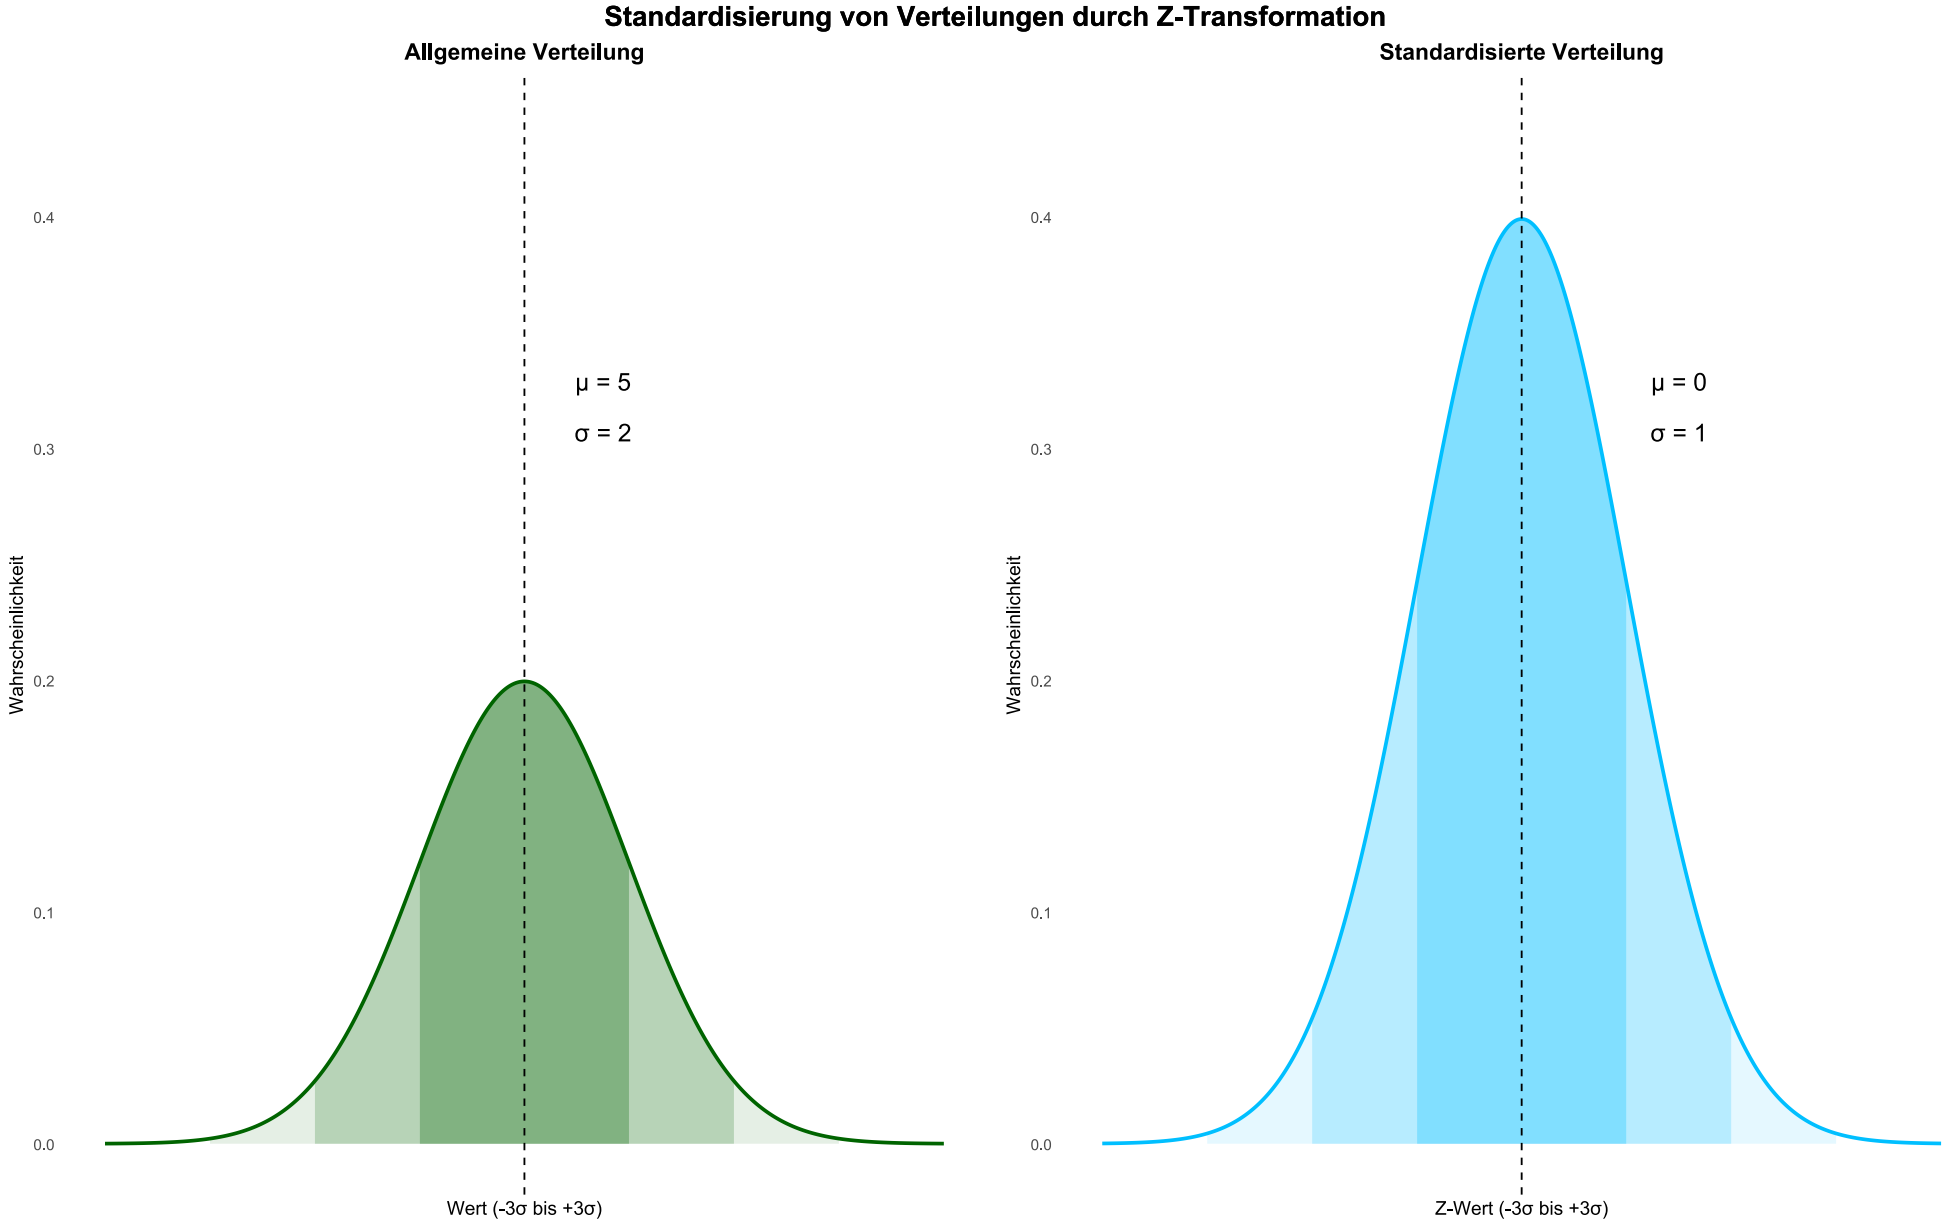
	Variable	Unstd_Loadings	Std_Loadings	Std_Part_Loadings	Commu
val10i1	Politische Führung	1.000	0.292	0.161	
val10i2	Uni ist wichtiger	0.490	0.236	0.079	
val10i3	Arbeit ist wichtiger	1.502	0.557	0.241	
val10i4	Haushalt/Kinder wichtiger	-2.020	-0.659	-0.324	
val10i5	Besser Kinderbetreuung	-1.982	-0.537	-0.318	

Interpretation der Parameter einer Faktorenanalyse

Parameter	Interpretation
Faktorladung *unstandardisiert*	Mit jedem Schritt um **eine Einheit** des latenten Faktors, ändert sich die Reaktion auf das Item um β
Faktorladung *teil-standardisiert*	Mit jedem Schritt um **eine Standardabweichung** des latenten Faktors, ändert sich die Reaktion auf das Item um β.
Faktorladung *standardisiert*	Mit jedem Schritt um **eine Standardabweichung** des latenten Faktors,

Parameter	Interpretation
	ändert sich die Reaktion auf das Item um β Standardabweichungen.
Uniqueness	Teil der Varianz des Items, das **nicht** auf den latenten Faktor zurückgeführt werden kann.
Communality	Teil der Varianz des Items, dass **auf** den latenten Faktor zurückgeführt werden kann.

Mini-Exkurs: Standardisierung


Standardisierung von Verteilungen durch Z-Transformation
Allgemeine Verteilung
Standardisierte Verteilung
μ = 5
σ = 2
μ = 0
σ = 1
Wahrscheinlichkeit
Wahrscheinlichkeit
0.4
0.3
0.2
0.1
0.0
0.4
0.3
0.2
0.1
0.0
Wert (-3σ bis +3σ)
Z-Wert (-3σ bis +3σ)

Mini-Exkurs: Standardisierung

- Manchmal ist es sinnvoll, Ergebnisse von Modellen zu standardisieren, damit man Einflüsse besser vergleichen kann.[1]
- Standardisierung erfolgt entweder über z-transformierte Variablen, die in einer Regression genutzt werden mit

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

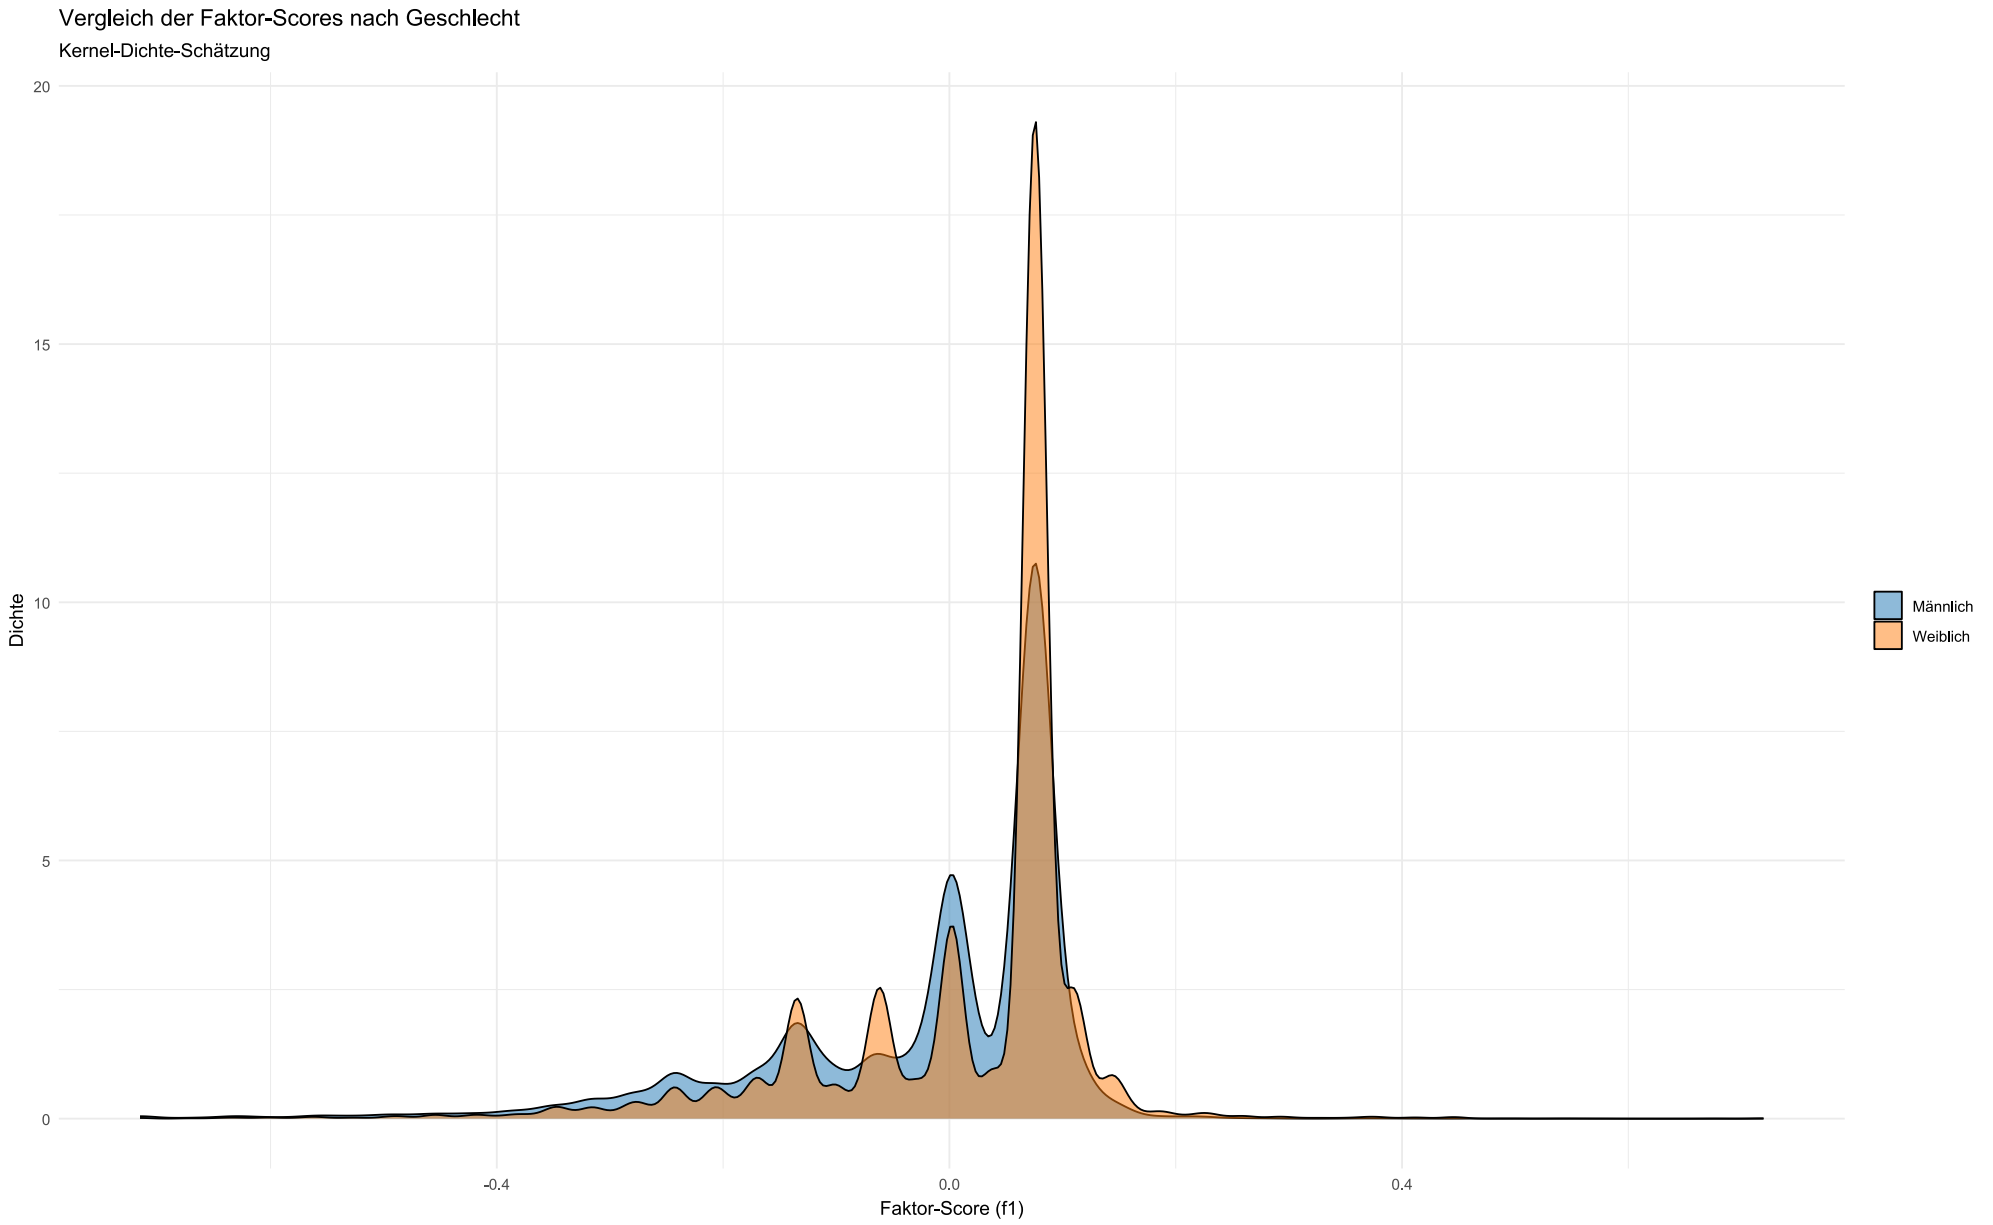
- oder über die (erneute) Multiplikation des $\hat{\beta}$-Koeffizienten mit $\frac{s_x}{s_y}$

1. $\hat{\beta}$-Koeffizienten sind abhängig von der zugrunde liegenden Einheit. Sie können damit $\hat{\beta}$-Koeffizienten beliebig groß/klein machen in der Kommunikation, wenn Sie z.B. Einkommen in Tausender- oder in Ein-Euro-Schritten in einer Regression nutzen.

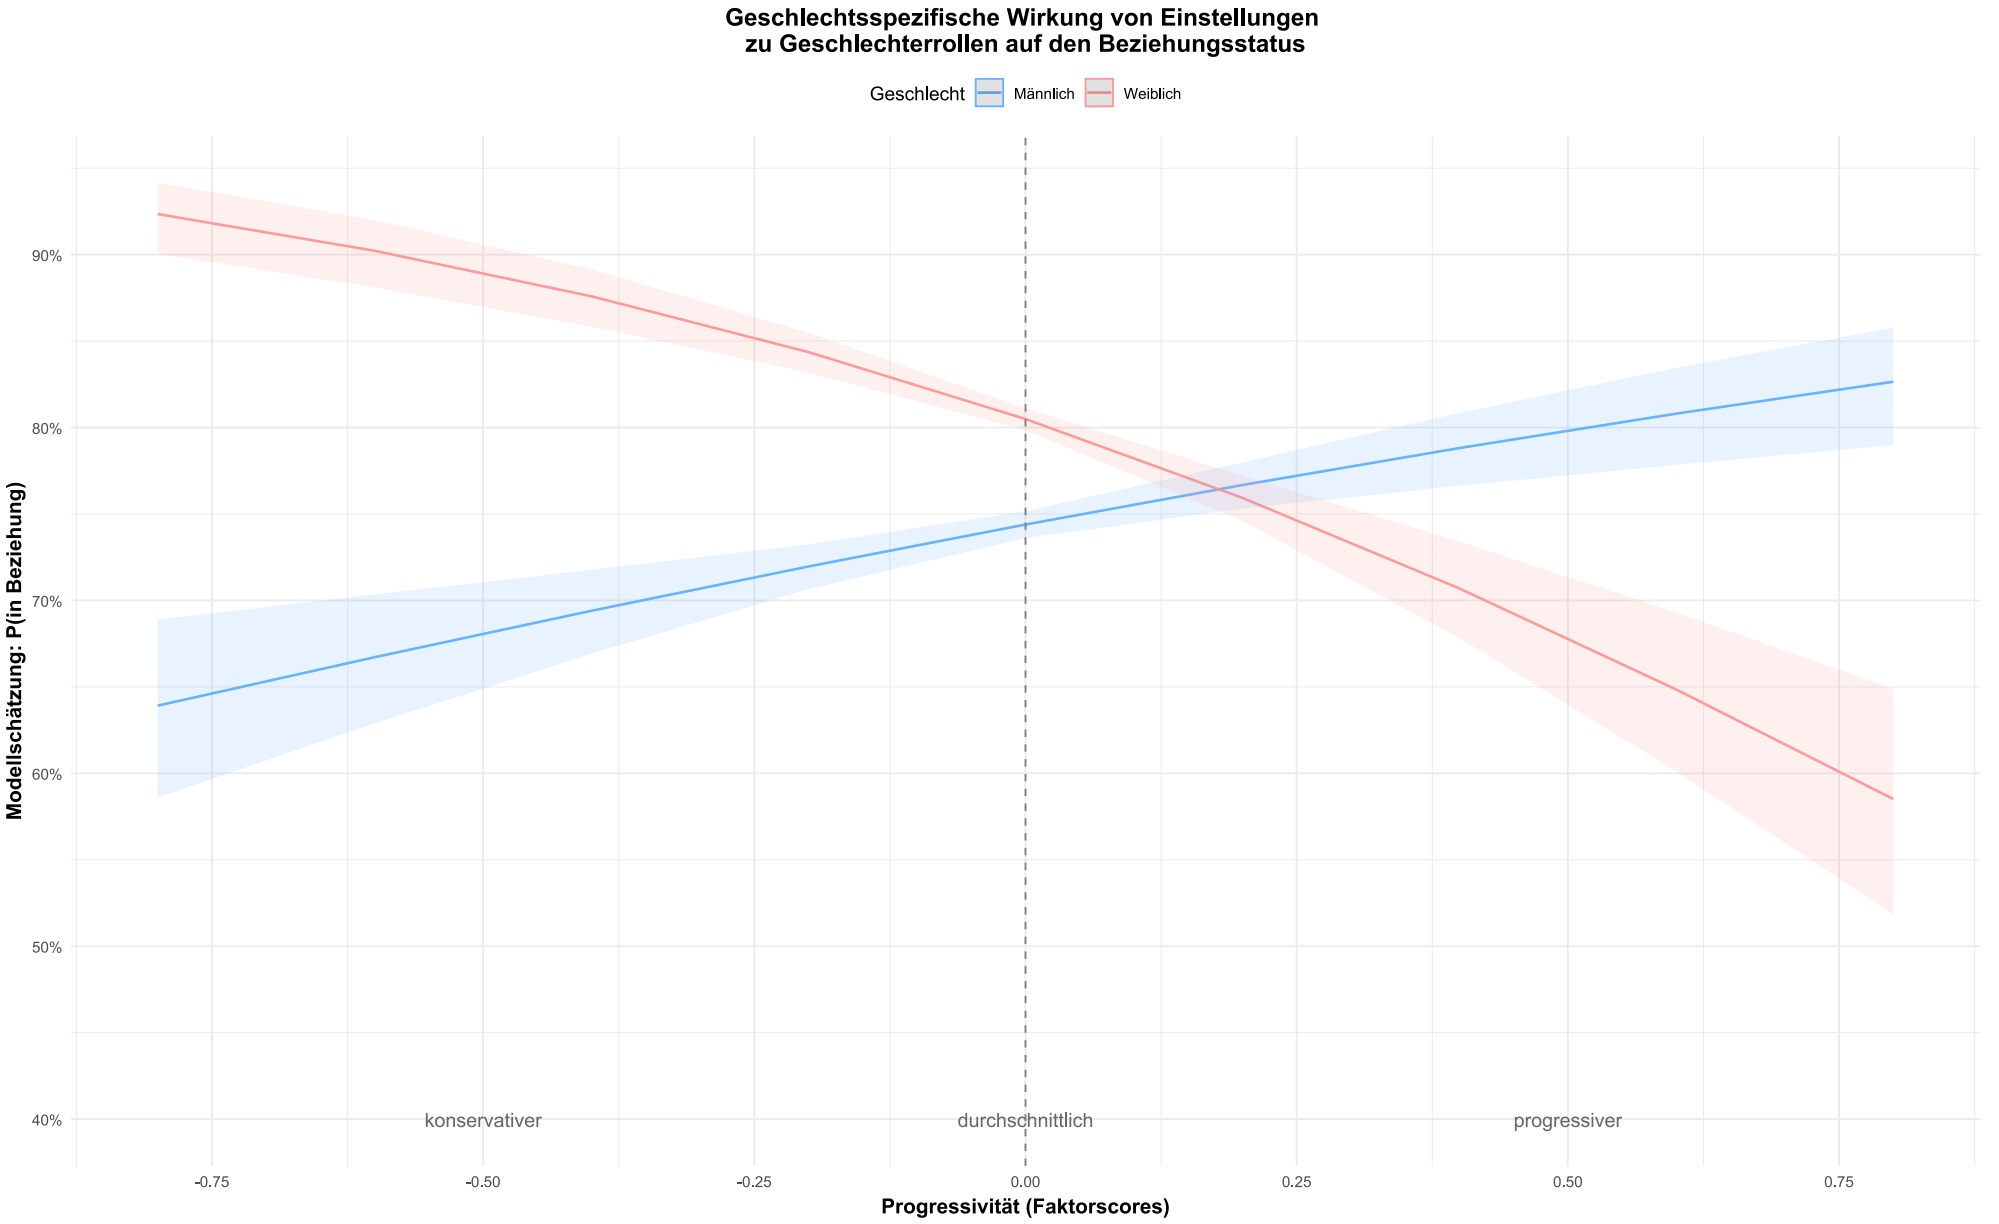
Mini-Exkurs: Standardisierung

- Werden nur die x-Variablen z-transformiert, spricht man von Teil-Standardisierung.
  - $\rightarrow$ Mit jeder Standardabweichung von X steigt Y durchschnittlich um $\hat{\beta}$ **Einheiten**.
- Werden sowowhl die Y-Variable als auch die X-Variable standardisiert, spricht man von Standardisierung.
  - $\rightarrow$ Mit jeder Standardabweichung von X steigt Y durchschnittlich um $\hat{\beta}$ **Standardabweichungen**.

Sind Männer konservativer in Bezug auf Geschlechterrollen?


Vergleich der Faktor-Scores nach Geschlecht
Kernel-Dichte-Schätzung
Dichte
20
15
10
5
0
-0.4
0.0
0.4
Faktor-Score (f1)
Männlich
Weiblich

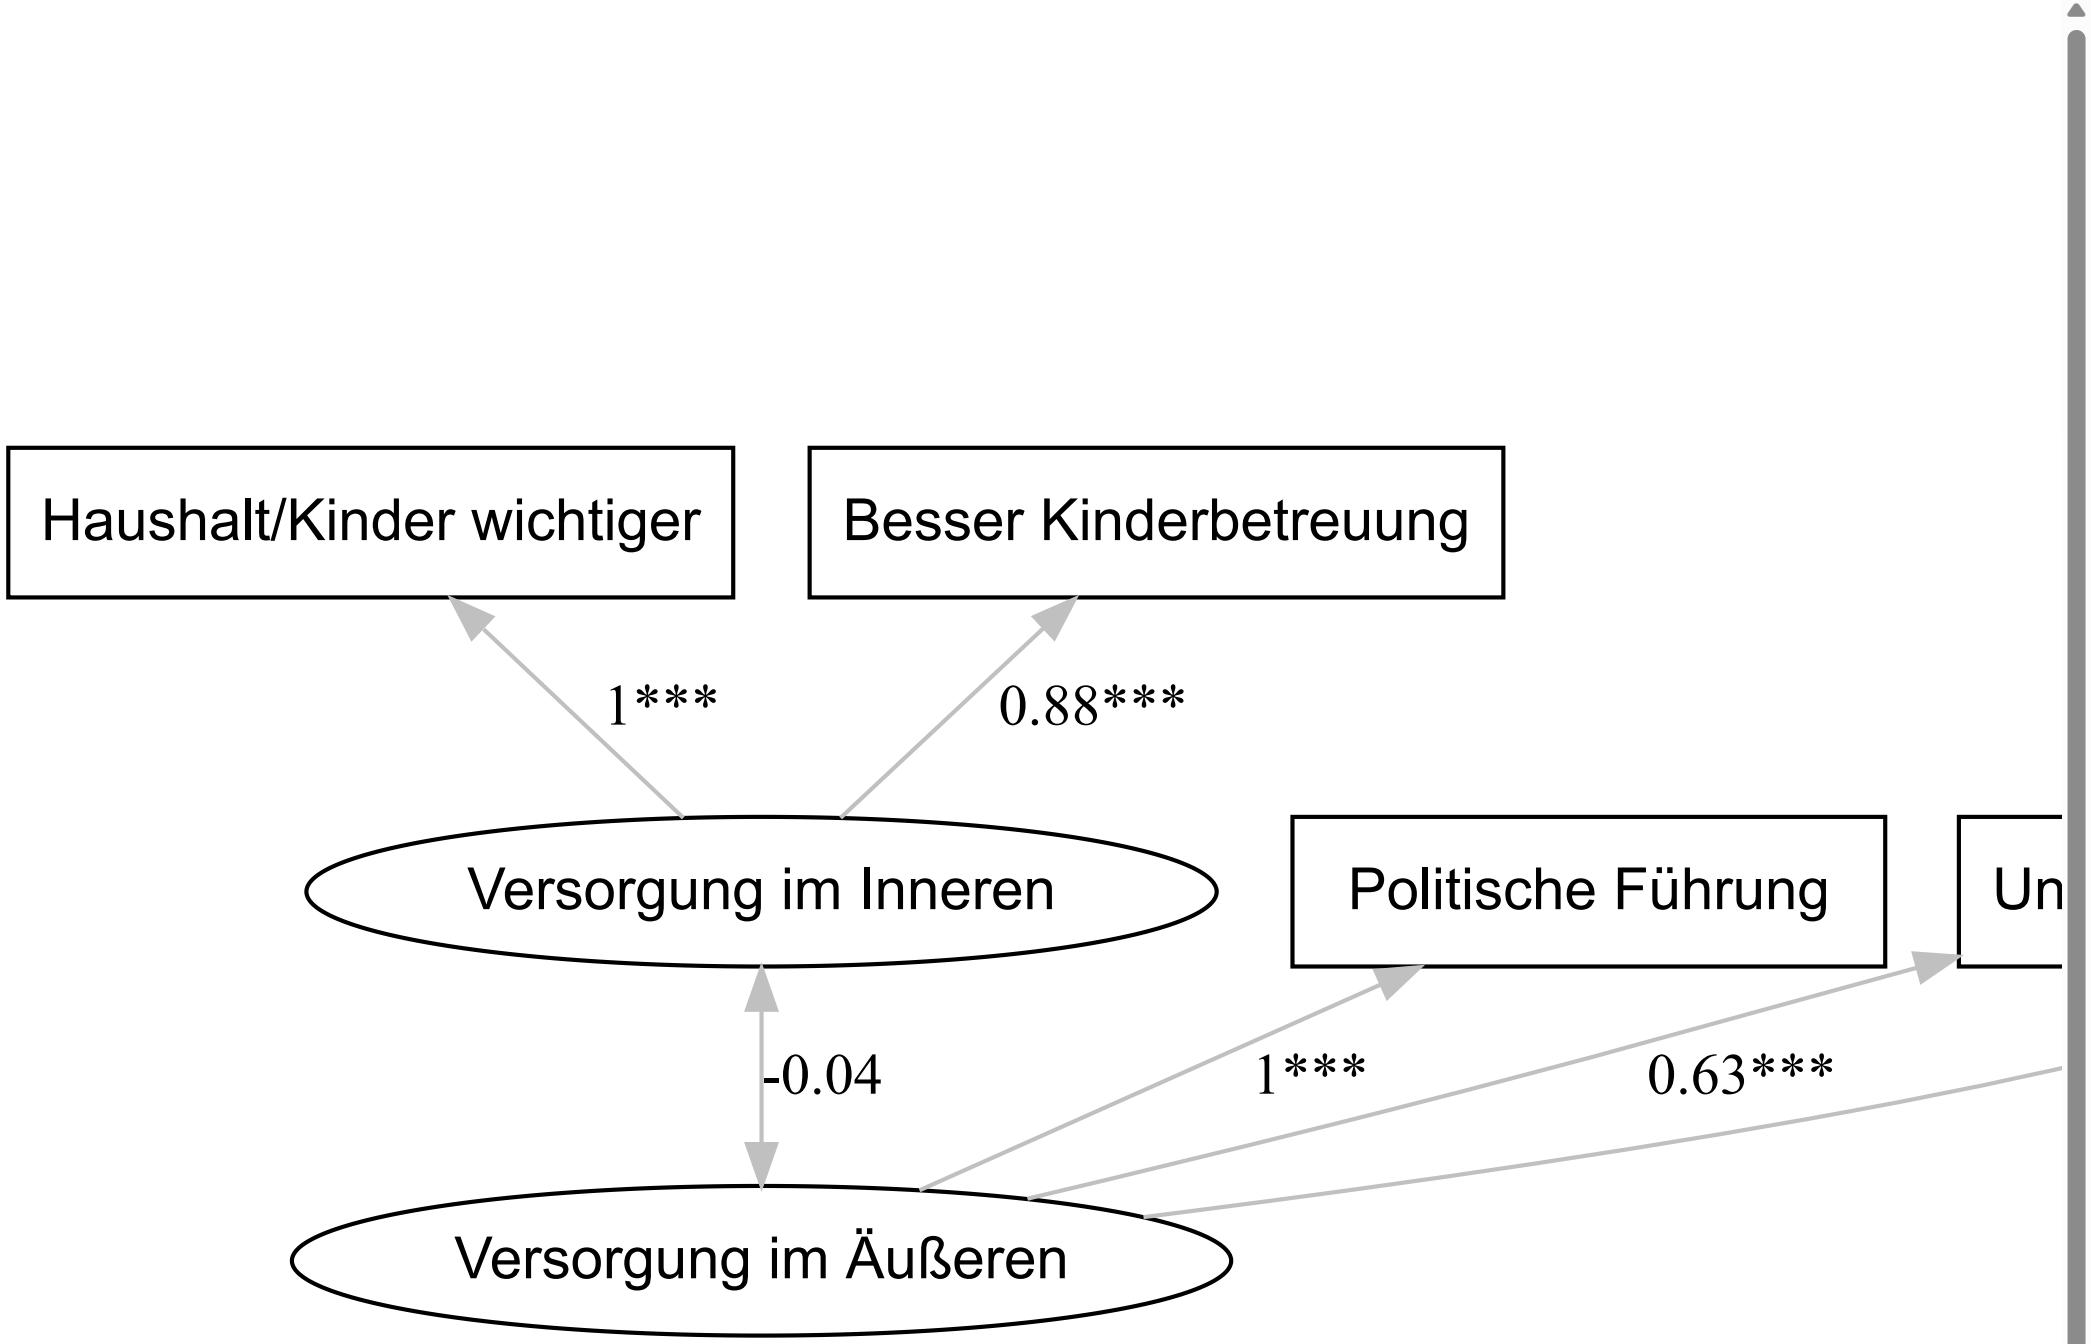
Geschlecht, Geschlechterrolleneinstellungen und Beziehungsstatus


Geschlechtsspezifische Wirkung von Einstellungen
zu Geschlechterrollen auf den Beziehungsstatus
Geschlecht
Männlich
Weiblich
Modellschätzung: P(in Beziehung)
90%
80%
70%
60%
50%
40%
konservativer
durchschnittlich
progressiver
-0.75
-0.50
-0.25
0.00
0.25
0.50
0.75
Progressivität (Faktorscores)

Sind die Ergebnisse (datenanalytisch) sinnvoll?

- Die Ergebnisse von Faktoranalysen sind stets abhängig vom (theoretischen) Input.
- Grundsätzlich müssen Sie drei Fragen beantworten können:
  - Warum nutzen Sie eine bestimmte Anzahl von Faktoren (= Problem der *Dimensionalität*)?
  - Wenn Sie mehr als ein Faktor annehmen, sind diese verschiedenen Faktoren voneinander unabhängig oder nicht?
  - Sind die Fehler voneinander abhängig oder unabhängig?

Zwei Dimensionen



Zwei Dimenensionen

Vergleichen der Modellanpassung

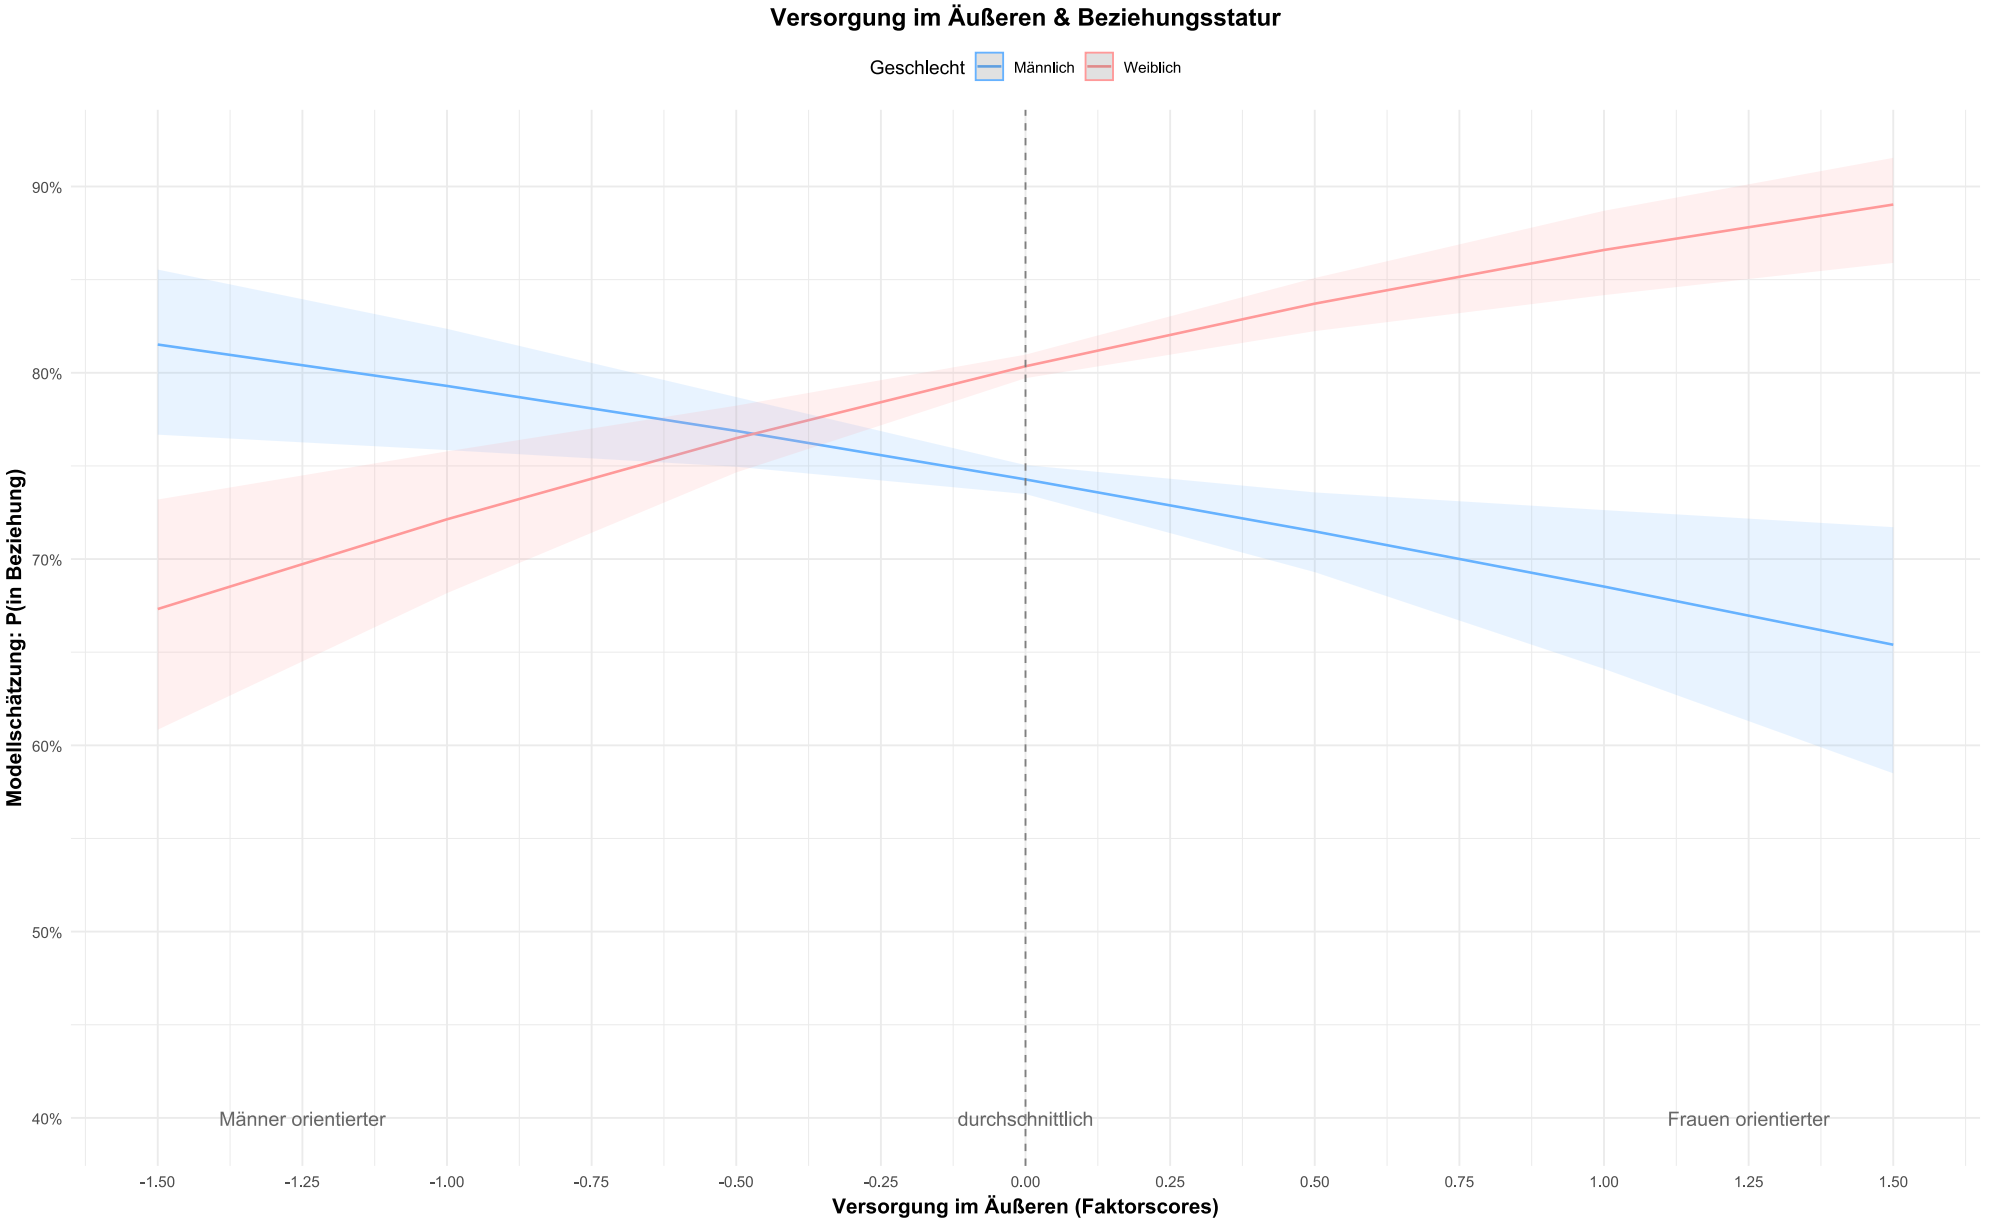
Vergleich der Modellanpassungen

	Df	AIC	BIC	Chisq	Chisq diff	RMSEA	Df diff	Pr(>Chisq)
fit2	4	189428.5	189520.1	406.41	NA	NA	NA	NA
fit	5	190450.2	190533.4	1430.09	1023.68	0.18	1	0

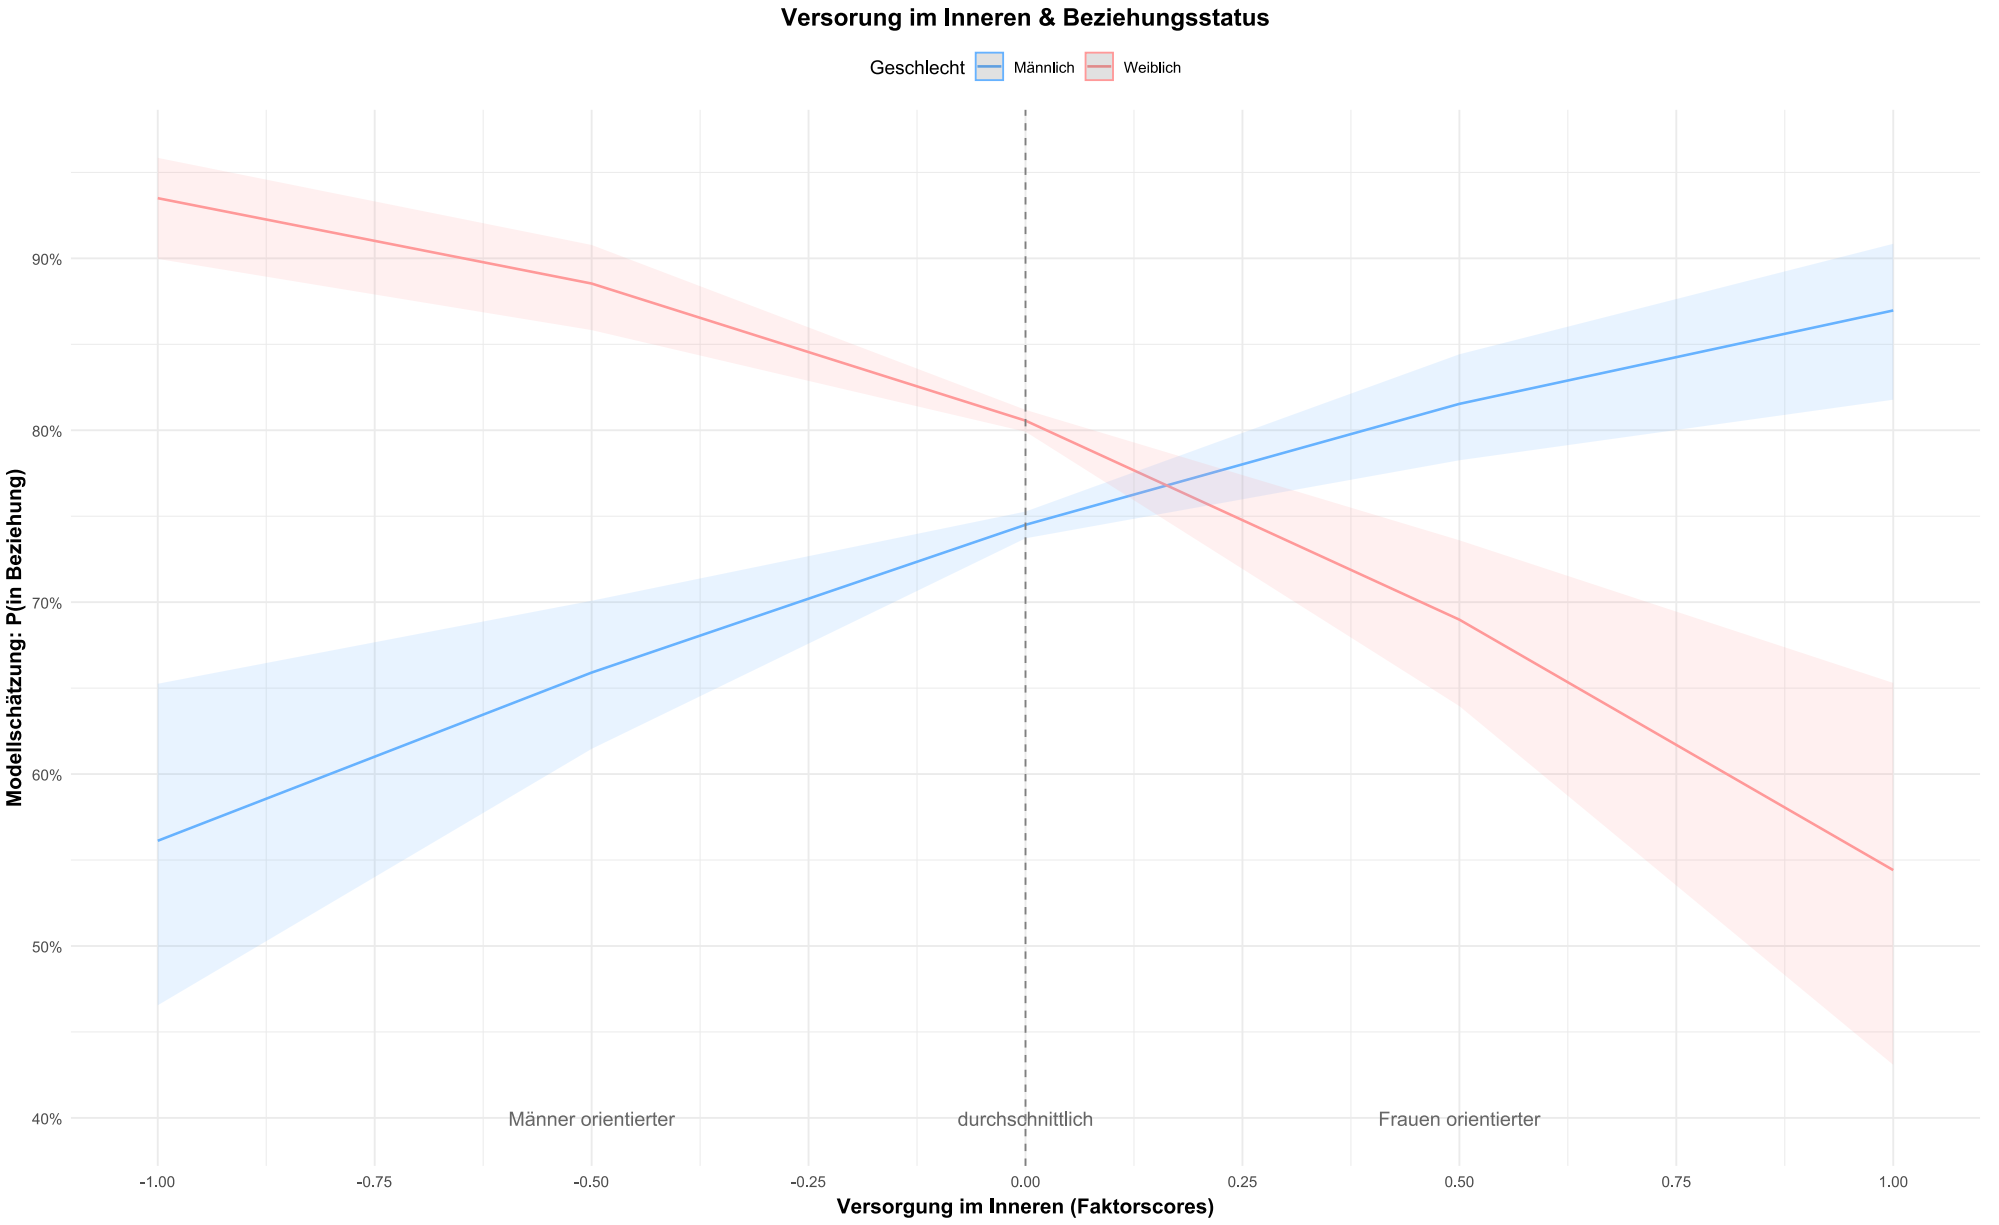
- Das Modell mit zwei Dimensionen ist den Daten deutlich besser angepasst:[1]
  - “AIC” & “BIC” sind “Informationskriterien”. Es gilt: Je kleiner der Wert, desto besser geht das Modell mit den zur Verfügung stehenden Informationen um.
  - Die χ^2 - Werte und RMSEA zeigen, dass das Modell mit zwei Dimensionen eine deutlich geringere Residualvarianz hat.

1. Achtung! Das hier setzt Dinge voraus, die wir noch besprechen müssen.

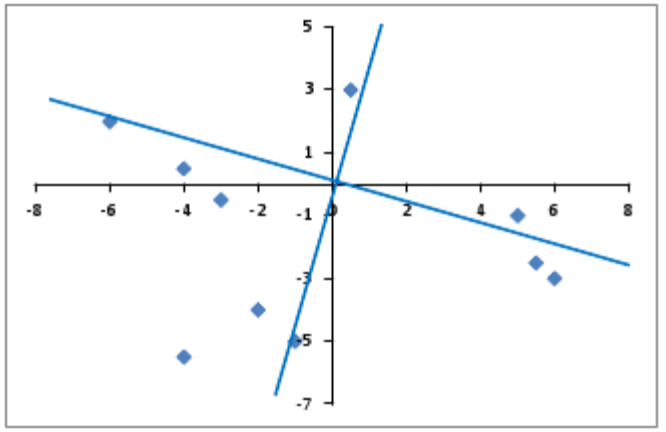
Werden wir dadurch schlauer?


Versorgung im Äußeren & Beziehungsstatur
Geschlecht
Männlich
Weiblich
90%
80%
70%
60%
50%
40%
Modellschätzung: P(in Beziehung)
Männer orientierter
durchschnittlich
Frauen orientierter
-1.50
-1.25
-1.00
-0.75
-0.50
-0.25
0.00
0.25
0.50
0.75
1.00
1.25
1.50
Versorgung im Äußeren (Faktorscores)

Werden wir dadurch schlauer?


Versorung im Inneren & Beziehungsstatus
Geschlecht
Männlich
Weiblich
90%
80%
70%
60%
50%
40%
Modellschätzung: P(in Beziehung)
Männer orientierter
durchschnittlich
Frauen orientierter
-1.00
-0.75
-0.50
-0.25
0.00
0.25
0.50
0.75
1.00
Versorgung im Inneren (Faktorscores)

Unkorrelierte Faktoren



Orthogonale Rotation von zwei Faktoren

- Die Altvorderen haben erzwungen, dass die latenten Faktoren miteinander unkorreliert sind.
- Sie dachten, dass das die Interpretation von einzelnen Faktoren “einfacher” macht.
- Wir (ja, auch Sie!) wollen aber nicht einfach, wir wollen empirisch adäquat.
- Deswegen machen wir das jetzt nicht mehr.