Inferenzstatistik - Teil 1

Ein Kessel Buntes

- Wie viel Blut müssen Sie jemandem abnehmen, um mit Sicherheit seine Blutgruppe zu bestimmen?
- Wie viele Nudeln müssen Sie aus einem Topf mit kochenden Nudeln probieren, um einzuschätzen, ob die Nudeln gar sind?
- Wie viele Paare müssen Sie befragen, um sicher zu wissen, wie groß die Unterschiede in der häuslichen Arbeitsteilung sind?

  Woher kommt der Unterschied der Antworten auf die ersten zwei Fragen zur dritten?

Unsicherheit, Informationen und Stichproben

Die Unsicherheit der Schätzung eines Merkmals hängt im Wesentlichen von zwei Fragen ab:

1. Wie unterschiedlich ist die Verteilung dieses Merkmals?
2. Wie oft wurde das Merkmal beobachtet?

Hat das Merkmal *keine* Varianz (wie die Blutgruppe eines Menschen) genügt prinzipiell *eine* Beobachtung zur Bestimmung des Merkmals. Je unterschiedlicher das Merkmal ist, desto mehr Beobachtungen werden benötigt, um die Unsicherheit des Schlusses von einer Stichprobenverteilung auf die Verteilung in der Grundgesamtheit zu verringern.
Wir haben daher immer folgende Relation:

$$\text{Unsicherheit des Parameters durch Sampling} = \frac{\text{Variabilität des Parameters}}{\text{Stichprobengröße}}$$

Über was sind wir (durch Stichproben) unsicher?

Bitte prägen Sie sich folgende Annahmen[1] für die kommenden Argumentationen & Interpretationen ein:

1. Werte, Zusammenhänge, Unterschiede (=Parameter) **in der Population** sind fix. D.h. sie haben keine Wahrscheinlichkeit, sie sind zu einem definierten Zeitpunkt nicht veränderlich.
2. Parameter in einer **Stichprobe** sind **auch** das Resultat von Zufallsschwankungen. Diese Zufallsschwankungen betreffen die Wahrscheinlichkeit, Werte aus der Population auch in der Stichprobe zu finden.
3. Alles, was wir berechnen können (Mittelwerte, Varianzen, Regressionskoeffizienten ...)

1. Für die Expert:innen: Diese Annahmen und die daraus entstehenden Konsequenzen unterscheiden im Wesentlichen frequentistische von bayesianischer Statistik. Wir machen hier ersteres, d.h. die hier getroffenen Annahmen sind zentrale frequentistische Annahmen.

Ausdruck von Unsicherheit 1: Konfidenzintervalle

Wir formulieren Erwartungen über Werte von **zukünftigen** Stichproben.

1. Wenn wir viele, weitere Stichproben aus *der selben* Population ziehen *und* sich die Stichproben nur *zufällig* unterscheiden würden, was für eine *Streuung* von Ergebnissen können wir dann erwarten?
   $\rightarrow$ Das ist ein Gedankenexperiment!
2. Da die Ergebnisse durch zufällig varrierende Stichproben aus der gleichen Population berechnet wurden, können wir die Zufallsstreuung aus den Ergebnissen herausrechnen. Das gibt uns eine sehr gute Annäherung an den uns unbekannten Populationsparameter.
   $\rightarrow$ Das funktioniert aber nur, wenn *keine* Selektionen im Sampling, ins Treatment oder Fehler in der Modellierung sind.

Ausdruck von Unsicherheit 2: Signifikanz

Wir möchten wissen, mit welcher Wahrscheinlichkeit wir eine/n Differenz/Zusammenhang in der Stichprobe nur durch Zufall sehen *könnten*.

1. Dazu treffen wir Annahmen, wie die Daten verteilt sein müssten, wenn es keine Differenz oder keinen Zusammenhang geben würde.
2. Auch in diesem Fall varrieren Ergebnisse von vielen Stichproben *zufällig*. Manchmal könnte es aus reinem Zufall zu gehäuftem Auftreten von Wertepaaren kommen, was dann zu zufälligen Zusammenhängen oder Differenzen führt, die es in der Population nicht gibt.
3. Die Daten, mit denen wir arbeiten, könnten eine solche Stichprobe sein. Unter der Annahme, dass dies der Fall ist, können wir alle Ergebnisse, die wir mit der Stichprobe berechnen, als Zufallsereignis ansehen. Die Auftretenswahrscheinlichkeit von solchen (oder extremeren) Zufallsereignissen lässt sich gut berechnen.

4. Ist diese Wahrscheinlichkeit sehr klein, sagen wir **per Konvention**, dass unsere Ergebnisse nicht durch Zufall entstanden sind.

Woher kommen Schwankungen von Parametern in Stichproben?

Sie wissen, dass der Erwartungswert die Summe der Produkte von Werten mit ihrer Auftretenswahrscheinlichkeit ist:

$$E[Y] = \underbrace{\sum y_i}_{\substack{\text{Werte der} \\ \text{Eigenschaft Y}}} \cdot \underbrace{P(y_i)}_{\substack{\text{Wahrscheinlichkeit des Wertes} \\ \text{in der Stichprobe}}}$$

- Eine reine Zufallsstichprobe ändert nichts an den Werten der Eigenschaft Y.
- Bei einer reinen Zufallsstichprobe haben auch alle Werte die gleiche Chance, Teil der Stichprobe zu werden, aber das ist letztlich eine Lotterie. Es wird fast immer so sein, dass eine Zufallsstichprobe in Bezug auf $P(y_i)$ Abweichungen von der Population aufweist.
- Dadurch enstehen **zufallsbedingte Abweichungen** der Stichprobenparameter in Bezug auf die Populationsparameter.

Zentraler Grenzwertsatz

Zentraler Grenzwertsatz: Wenn die Verteilung eines Merkmals/Unterschieds auf reinem Zufall beruht, dann verteilt sich dieses/r Merkmal/Unterschied nach einer Normalverteilung.
Wenn also der **Unterschied** eines Stichprobenparameters zum Popuplationsparameter auf einer **Zufallsschwankung** beruht, dann können wir annehmen, dass diese Parameter**unterschiede** normalverteilt sind.[1]
Da jede Normalverteilung durch z-Transformation zu einer Standardnormalverteilung umformbar ist, und wir über die Standardnormalverteilung definitorisches Wissen haben, haben wir auch volles Wissen über die Verteilung der zu analysierenden Verteilung.

.. Verwechseln Sie hier nicht den Fehler und behaupten, dass dadurch die Merkmale oder Parameter normalverteilt sein müssten.

Sind zufallsbedingte Abweichungen der Stichprobenparameter problematisch?

- Das kommt auf den Parameter an!
- Bei einigen Parametern, wie beim arithmetischen Mittel, sind diese Abweichungen unproblematisch. Diese Parameter werden *erwartungstreu* genannt.
- Andere Parameter sind nicht erwartungstreu. Ein Beispiel dafür ist die Varianz.

Korrektur der Varianz bei Stichproben

Die Stichproben-Varianz (s) ist *kein* erwartungstreuer Schätzer der Populationsvarianz σ^2 (sprich: sigma quadrat), sie ist *systematisch zu klein*! Sie muss daher mit dem Term $\frac{n}{n-1}$ nach oben korrigiert werden, was unsere Schätzung für die Populationsvarianz ($\hat{\sigma}^2$) sowie die Schätzung für die Populations-Standardabweichung ($\hat{\sigma}$) ergibt.

$$\begin{aligned}\hat{\sigma}^2 &= \frac{\sum(x_i - \bar{x})^2}{n} \cdot \frac{n}{n-1} \\ &= \frac{\sum(x_i - \bar{x})^2}{n-1}\end{aligned}$$

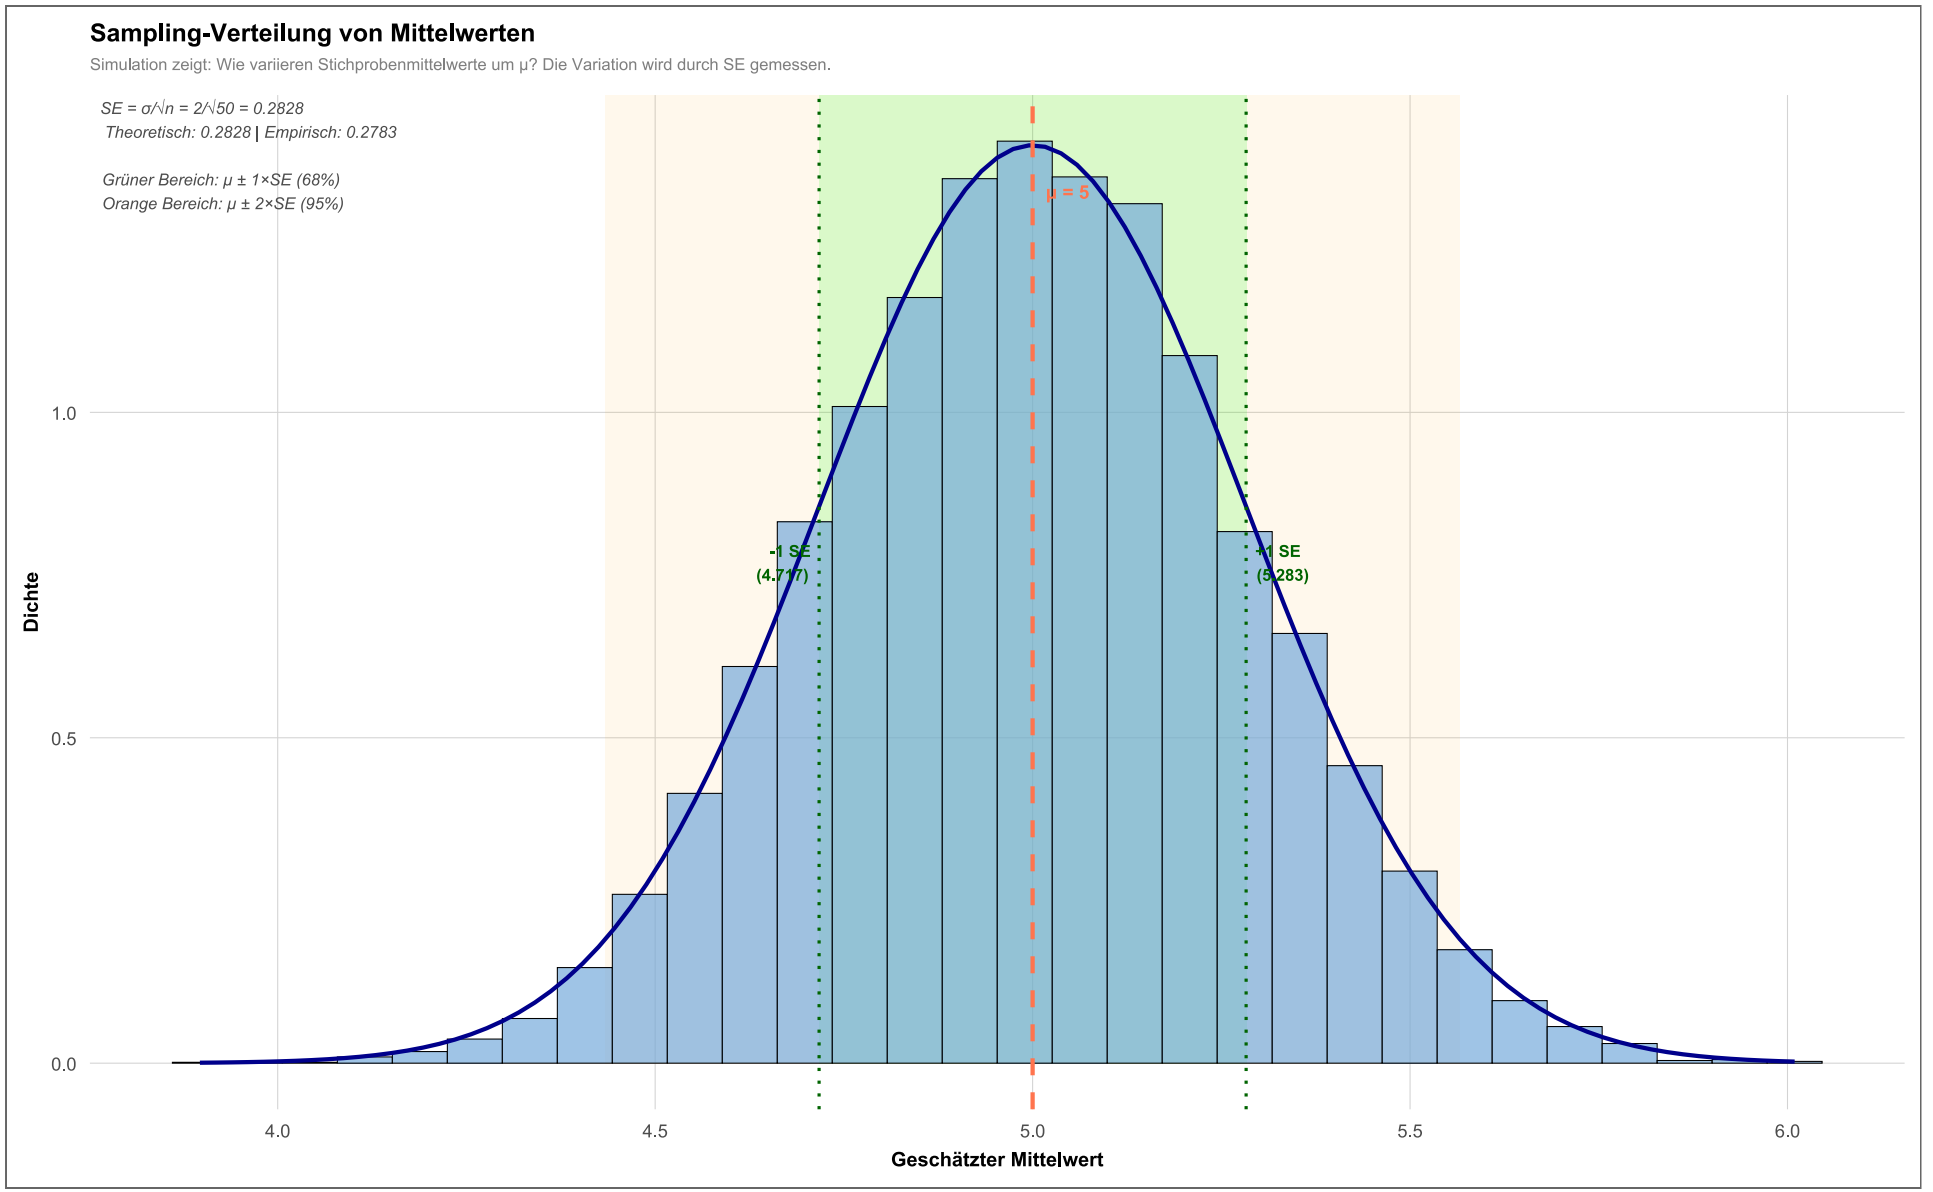
Die korrigierte Standardabweichung ist dementsprechend:

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2}$$

Standardfehler = Standardabweichung erwarteter/zukünftiger Ergebnisse

- Hier hat ein Computer aus einer Population 10.000 mal Stichproben von n = 50 gezogen.
- In der Population ist der Mittelwert der Eigenschaft 5 mit einer Standardabweichung von 2.
- Die Verteilung der 10.000 Mittelwerte hat eine Standardabweichung von 0.2783.
- Der **Standardfehler** aufgrund einer Stichprobe versucht genau diesen Wert zu **schätzen** mit

$$\hat{\sigma}_{\bar{x}} = \frac{2}{\sqrt{50}} = 0.2828$$


Sampling-Verteilung von Mittelwerten
Simulation zeigt: Wie variieren Stichprobenmittelwerte um μ? Die Variation wird durch SE gemessen.
SE = σ/√n = 2/√50 = 0.2828
Theoretisch: 0.2828 | Empirisch: 0.2783
Grüner Bereich: μ ± 1×SE (68%)
Orange Bereich: μ ± 2×SE (95%)
μ = 5
-1 SE
(4.717)
+1 SE
(5.283)
Dichte
1.0
0.5
0.0
4.0
4.5
5.0
5.5
6.0
Geschätzter Mittelwert

Der Standard Error (SE) — Die Kernidee

Was ist SE?

Der Standardfehler (= **S**tandard **E**rror) ist die **Standardabweichung weiterer möglicher Mittelwerte aus gleich gezogenen Stichproben der selben Population**.

$$\mathrm{SE}_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Berechnung

$$\mathrm{SE}_{\bar{x}} = \frac{2}{\sqrt{50}} = \frac{2}{7.07} = 0.2828$$

Das bedeutet: Wir *schätzen*, dass die Mittelwerte zukünftiger Stichproben sich typischerweise um 0.2828 unterscheiden.

Folgen

Größere Stichproben = Kleinerer SE

Wenn wir ein größeres n statt 50 hätten, z.B. n = 200:

$$\text{SE}_{neu} = \frac{2}{\sqrt{200}} = 0.1414$$

Die SE würde halbiert! Die grünen Linien würden näher zusammenrücken.

Folge: Mit größeren Stichproben sind unsere Schätzungen präziser.

Mehr Variation in den Daten = Größerer SE

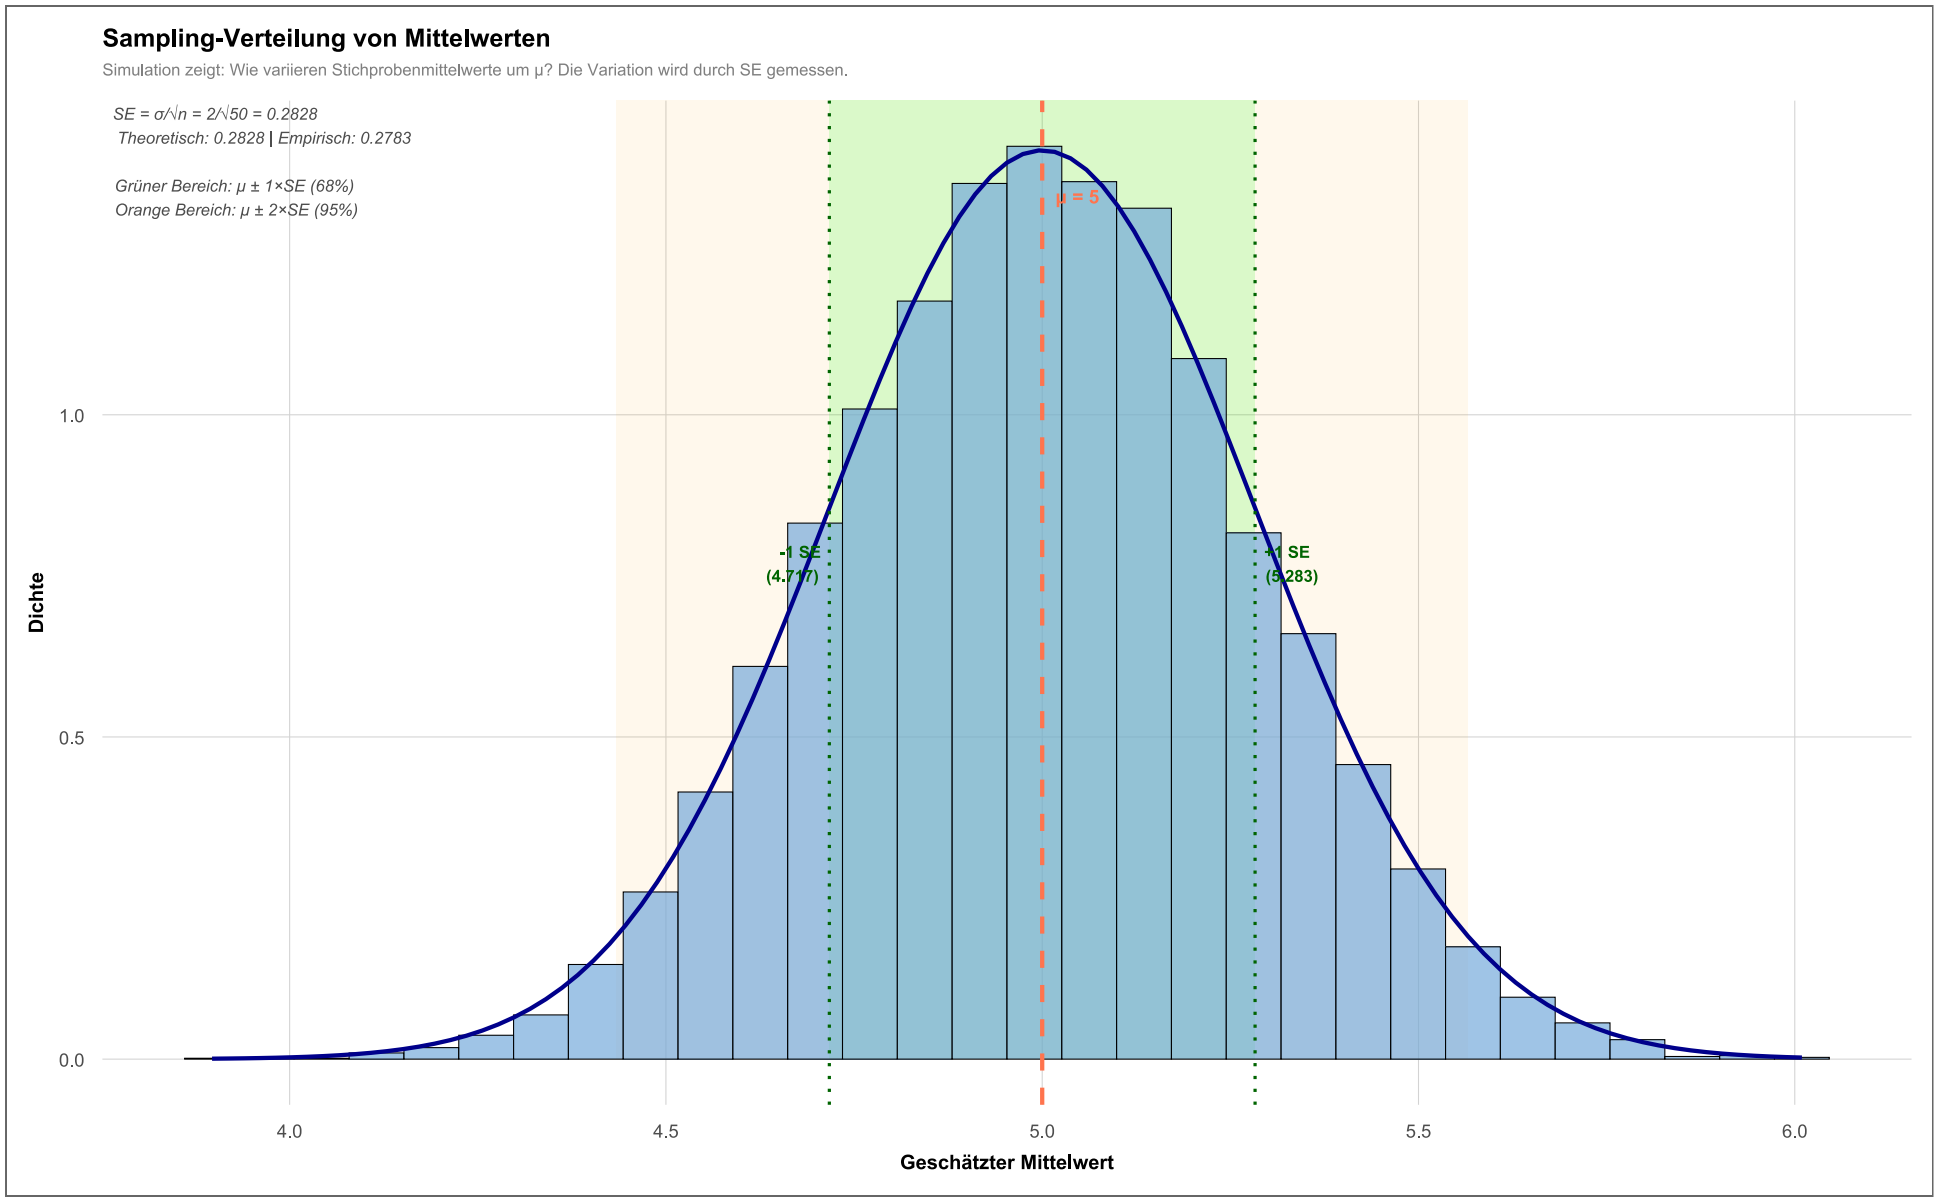
Wenn σ größer statt 2 wäre, z.B. σ = 4:

$$\text{SE}_{neu} = \frac{4}{\sqrt{50}} = 0.5657$$

Der SE würde sich verdoppeln! Die grünen Linien würden weiter auseinander liegen.

Folge: Heterogenere Populationen sind schwerer zu schätzen.

Konfidenzintervalle = Bereiche von möglichen Schwankungen


Sampling-Verteilung von Mittelwerten
Simulation zeigt: Wie variieren Stichprobenmittelwerte um μ? Die Variation wird durch SE gemessen.
SE = σ/√n = 2/√50 = 0.2828
Theoretisch: 0.2828 | Empirisch: 0.2783
Grüner Bereich: μ ± 1×SE (68%)
Orange Bereich: μ ± 2×SE (95%)
μ = 5
-1 SE
(4.717)
+1 SE
(5.283)
Dichte
1.0
0.5
0.0
4.0
4.5
5.0
5.5
6.0
Geschätzter Mittelwert

Was sind Konfidenzintervalle (deep dive)?

- Konfidenzintervalle sind Perzentilgrenzen für eine geschätzte Verteilung möglicher Parameter, die *nur* durch zufällige Unterschiede bei der Stichprobenziehung variiert.
- Wir behaupten, dass unser Parameter der Mittelwert[1] und der geschätzte Standardfehler die Standardabweichung der Parameterverteilung ist.
- Da die Variation der Parameter zufällig ist[2], ergibt die Parameterverteilung eine Zufallsverteilung, über die wir komplettes Wissen haben.
- Wir können daher angeben, wie viele Standardabweichungen wir vom Mittelwert aus nach oben/unten gehen müssen, um 99%, 98%, 97%, 96%, 95%, usw. der nicht extremen Zufallsvariation zu erfassen.

1. Genauer: Der Erwartungswert der Verteilung
2. In der Praxis: als zufällig behauptet wird.
3. Extrem ist im Zufallssprech alles, was an den Rändern liegt.

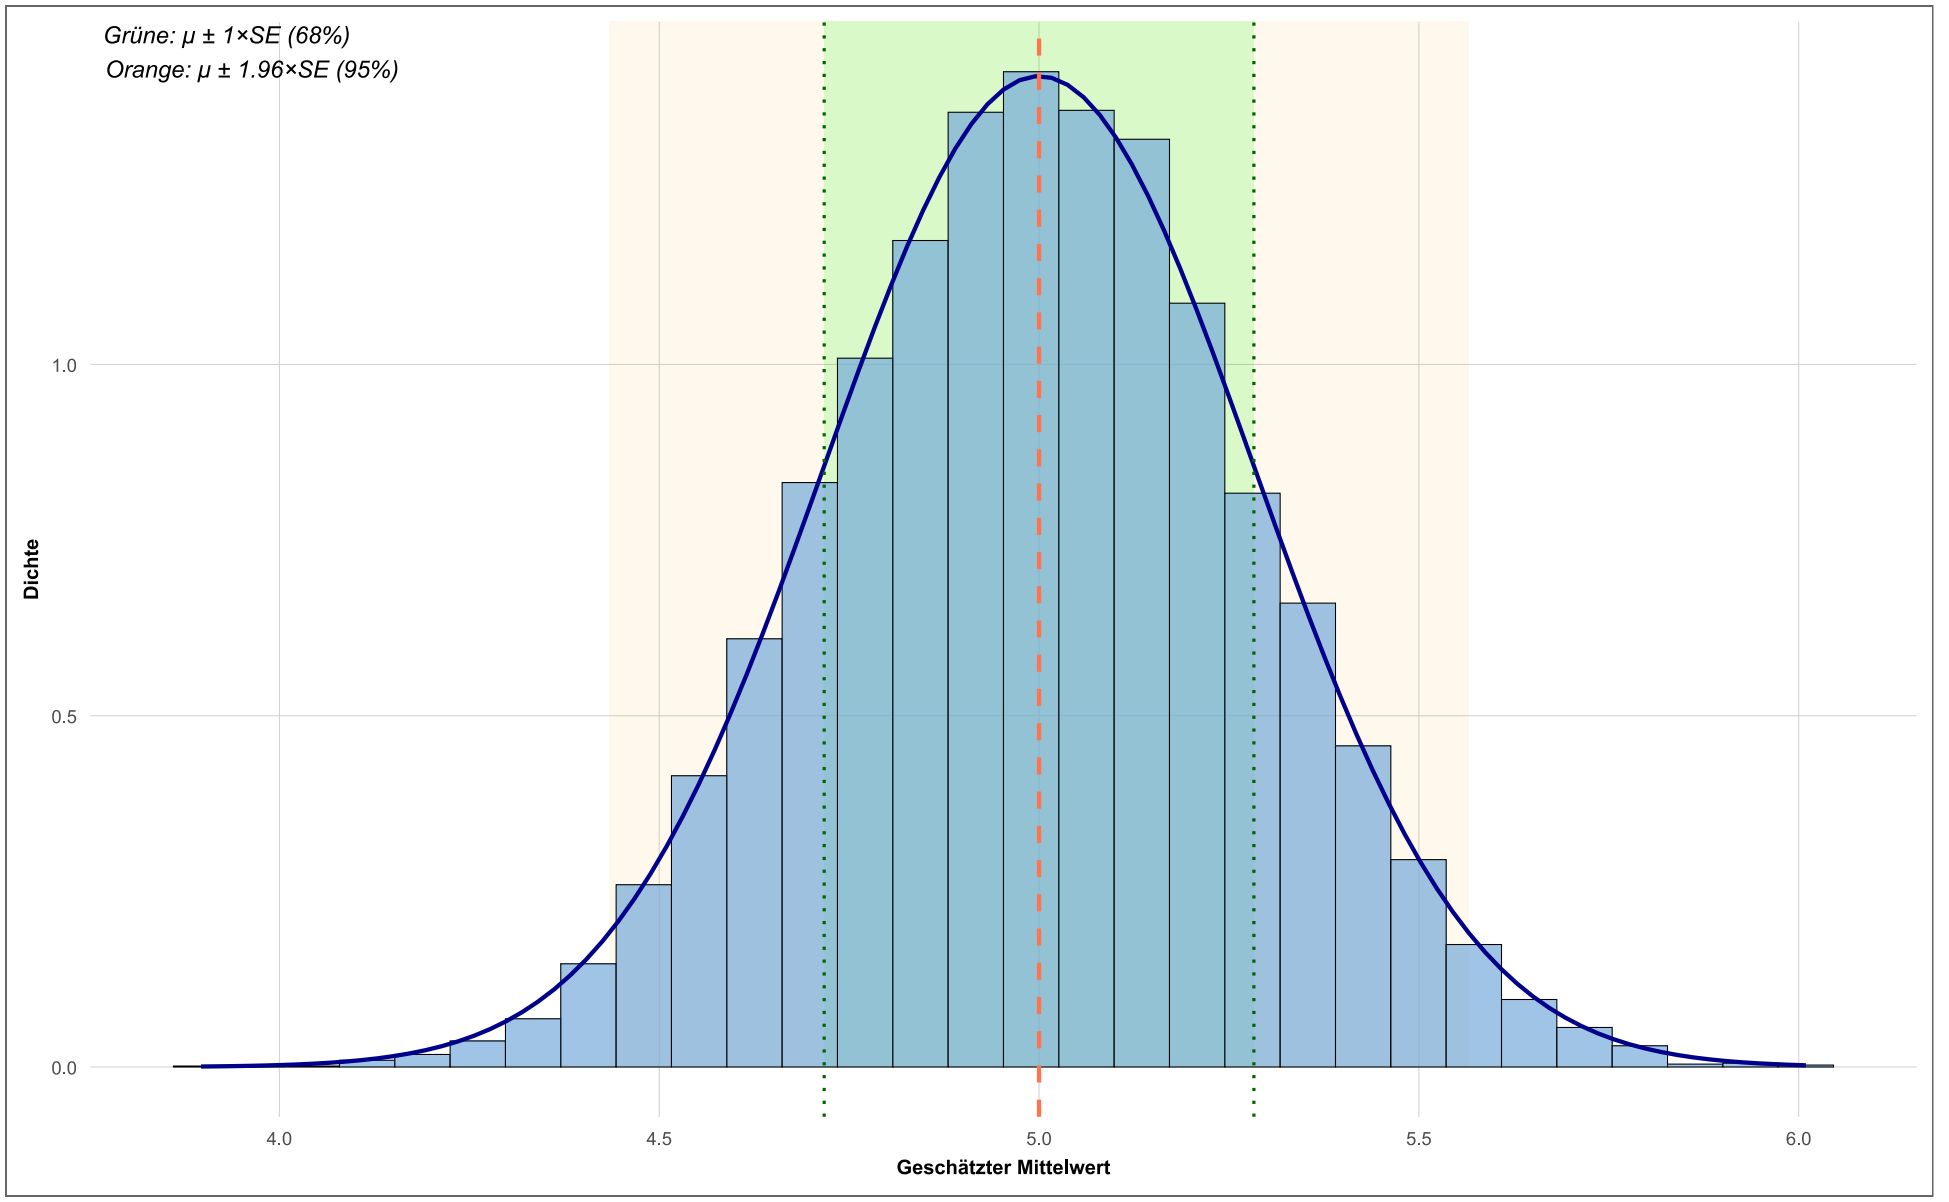
Generelle Berechnung

Die Berechnung von Konfidenzintervallen ist grundsätzlich immer gleich - egal, was für ein Parameter wir nutzen:

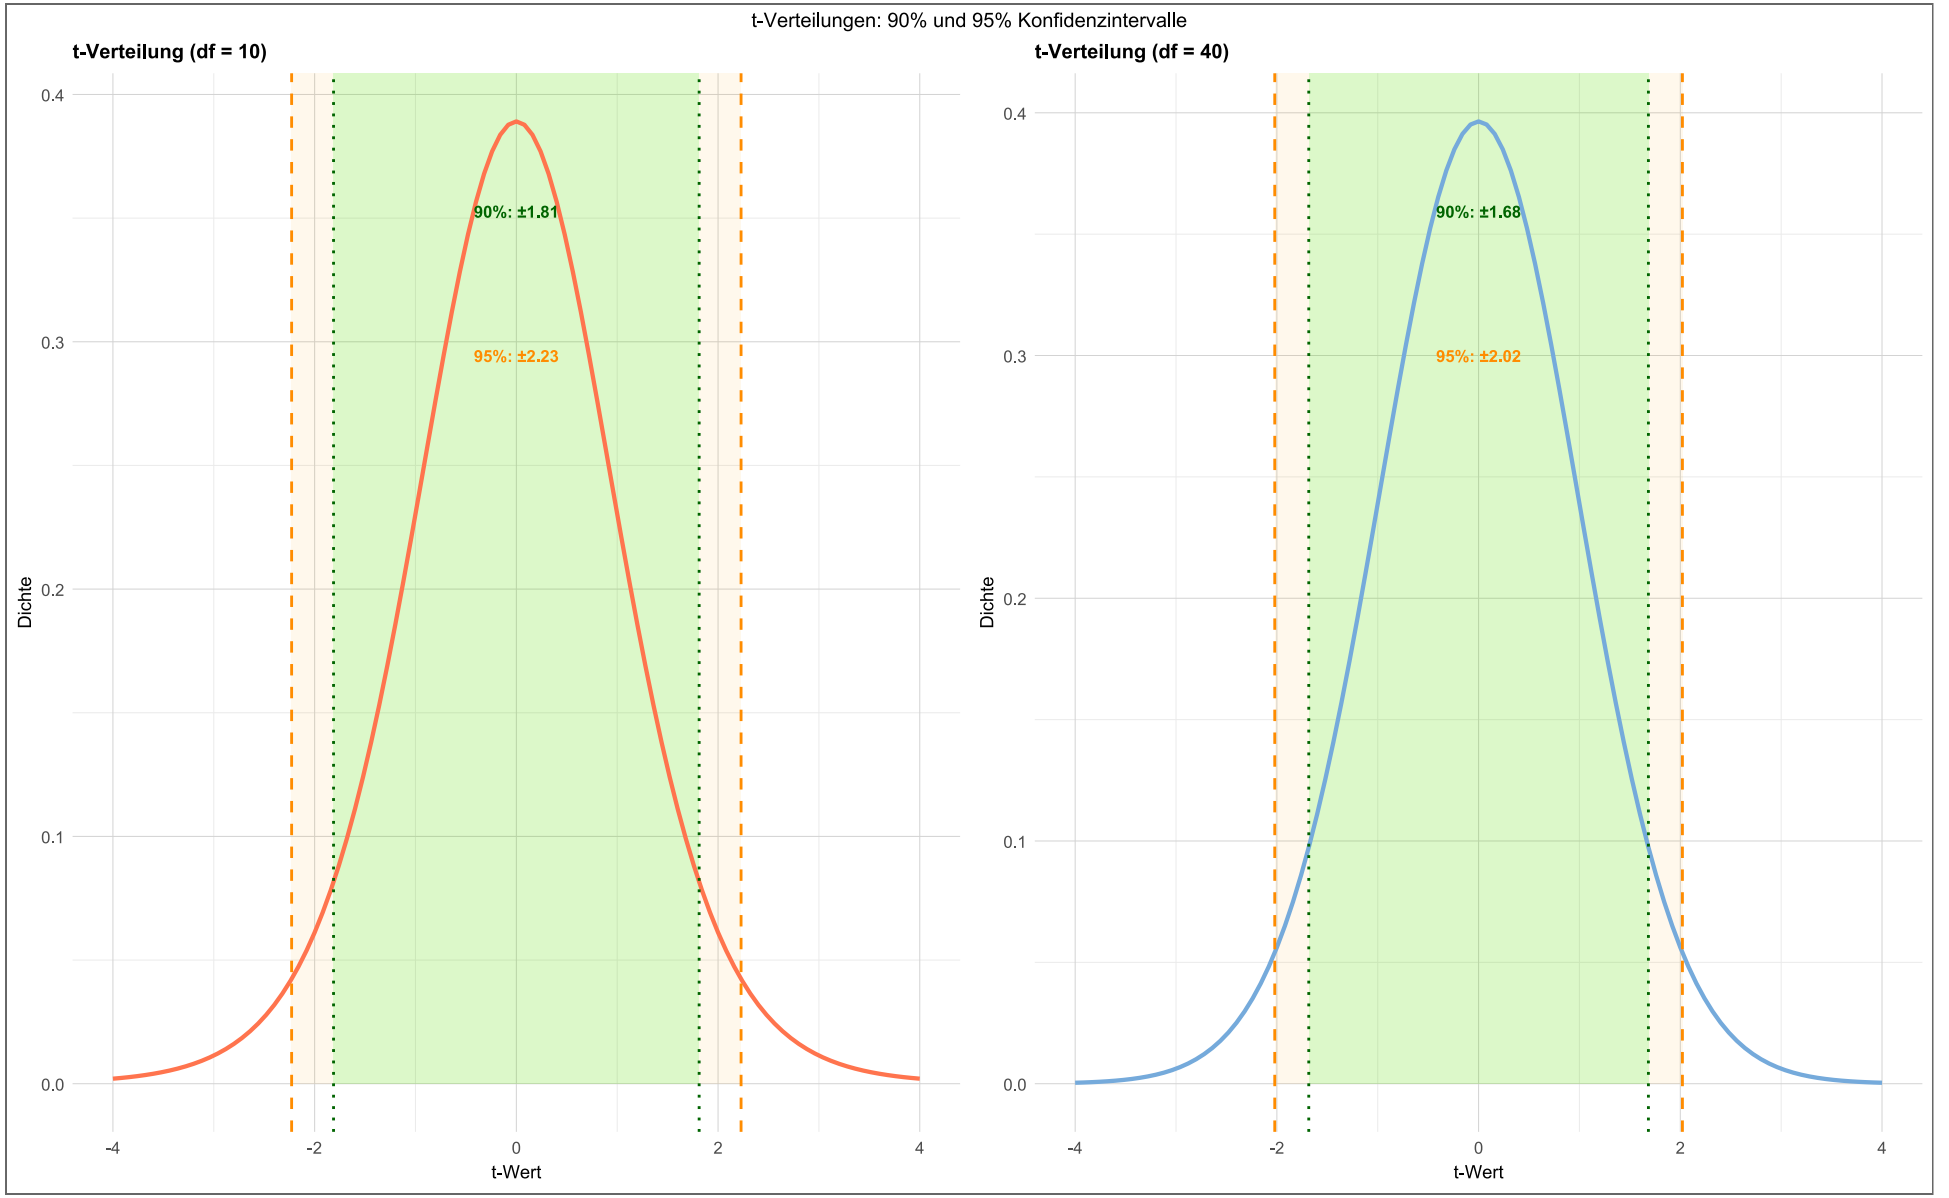
$$\text{Konfidenzintervall} = \text{Parameter} \pm \text{Skalierungsfaktor} \cdot \text{Standardfehler}$$

- Der Skalierungsfaktor (manchmal auch: kritischer Wert) bezeichnet, wie wieviel wir den Standardfehler erhöhen, um nicht extreme Bereiche der Zufallsvariation zu erfassen.

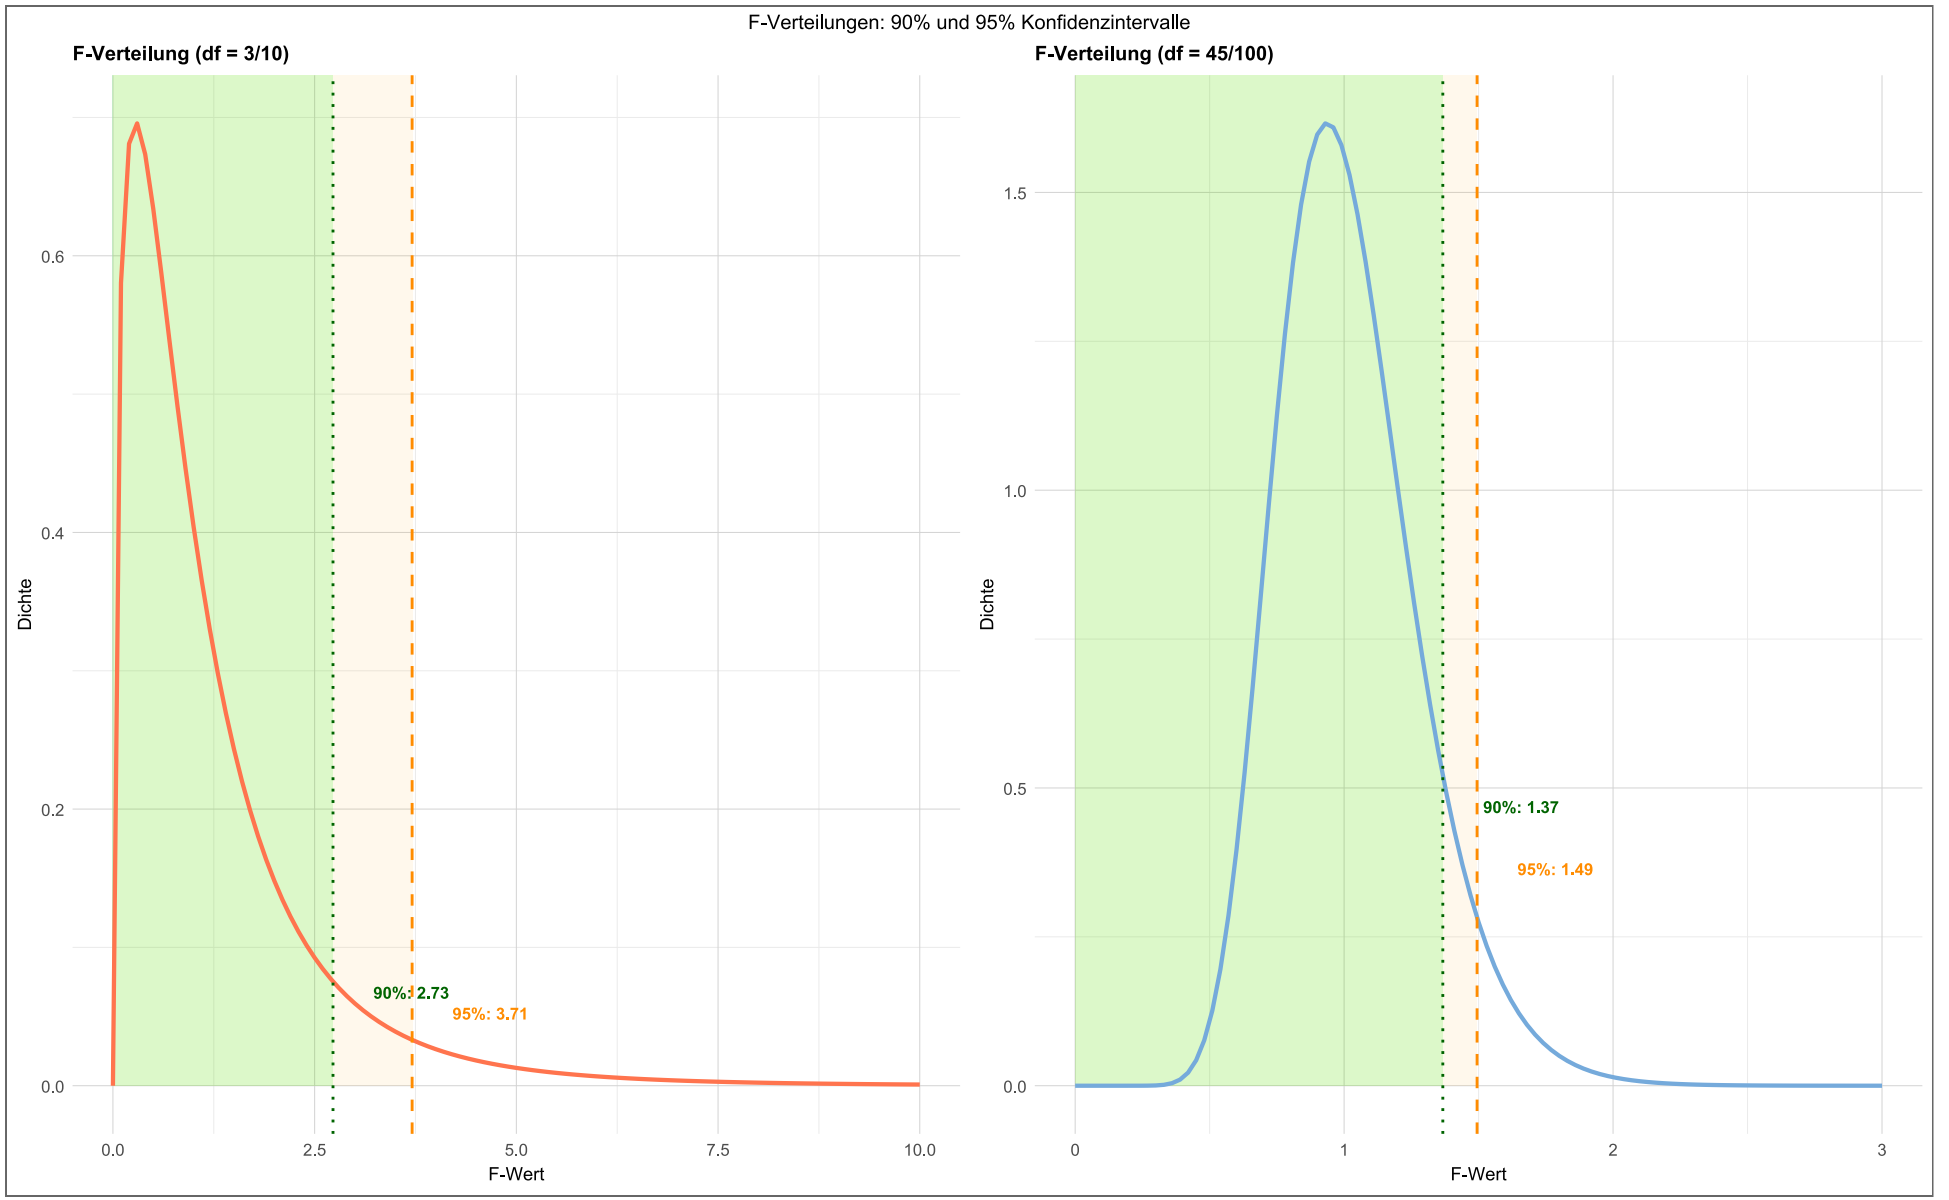
Bereiche der Normalverteilung


Grüne: μ ± 1×SE (68%)
Orange: μ ± 1.96×SE (95%)
Dichte
1.0
0.5
0.0
4.0
4.5
5.0
5.5
6.0
Geschätzter Mittelwert

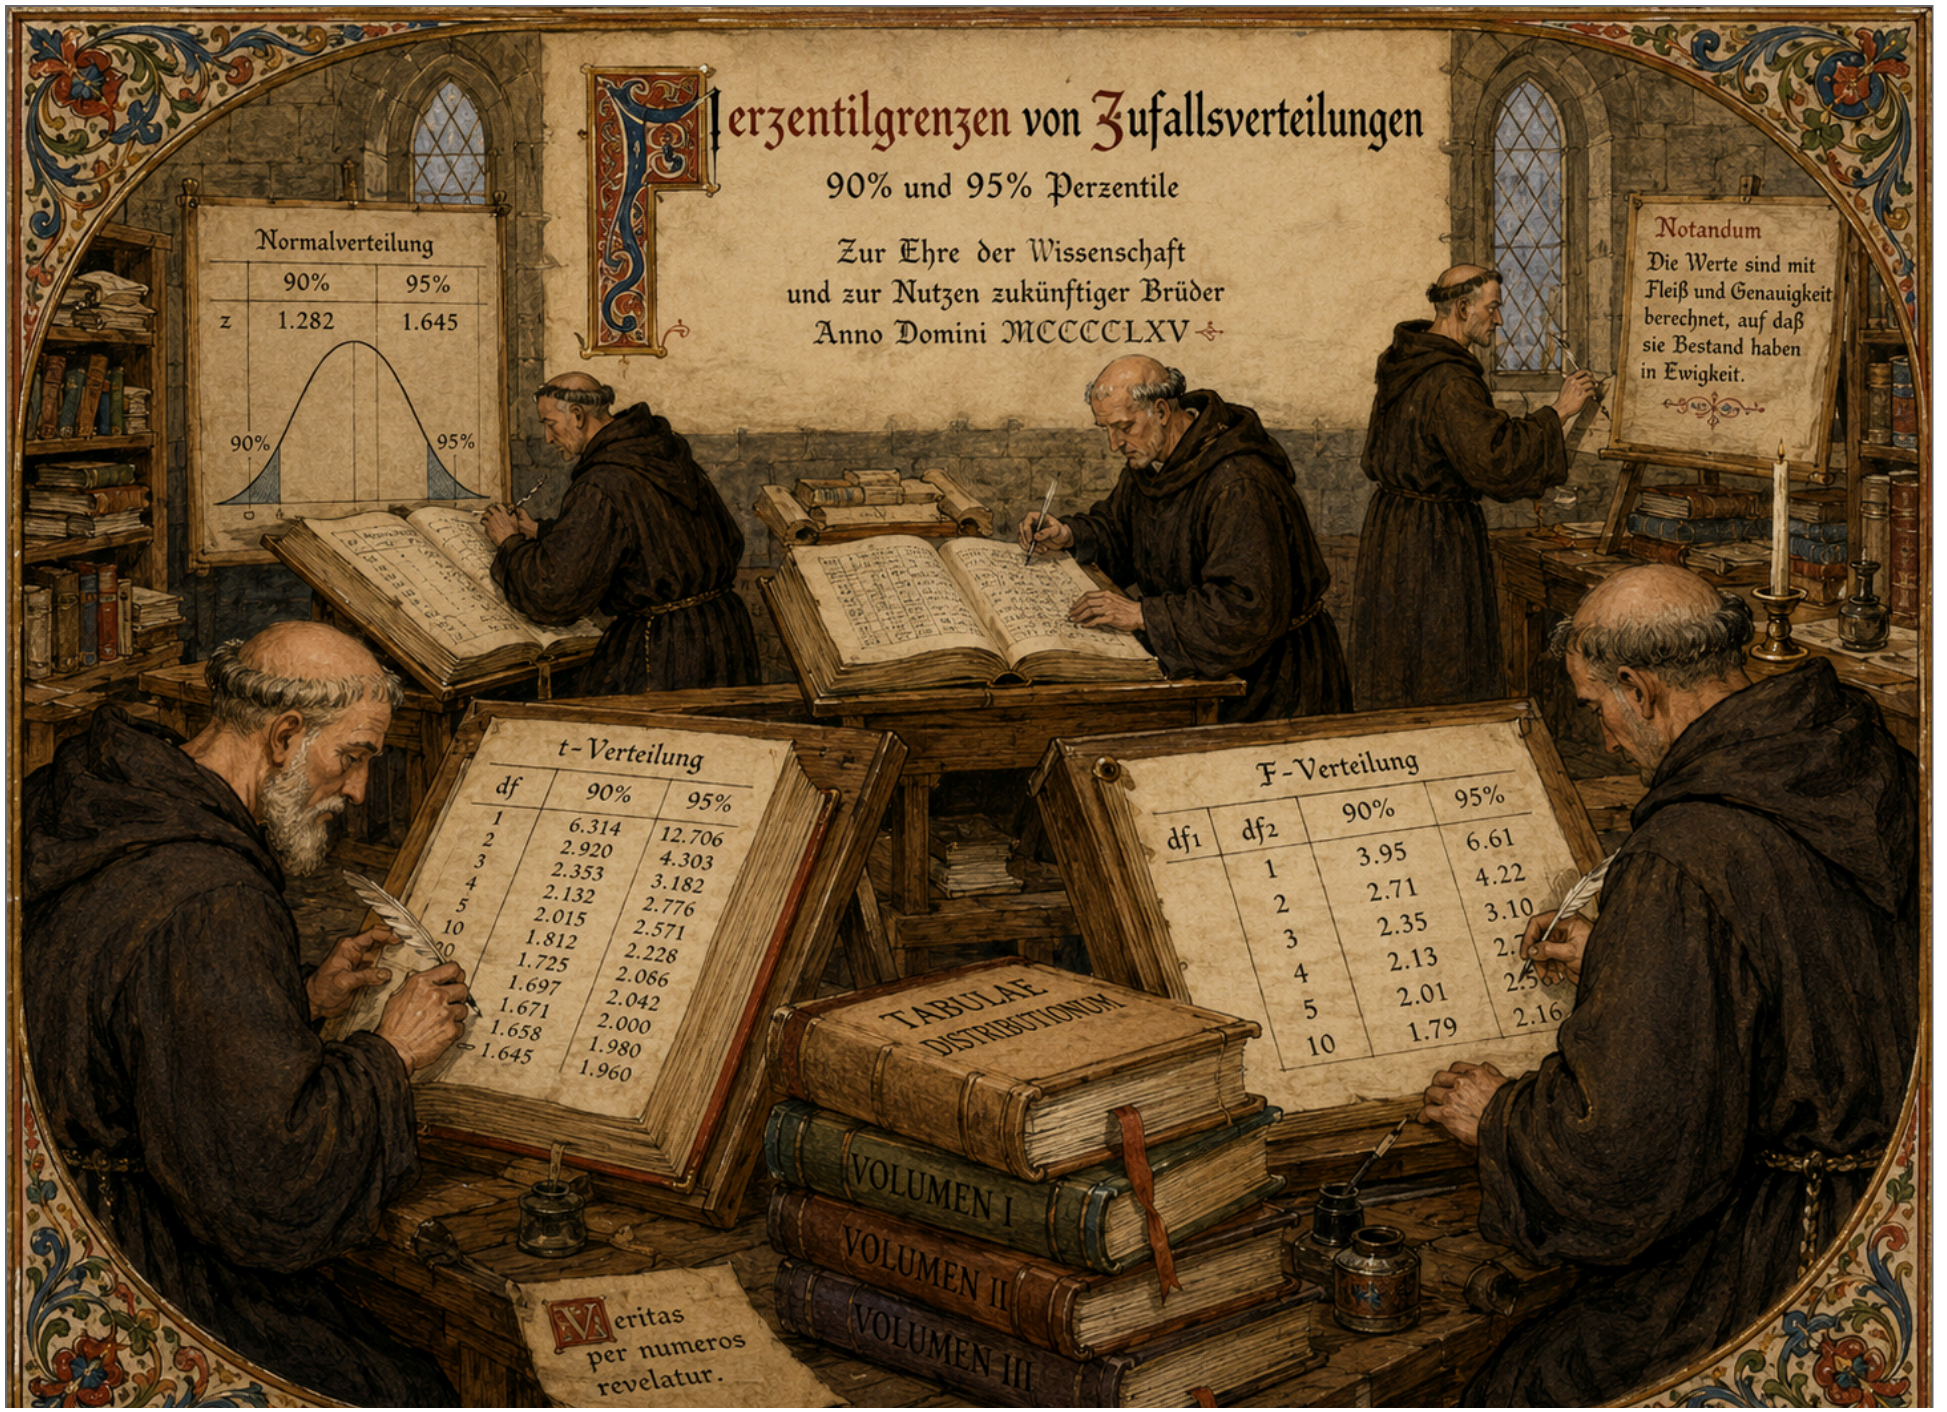
Spezialitätenproblem 1: Kleine Stichproben führen mit höherer Wahrscheinlichkeit zu extremen Abweichungen


t-Verteilungen: 90% und 95% Konfidenzintervalle
t-Verteilung (df = 10)
90%: ±1.81
95%: ±2.23
t-Verteilung (df = 40)
90%: ±1.68
95%: ±2.02
Dichte
t-Wert
0.0
0.1
0.2
0.3
0.4
-4
-2
0
2
4

Spezialitätenproblem 2: Verhältnisse sind (meist) nicht symmetrisch verteilt


F-Verteilungen: 90% und 95% Konfidenzintervalle
F-Verteilung (df = 3/10)
Dichte
0.0
0.2
0.4
0.6
90%: 2.73
95%: 3.71
0.0
2.5
5.0
7.5
10.0
F-Wert
F-Verteilung (df = 45/100)
Dichte
0.0
0.5
1.0
1.5
90%: 1.37
95%: 1.49
0
1
2
3
F-Wert

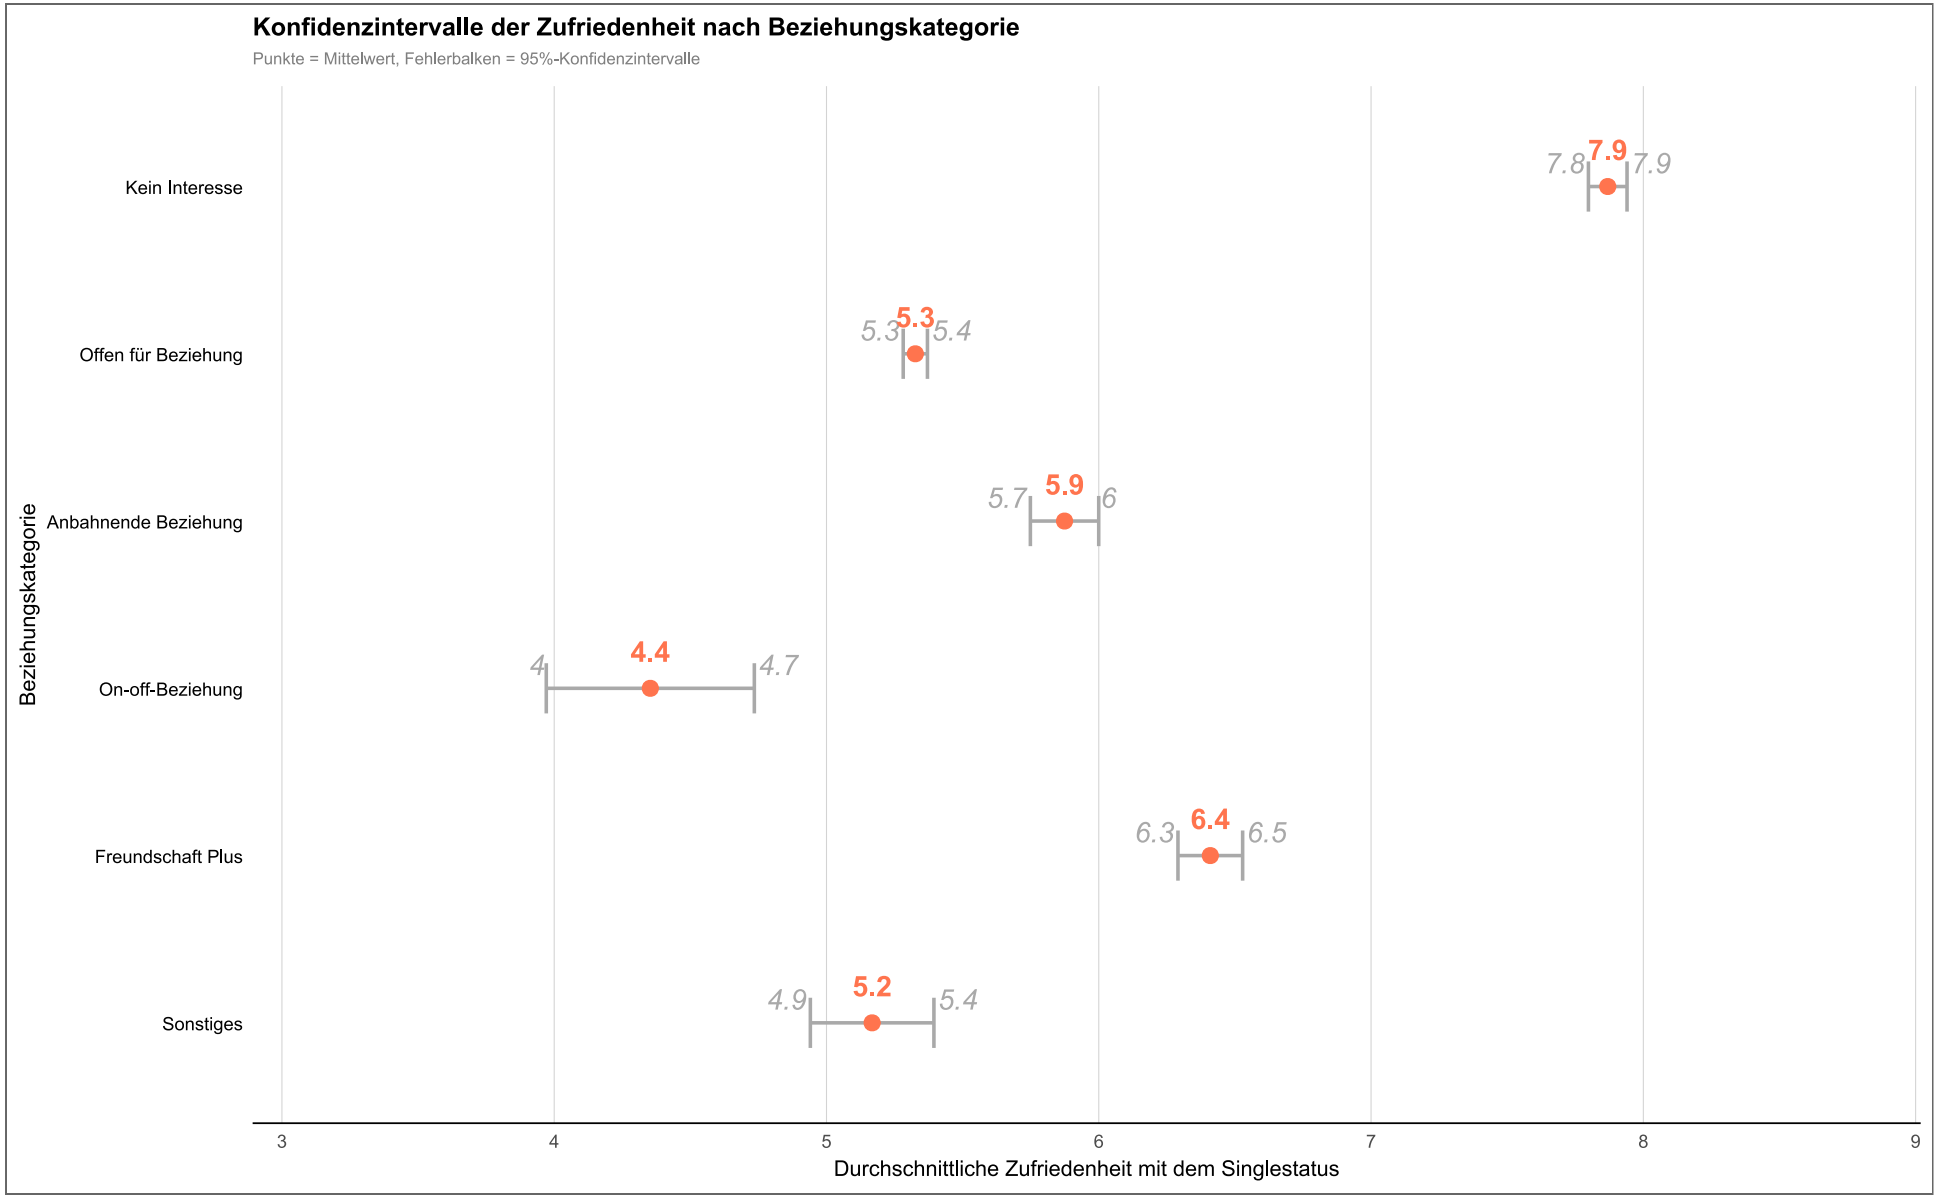
Woher kennen wir Skalierungsparameter für jede Verteilung?


Perzentilgrenzen von Zufallsverteilungen
90% und 95% Perzentile
Zur Ehre der Wissenschaft
und zur Nutzen zukünftiger Brüder
Anno Domini MCCCCLXV
Normalverteilung
90%
95%
z
1.282
1.645
90%
95%
Notandum
Die Werte sind mit Fleiß und Genauigkeit berechnet, auf daß sie Bestand haben in Ewigkeit.
t-Verteilung
df
90%
95%
1 6.314 12.706
2 2.920 4.303
3 2.353 3.182
4 2.132 2.776
5 2.015 2.571
10 1.812 2.228
1.725 2.066
1.697 2.042
1.671 2.000
1.658 1.980
1.645 1.960
F-Verteilung
df1
df2
90%
95%
1 3.95 6.61
2 2.71 4.22
3 2.35 3.10
4 2.13
5 2.01
10 1.79 2.16
TABULAE DISTRIBUTIONUM
VOLUMEN I
VOLUMEN II
VOLUMEN III
Veritas per numeros revelatur.



Für jedes Problemchen ein Appchen

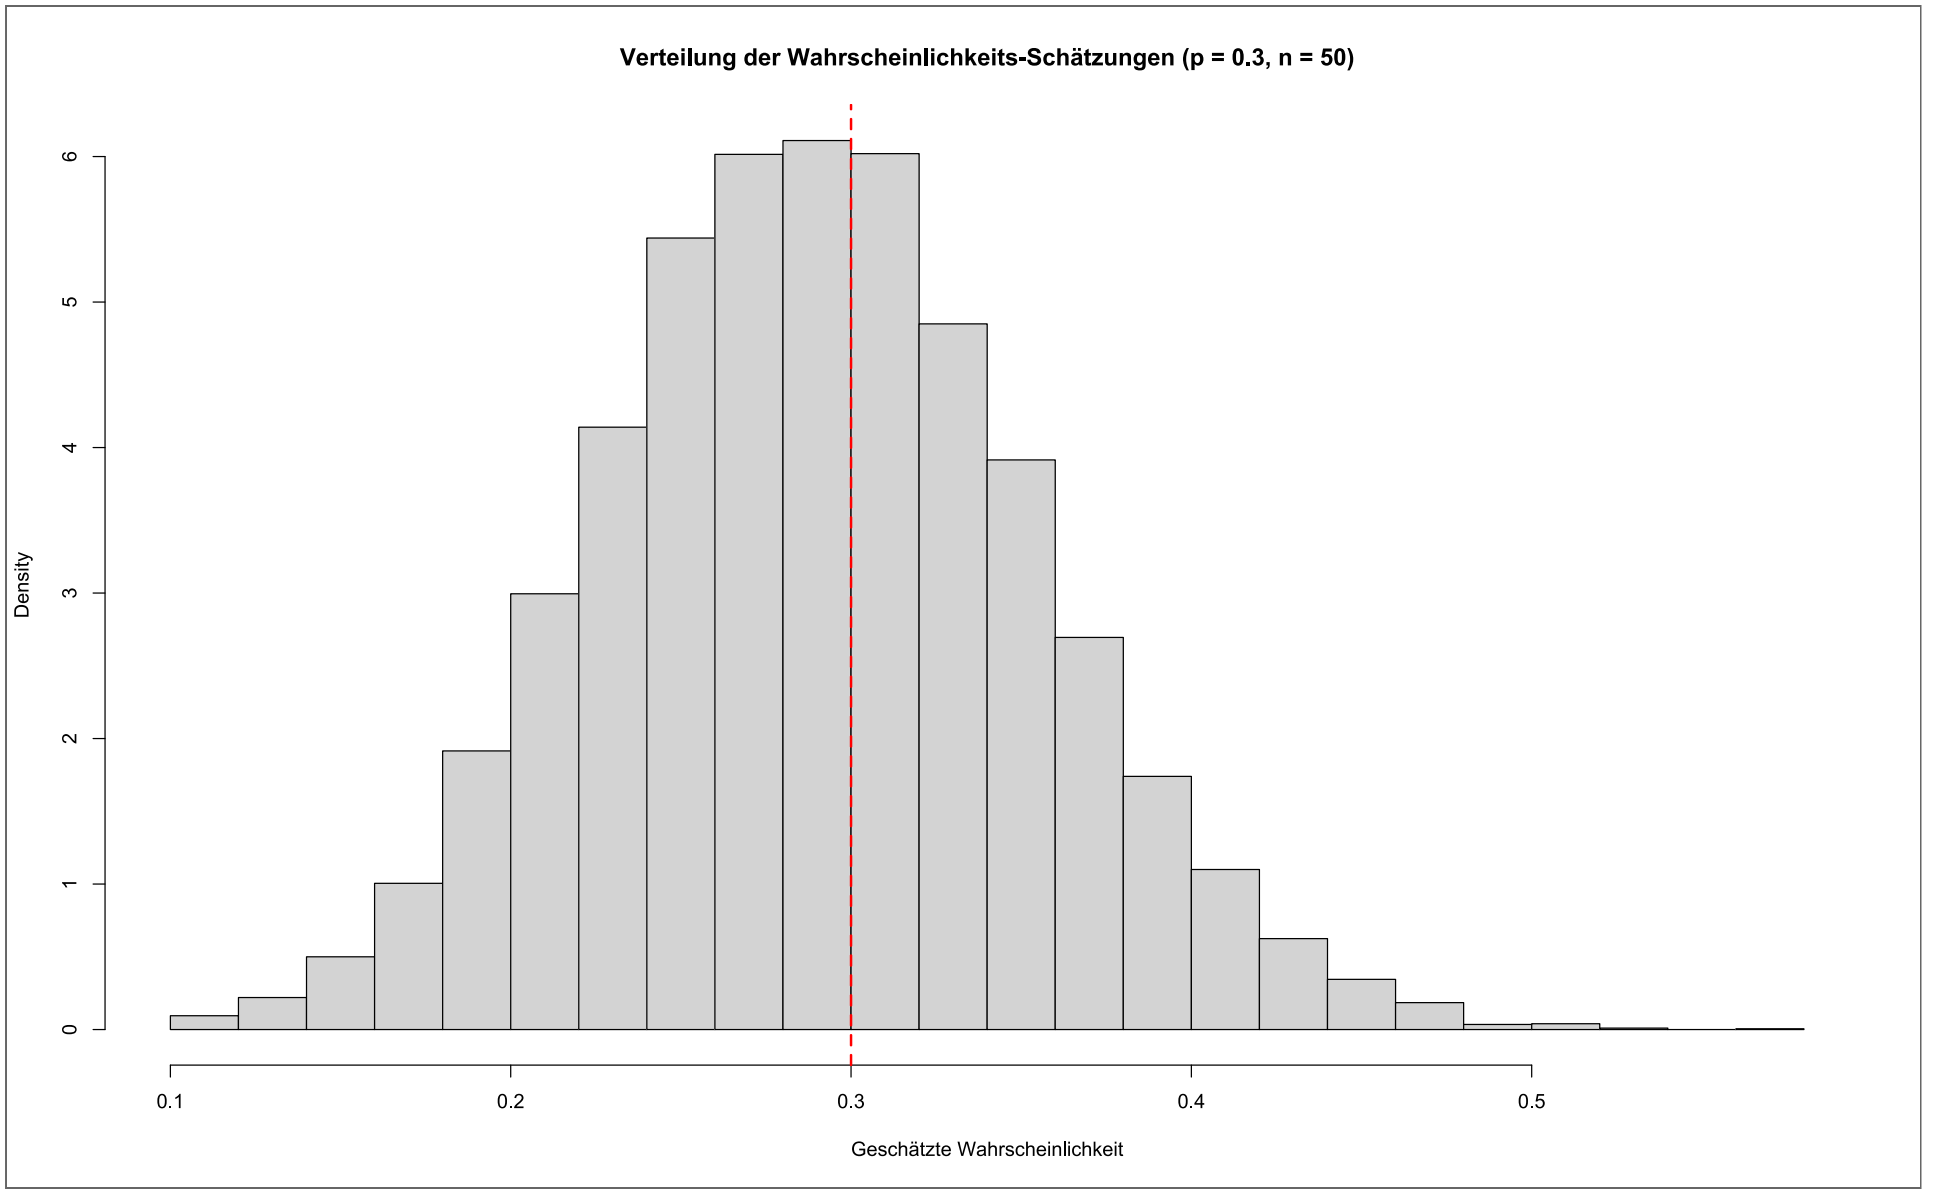
“Es ist kompliziert” macht unglücklich


Konfidenzintervalle der Zufriedenheit nach Beziehungskategorie
Punkte = Mittelwert, Fehlerbalken = 95%-Konfidenzintervalle
Beziehungskategorie
Kein Interesse
Offen für Beziehung
Anbahnende Beziehung
On-off-Beziehung
Freundschaft Plus
Sonstiges
7.8
7.9
7.9
5.3
5.3
5.4
5.7
5.9
6
4
4.4
4.7
6.3
6.4
6.5
4.9
5.2
5.4
3
4
5
6
7
8
9
Durchschnittliche Zufriedenheit mit dem Singlestatus

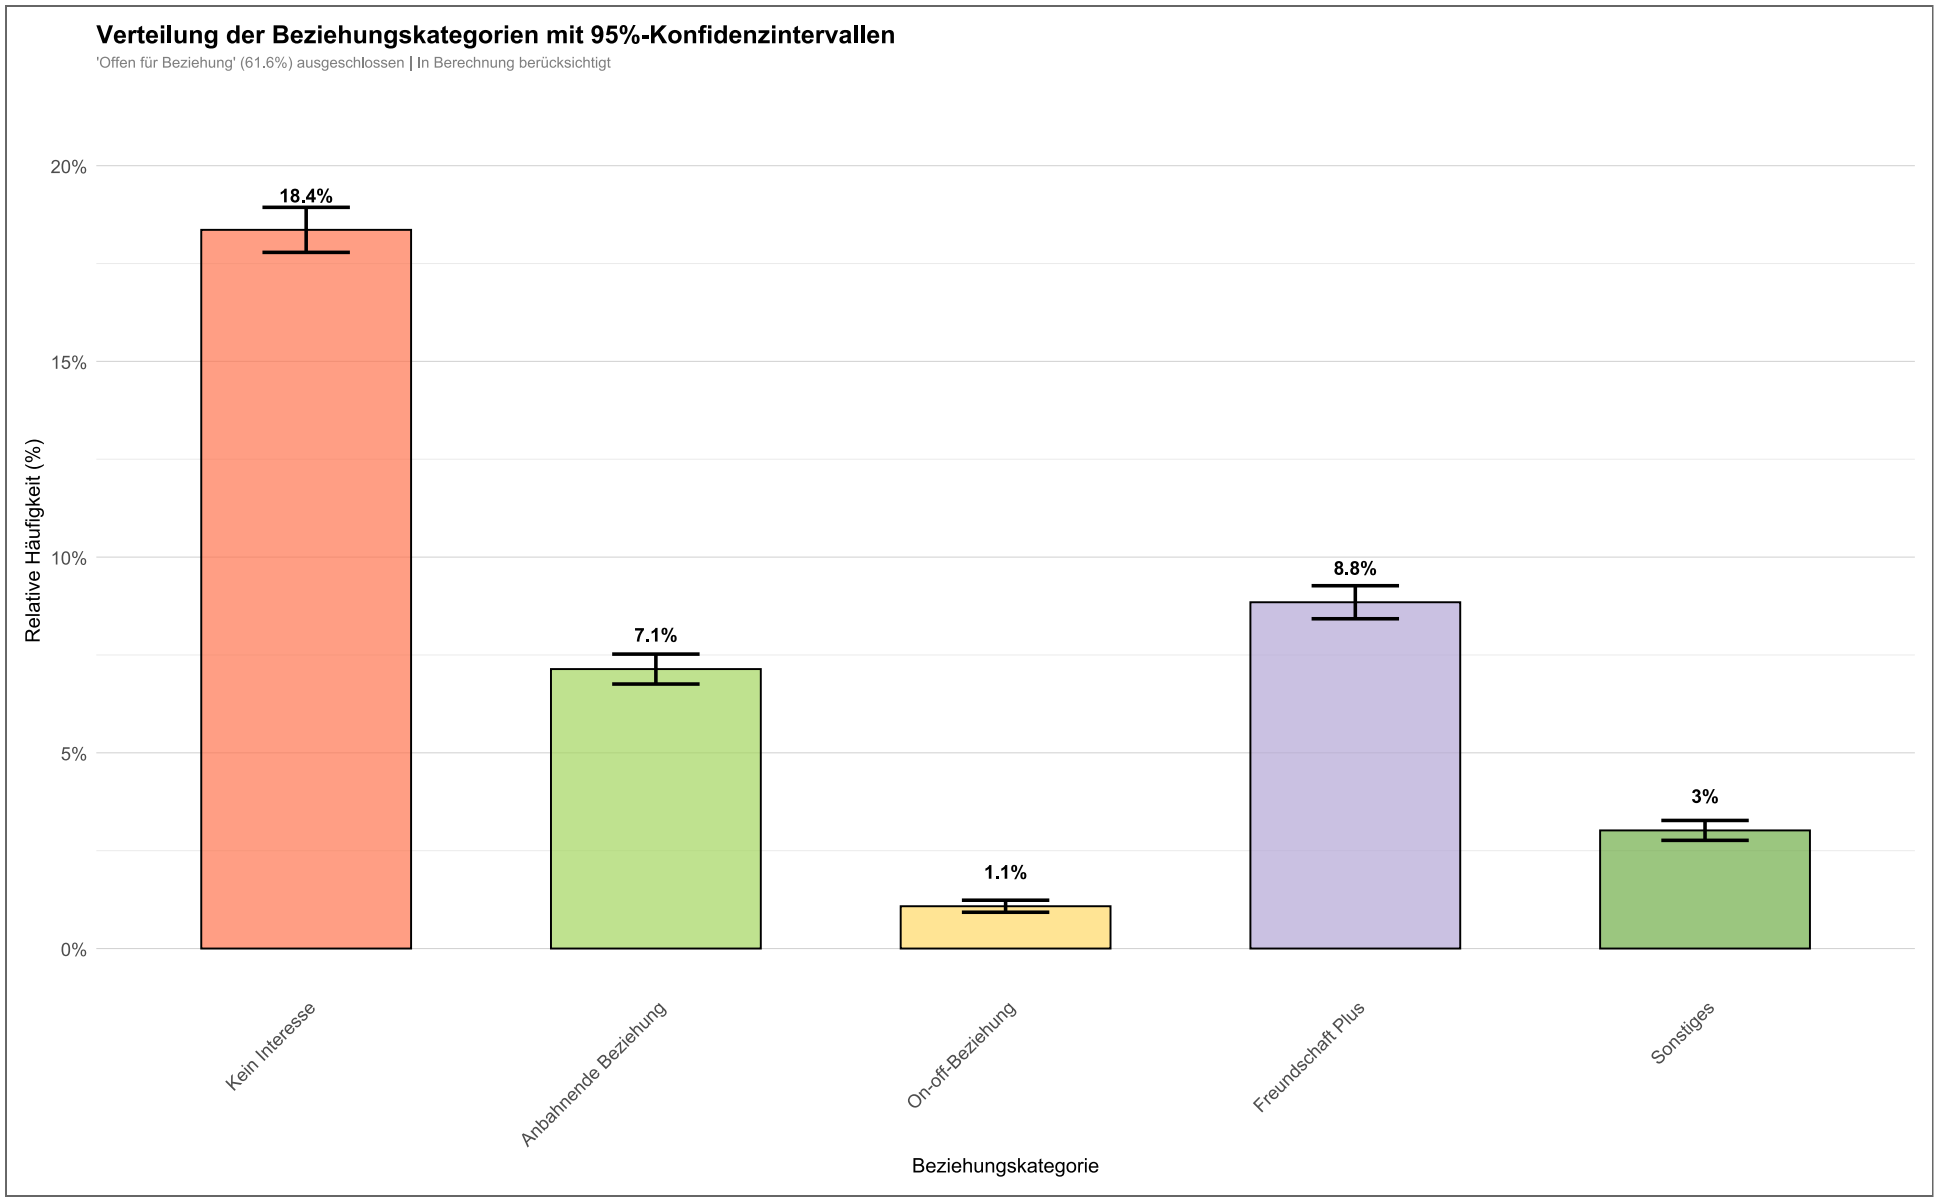
Standardfehler für Wahrscheinlichkeiten

$$SE_p = \sqrt{\frac{p(1-p)}{n}}$$

wobei: p = Wahrscheinlichkeit in der Grundgesamtheit n = Stichprobengröße


Verteilung der Wahrscheinlichkeits-Schätzungen (p = 0.3, n = 50)
Density
0
1
2
3
4
5
6
0.1
0.2
0.3
0.4
0.5
Geschätzte Wahrscheinlichkeit

“Es ist kompliziert” ist selten


Verteilung der Beziehungskategorien mit 95%-Konfidenzintervallen
'Offen für Beziehung' (61.6%) ausgeschlossen | In Berechnung berücksichtigt
Relative Häufigkeit (%)
20%
15%
10%
5%
0%
18.4%
7.1%
1.1%
8.8%
3%
Kein Interesse
Anbahnende Beziehung
On-off-Beziehung
Freundschaft Plus
Sonstiges
Beziehungskategorie

Standardfehler für Mittelwertdifferenzen

$$\mathrm{SE}_{\bar{x}_A - \bar{x}_B} = \sqrt{\frac{\hat{\sigma}^2_\mathrm{A}}{n_\mathrm{A}} + \frac{\hat{\sigma}^2_\mathrm{B}}{n_\mathrm{B}}}$$

Je kleiner die Stichproben und/oder je größer die Varianz des Merkmals:

- desto “unsicherer” ist unsere Inferenz über die Differenzen in der Population;
- desto wahrscheinlicher sind extreme, aber dennoch zufällige Abeichungen;
- desto wahrscheinlicher weichen die Ergebnisse vom Populationsparameter ab.

Sind Frauen auch bei “es ist kompliziert” zufriedener als Männer?

Zufriedenheit mit Singlestatus nach Geschlecht und Beziehungskategorie

Beziehungskategorie	MW Frauen	MW Männer	Differenz	SD Frauen	SD Männer	SE Diff.	95%-KI
Kein Interesse	8.02	7.62	0.39	2.00	2.10	0.075	[0.25, 0.54]
Offen für Beziehung	5.60	5.11	0.49	2.32	2.35	0.045	[0.4, 0.58]
Anbahnende Beziehung	6.09	5.60	0.49	2.21	2.29	0.129	[0.24, 0.74]
On-off-Beziehung	4.54	3.97	0.58	2.68	2.63	0.411	[-0.23, 1.38]
Freundschaft Plus	6.34	6.49	-0.16	2.40	2.35	0.121	[-0.4, 0.08]

Beziehungskategorie	MW Frauen	MW Männer	Differenz	SD Frauen	SD Männer	SE Diff.	95%-KI
Sonstiges	5.50	4.61	0.89	2.66	2.56	0.234	[0.44, 1.35]

Detailliertes Beispiel: “Kein Interesse”

Wir verdeutlichen die Konfidenzintervall-Berechnung Schritt-für-Schritt für die Kategorie “Kein Interesse”.

- Frauen: n = 1988; Mittelwert = 8.02; SD = 2.00
- Männer: n = 1202; Mittelwert = 7.62; SD = 2.10

$$\text{Differenz} = \bar{x}_{\text{Frauen}} - \bar{x}_{\text{Männer}} = 8.02 - 7.62 = 0.395$$

Interpretation: Frauen sind im Durchschnitt um 0.40 Punkte (auf 0-10 Skala) zufriedener mit dem Singlestatus.

Standardfehler der Differenz

Der Standardfehler kombiniert die Varianzen der Zufriedenheit beider Gruppen und berücksichtigt ihre verschiedenen Stichprobengrößen:

$$
\begin{aligned}
\text{SE}_{\bar{x}_{\text{Frauen}} - \bar{x}_{\text{Männer}}} &= \sqrt{\frac{\hat{\sigma}^2_{\text{Frauen}}}{n_{\text{Frauen}}} + \frac{\hat{\sigma}^2_{\text{Männer}}}{n_{\text{Männer}}}} \\
&= \sqrt{\frac{4.00}{1988} + \frac{4.41}{1202}} \\
&= \sqrt{0.00201 + 0.00367} \\
&= 0.0753
\end{aligned}
$$

Wir schätzen, dass Mittelwertdifferenzen in der Zufriedenheit zwischen Frauen und Männern, die als Single keine Beziehung suchen typischerweise um 0.0753 Einheiten schwanken.

Skalierungsparameter

df	95%-Perzentil (einseitig)	97,5%-Perzentil (zweiseitig)
1	6,3138	12,706
2	2,9200	4,3027
3	2,3534	3,1824
4	2,1318	2,7764
—	—	—
9	1,8331	2,2622
10	1,8125	2,2281
—	—	—
1000	1,6464	1,9623
2000	1,6455	1,9616

df	95%-Perzentil (einseitig)	97,5%-Perzentil (zweiseitig)
3000	1,6453	1,9614

Konfidenzintervall berechnen

Untere Grenze:

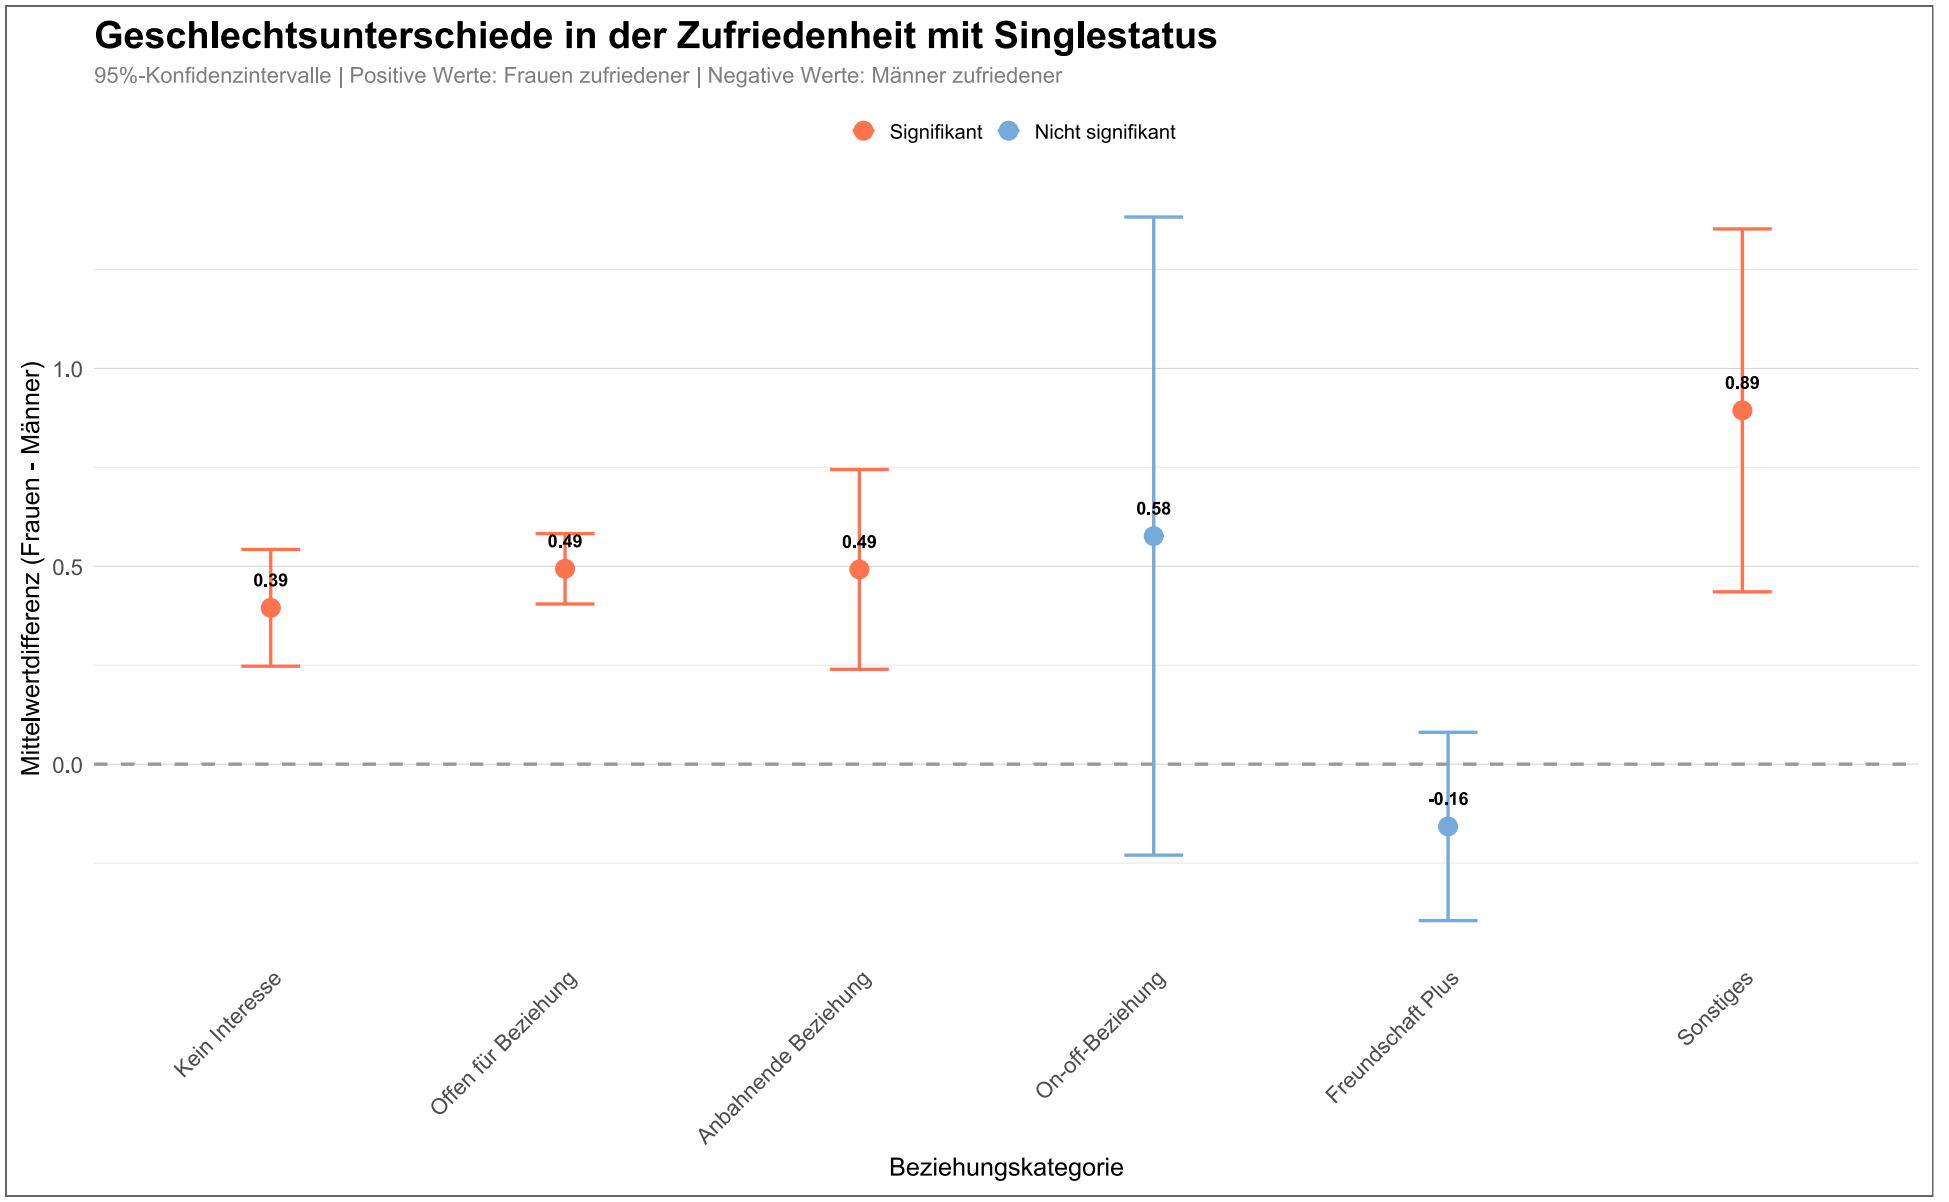
$$\text{Differenz} - z \times \text{SE}_{\text{Diff}} = 0.395 - 1.96 \times 0.0753 = 0.395 - 0.147 = 0.247$$

Obere Grenze:

$$\text{Differenz} + z \times \text{SE}_{\text{Diff}} = 0.395 + 1.96 \times 0.0753 = 0.395 + 0.147 = 0.543$$

Interpretation: Wir erwarten bei zukünftigen Stichproben, dass 95% aller nicht-extremen Stichproben eine Mittelwertdifferenz der Single-Zufriedenheit für Singles, die kein Interesse an einer Beziehung haben, zwischen 0.25 und 0.54 schwankt.

Visualisierung aller t-Tests


Geschlechtsunterschiede in der Zufriedenheit mit Singlestatus
95%-Konfidenzintervalle | Positive Werte: Frauen zufriedener | Negative Werte: Männer zufriedener
Signifikant
Nicht signifikant
Mittelwertdifferenz (Frauen - Männer)
1.0
0.5
0.0
0.39
0.49
0.49
0.58
-0.16
0.89
Kein Interesse
Offen für Beziehung
Anbahnende Beziehung
On-off-Beziehung
Freundschaft Plus
Sonstiges
Beziehungskategorie

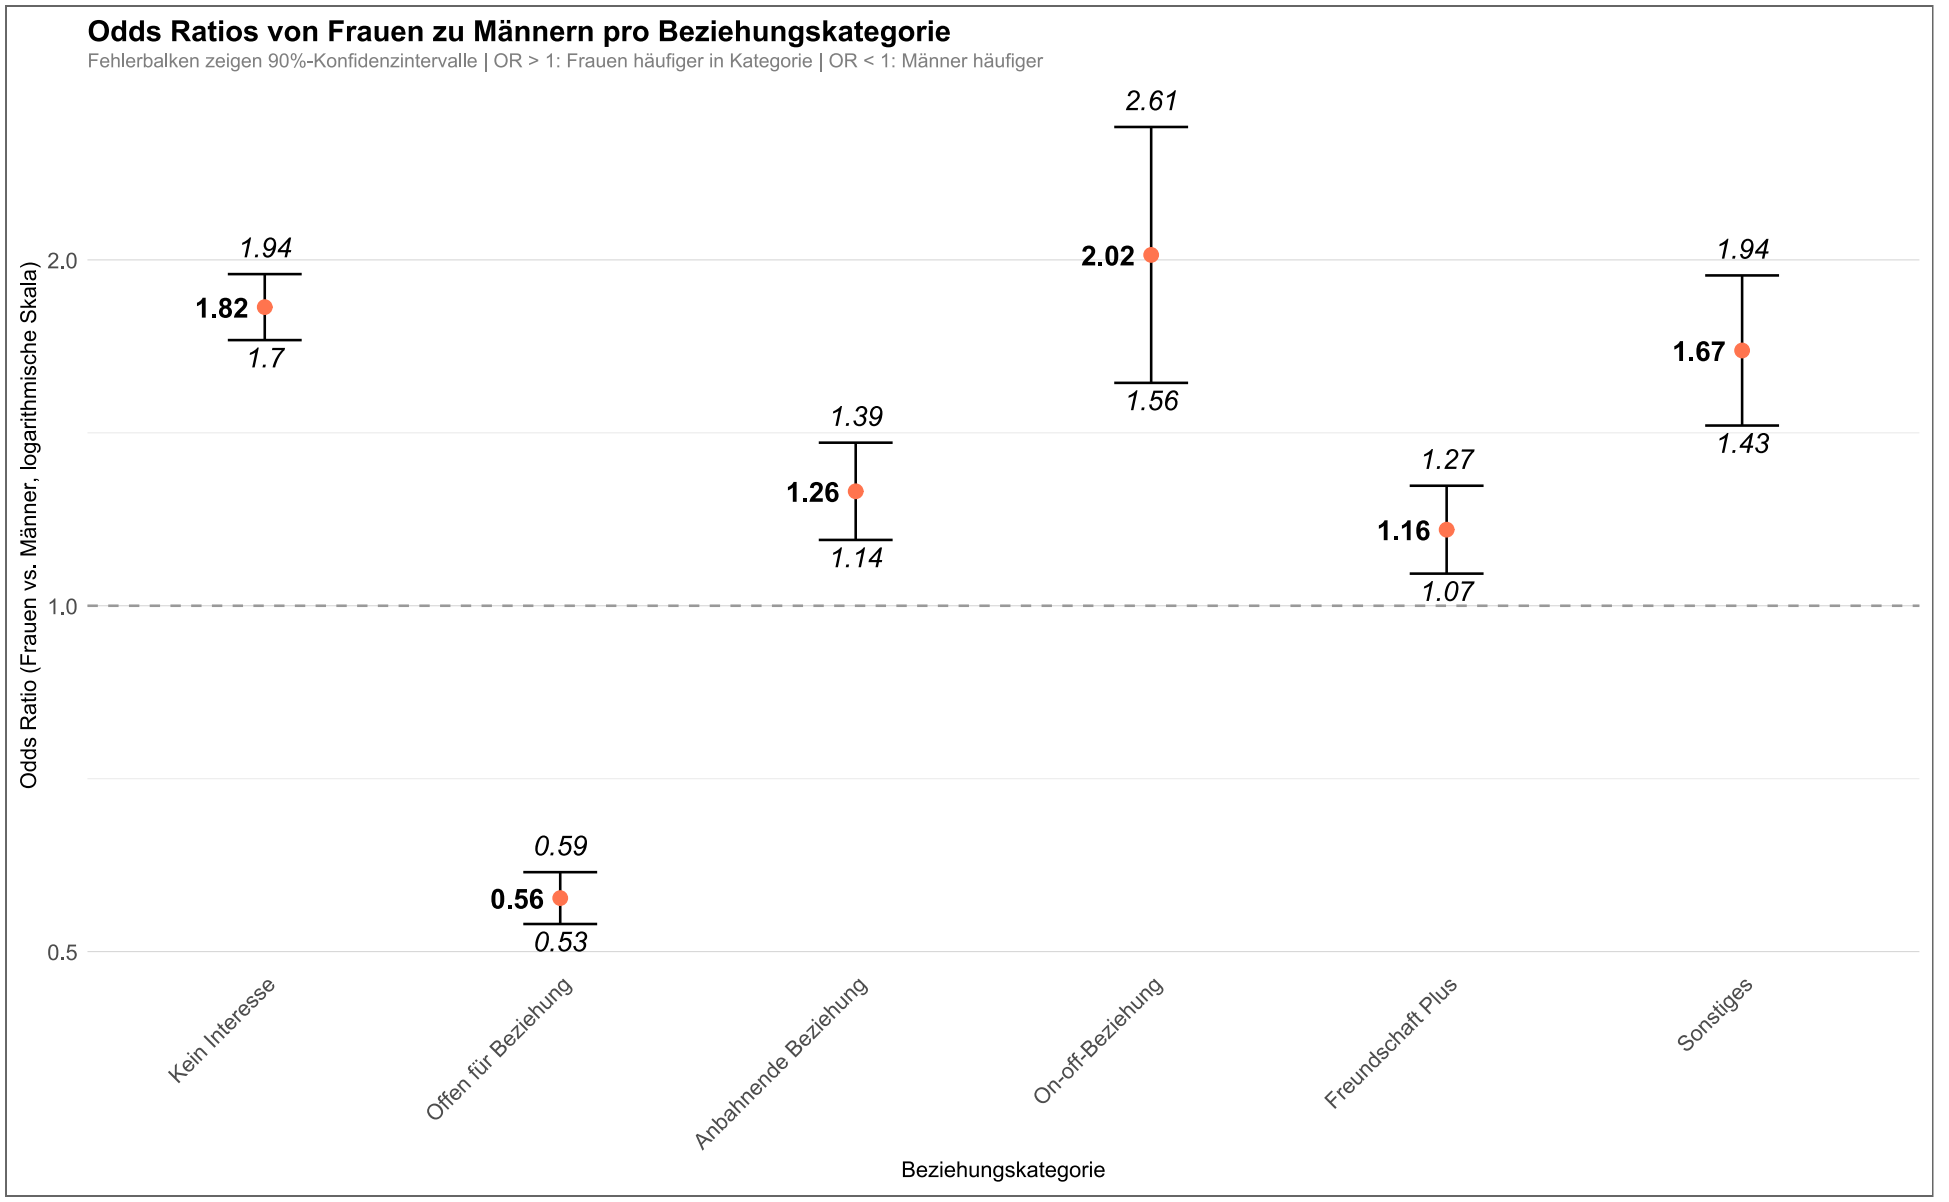
Standardfehler für Odds Ratios

$$SE_{\mathrm{OR}} = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

wobei: a, b, c, d = Zellhäufigkeiten in der empirischen Zusammenhangstabelle
Wichtig: Odds Ratios sind ein Verhältnis.

- Verhältnisse unter 1:1 konvergieren gegen 0, werden aber nie null.
- Verhältnisse über 1:1 konvergieren gegen $\inf$, werden aber nie $\inf$.
- Daher fallen Zufallsschwankungen von Odds Ratios in einen *asymmetrischen Bereich*.
- Das lässt sich mathematisch durch eine Log-Transformation leicht in den Griff bekommen (siehe Anhang).

Es ist (eher bei Frauen) kompliziert


Odds Ratios von Frauen zu Männern pro Beziehungskategorie
Fehlerbalken zeigen 90%-Konfidenzintervalle | OR > 1: Frauen häufiger in Kategorie | OR < 1: Männer häufiger
Odds Ratio (Frauen vs. Männer, logarithmische Skala)
2.0
1.0
0.5
1.94
1.82
1.7
0.59
0.56
0.53
1.39
1.26
1.14
2.61
2.02
1.56
1.27
1.16
1.07
1.94
1.67
1.43
Kein Interesse
Offen für Beziehung
Anbahnende Beziehung
On-off-Beziehung
Freundschaft Plus
Sonstiges
Beziehungskategorie

Standardfehler für bivariate Regressionskoeffizienten

$$SE_\beta = \sqrt{\frac{\sigma^2}{\sum (x_i - \bar{x})^2}}$$

σ^2 = Varianz der Residuen; x_i = Werte ; $\bar{x}$ = Mittelwert der beeinflussenden Eigenschaft

Überblick: Bivariate Regressionen

Wir testen die Beziehung zwischen Zufriedenheit mit Singlestatus mit verschiedenen Eigenschaften über eine Reihe bivariater Regressionen:

Einflüsse auf die Zufriedenheit mit Singlestatus

Prädiktor	Koeffizient (β)	Standardfehler (SE)	95%-Konfidenzintervall	R^2 (Modellgüte)
Weiblich	0.6433	0.0305	[0.5835, 0.703]	0.0165
Osten	0.2647	0.0420	[0.1823, 0.347]	0.0015
Alter	0.0131	0.0015	[0.0101, 0.0161]	0.0027

Beispielrechnung für β Alter

Das einfache lineare Regressionsmodell ist:

$$\text{Zufriedenheit mit Singlestatus}_i = \beta_0 + \beta_1 \times \text{Alter}_i + \varepsilon_i$$

Schritt 1: Daten zusammenfassen

```
n = 158332
```

```
Mittelwert Alter = 35.74
```

```
SD Alter = 9.22
```

Schritt 2: Regressionsgleichung

```
sat2 = 5.4904 + 0.0131 × age + ε
```

```
Interpretation des Slopes:
```

- Pro Lebensjahr steigt die Zufriedenheit mit dem Singlestatus um 0.0131 Punkte

- 10 Jahre älter → Zufriedenheit um 0.1312 Punkte höher

Schritt 3: Standardfehler des Koeffizients

Der Standardfehler misst die Unsicherheit der Schätzung:

$$\mathrm{SE}(\beta_1) = \sqrt{\frac{\sigma^2}{\sum (x_i - \bar{x})^2}}$$

Berechnung:

σ² = RSS / (n - k) = 165807.9 / 26518 = 6.2527

Σ(age - mean)² = 13471999

SE(β₁) = √(6.2527 / 13471999) = 0.000681

Schritt 4: Konfidenzintervall berechnen

$$\text{CI} = \hat{\beta}_1 \pm t_{\text{kritisch}} \times \text{SE}(\hat{\beta}_1)$$

```
Untere Grenze = 0.0131 - 1.9601 × 0.000681

              = 0.0131 - 0.0013

              = 0.0118

Obere Grenze  = 0.0131 + 1.9601 × 0.000681

              = 0.0131 + 0.0013

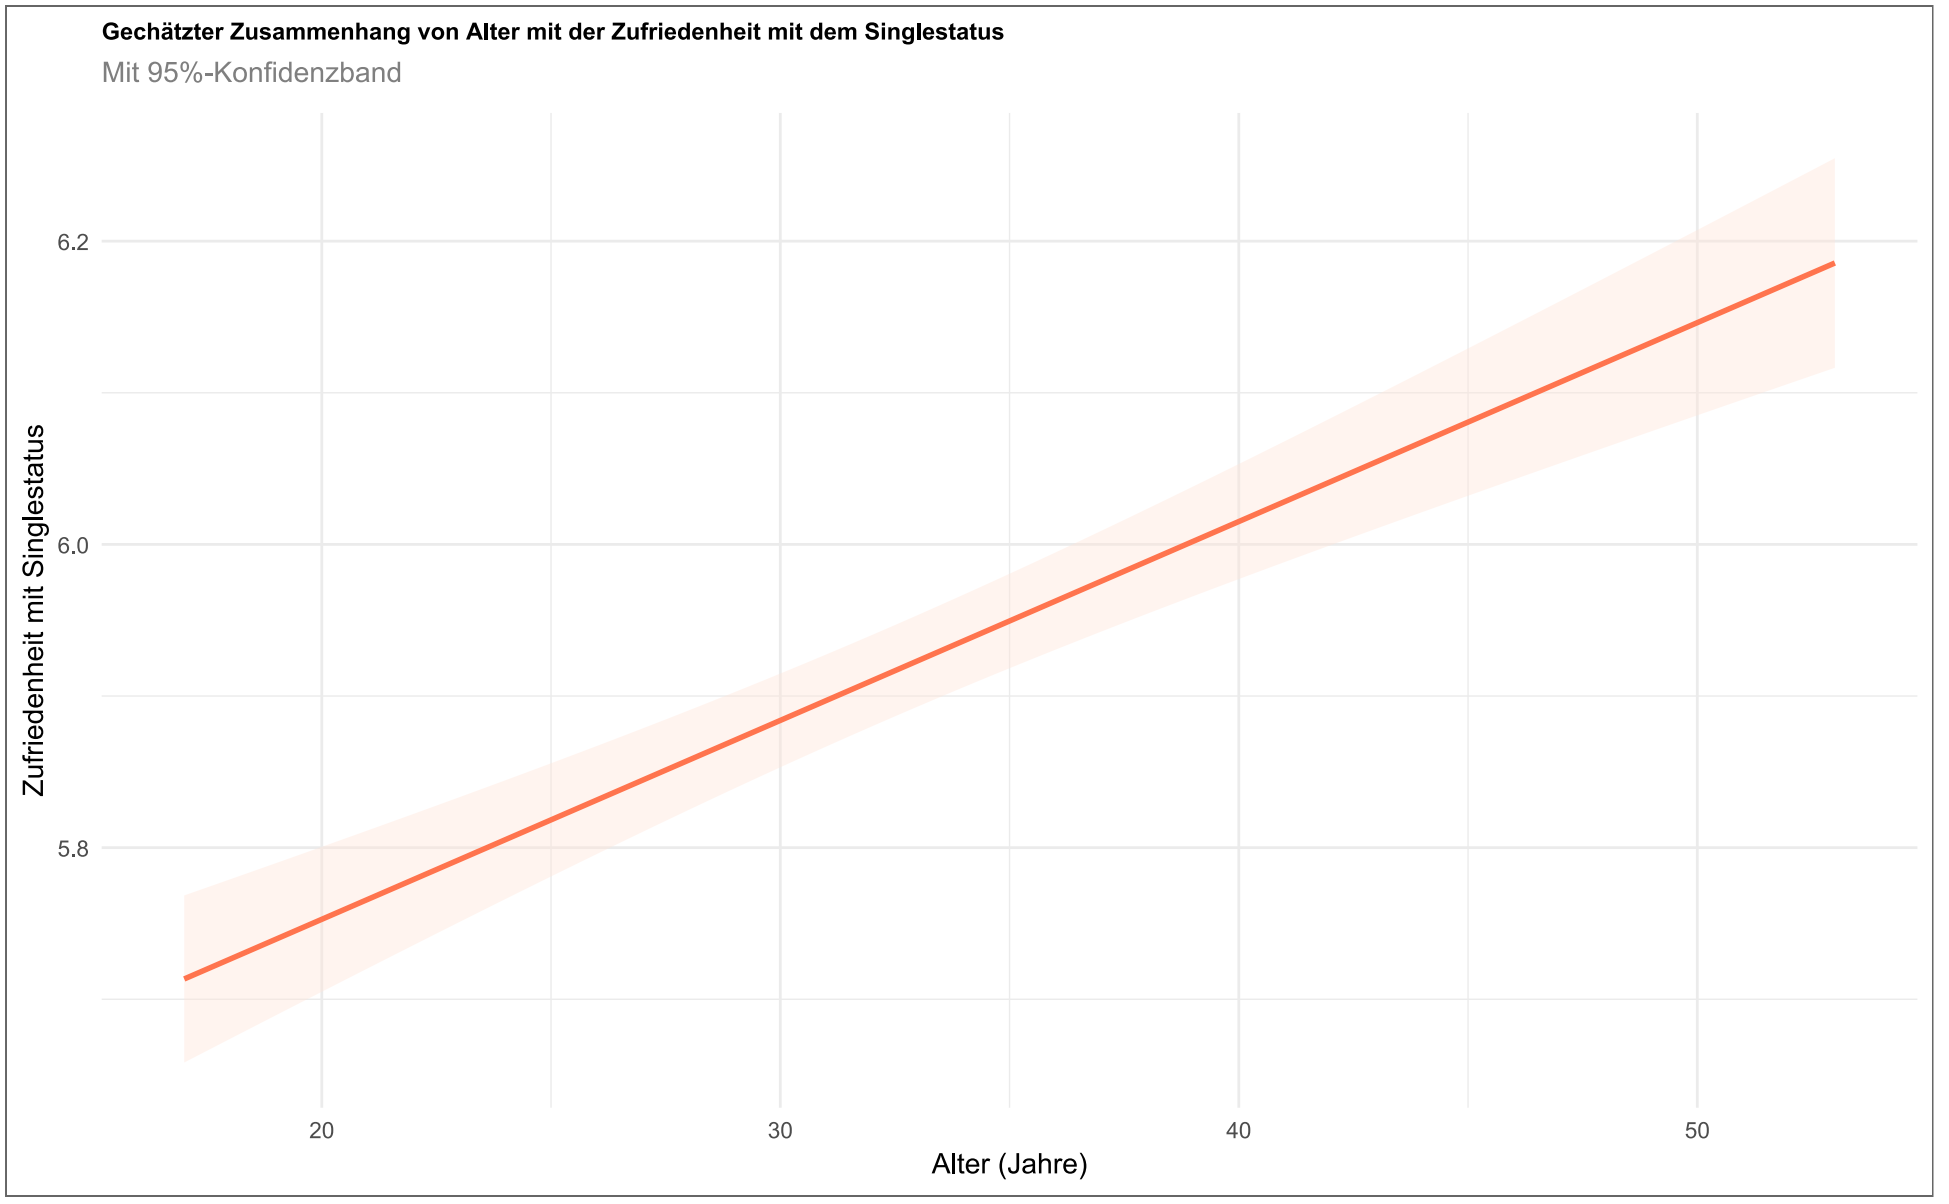
              = 0.0145

95%-KI: [ 0.0118 , 0.0145 ]
```

Wenn wir unendlich viele Stichproben wie FREDA ziehen würden, können wir erwarten, dass 95% aller nicht extremen Unterschiede aller $\hat{\beta}$-Koeffizienten für Alter im Bereich

[0.0118 , 0.0145] liegen.

Visualisierung


Gechätzter Zusammenhang von Alter mit der Zufriedenheit mit dem Singlestatus
Mit 95%-Konfidenzband
Zufriedenheit mit Singlestatus
6.2
6.0
5.8
20
30
40
50
Alter (Jahre)

Das multivariate Modell

$$
\begin{aligned}
\text{Zufriedenheit als Single}_i = \beta_0 \\
&+ \beta_{\text{Alter}} \\
&+ \beta_{\text{Frau}} + \beta_{\text{Ost}} + \beta_{\text{Frau X Ost}} \\
&+ \beta_{\text{Offen}} + \beta_{\text{Anbahnend}} + \beta_{\text{On-Off}} + \beta_{\text{Freundschaft Plus}} + \beta_{\text{So}} \\
&+ \varepsilon_i
\end{aligned}
$$

- Region und Geschlecht bilden einen Interaktionseffekt
- “kein Interesse” ist Referenzkategorie für die Beziehungskategorie

Regressionsergebnisse

Ergebnisse des multivariaten Regressionsmodells

Variabel	Koeffizient (β)	Standardfehler (SE)	95%-Konfidenzintervall
Konstante	7.46	0.08	[7.31, 7.62]
Frau	0.43	0.04	[0.36, 0.51]
Osten	0.25	0.07	[0.12, 0.38]
Alter	0.00	0.00	[0, 0.01]
Offen für Beziehung	-2.45	0.05	[-2.54, -2.36]
Anbahnende Beziehung	-1.95	0.08	[-2.1, -1.79]
On-off-Beziehung	-3.52	0.17	[-3.86, -3.18]
Freundschaft Plus	-1.42	0.07	[-1.56, -1.28]

Variabel	Koeffizient (β)	Standardfehler (SE)	95%-Konfidenzintervall
Sonstiges	-2.69	0.11	[-2.9, -2.48]
Interaktion: Frau × Osten	-0.05	0.09	[-0.24, 0.13]

Anhang

Wichtige Standardfehler

Standardfehler für Wahrscheinlichkeitsdifferenzen

$$SE_{p_1 - p_2} = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$$

Standardfehler für Varianzen

$$SE_{\sigma^2} = \sqrt{\frac{2\sigma^4}{n-1}}$$

wobei:
σ^2 = Varianz der Grundgesamtheit n = Stichprobengröße

Standardfehler für Odds

$$SE_{\text{Odds}} = \frac{\sqrt{\frac{p(1-p)}{n}}}{(1-p)^2}$$

wobei: p = Wahrscheinlichkeit in der Grundgesamtheit n = Stichprobengröße

Die 2×2 Kontingenztabelle

Zunächst betrachten wir die Häufigkeitsverteilung von “Freundschaft Plus” nach Geschlecht:

2×2 Kontingenztabelle: Freundschaft Plus nach Geschlecht

	Freundschaft Plus	Nicht Freundschaft Plus	Gesamt
Weiblich	828	7928	8756
Männlich	711	7929	8640
Gesamt	1539	15857	17396

Notation für die Berechnung: - a = 828 (Frauen in Freundschaft Plus) - b = 7928 (Frauen nicht in Freundschaft Plus) - c = 711 (Männer in Freundschaft Plus) - d = 7929 (Männer nicht in Freundschaft Plus)

Schritt 1: Odds für jedes Geschlecht berechnen

Die **Odds** ist das Verhältnis der Wahrscheinlichkeit eines Ereignisses zur Wahrscheinlichkeit, dass es nicht eintritt.

Odds für Frauen

$$\text{Odds}_{\text{Frauen}} = \frac{\text{Frauen in FP}}{\text{Frauen nicht in FP}} = \frac{828}{7928} = 0.1044$$

Interpretation: Von 100 Frauen, die nicht in “Freundschaft Plus” sind, haben etwa 10 Frauen diese Beziehungsform.

Odds für Männer

$$\text{Odds}_{\text{Männer}} = \frac{\text{Männer in FP}}{\text{Männer nicht in FP}} = \frac{711}{7929} = 0.0897$$

Interpretation: Von 100 Männern, die nicht in “Freundschaft Plus” sind, haben etwa 9 Männer diese Beziehungsform.

Schritt 2: Odds Ratio berechnen

Die **Odds Ratio** vergleicht die Odds zwischen den beiden Gruppen:

$$\text{OR} = \frac{\text{Odds}_{\text{Frauen}}}{\text{Odds}_{\text{Männer}}} = \frac{0.1044}{0.0897} = 1.165$$

Interpretation: Frauen haben eine **1.16-mal höhere Odds**, in “Freundschaft Plus” zu sein als Männer.

Schritt 3: Logarithmus nehmen

Für die Konfidenzintervall-Berechnung transformieren wir auf die logarithmische Skala:

$$\log(\text{OR}) = \log(1.165) = 0.1525$$

Warum Logarithmus? - Das Konfidenzintervall ist auf der log-Skala *symmetrisch* - Die Normalverteilungs-Annahme passt besser - Nach der Berechnung transformieren wir zurück mit exp()

Schritt 4: Standardfehler des log(OR)

Der Standardfehler quantifiziert, wie genau unsere Schätzung ist:

$$SE[\log(\mathrm{OR})] = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

Berechnung im Detail:

$$SE[\log(\mathrm{OR})] = \sqrt{\frac{1}{828} + \frac{1}{7928} + \frac{1}{711} + \frac{1}{7929}}$$

$$= \sqrt{0.001208 + 0.000126 + 0.001406 + 0.000126}$$

$$= \sqrt{0.002866} = 0.0535$$

Interpretation: Mit dieser Genauigkeit schätzen wir das log(OR).

Schritt 5: Kritischer z-Wert für 90% KI — Warum Normalverteilung?

Das zentrale Problem

Die **Odds Ratio selbst** ist NICHT normalverteilt: - Sie ist immer positiv (0 bis ∞) - Sie ist schief (asymmetrisch) - Das Konfidenzintervall würde asymmetrisch ausfallen

Die Lösung: Logarithmische Transformation

Durch den **Logarithmus** transformieren wir die Odds Ratio so, dass sie normalverteilt wird:

$$\mathrm{OR} \in (0, \infty) \xrightarrow{\log()} \log(\mathrm{OR}) \in (-\infty, +\infty)$$

Das $\log(\mathrm{OR})$ ist **asymptotisch normalverteilt** — und zwar aufgrund des **Zentralen Grenzwertsatzes**:

> Der SE des log(OR) ist eine Summe von Termen: $SE = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$

> Nach dem Zentralen Grenzwertsatz wird die Summe unabhängiger Zufallsvariablen asymptotisch normalverteilt, **unabhängig von ihrer einzelnen Verteilung**.

Praktische Anwendung

Für größere Stichproben (wie unsere mit n = 17,396) gilt:

$$\frac{\log(\text{OR}) - \log(\text{wahrer OR})}{\text{SE}[\log(\text{OR})]} \sim N(0,1)$$

Daher verwenden wir für ein **90%-Konfidenzintervall** den kritischen Wert $z = 1.645$:

$$P(-1.645 \leq Z \leq 1.645) = 0.90$$

Das bedeutet: 5% der Fläche liegt in jedem Schwanz der Normalverteilung (α/2 = 0.05).

Schritt 6: Konfidenzintervall auf log-Skala berechnen

Untere Grenze:

$$\log(\mathrm{OR}) - z \times SE[\log(\mathrm{OR})] = 0.1525 - 1.645 \times 0.0535 = 0.0644$$

Obere Grenze:

$$\log(\mathrm{OR}) + z \times SE[\log(\mathrm{OR})] = 0.1525 + 1.645 \times 0.0535 = 0.2405$$

90%-KI auf log-Skala: $[0.0644, 0.2405]$

Schritt 7: Zurück transformieren (Exponentialisieren)

Zum Schluss exponentialisieren wir, um auf die OR-Skala zurückzukehren:

Untere Grenze:

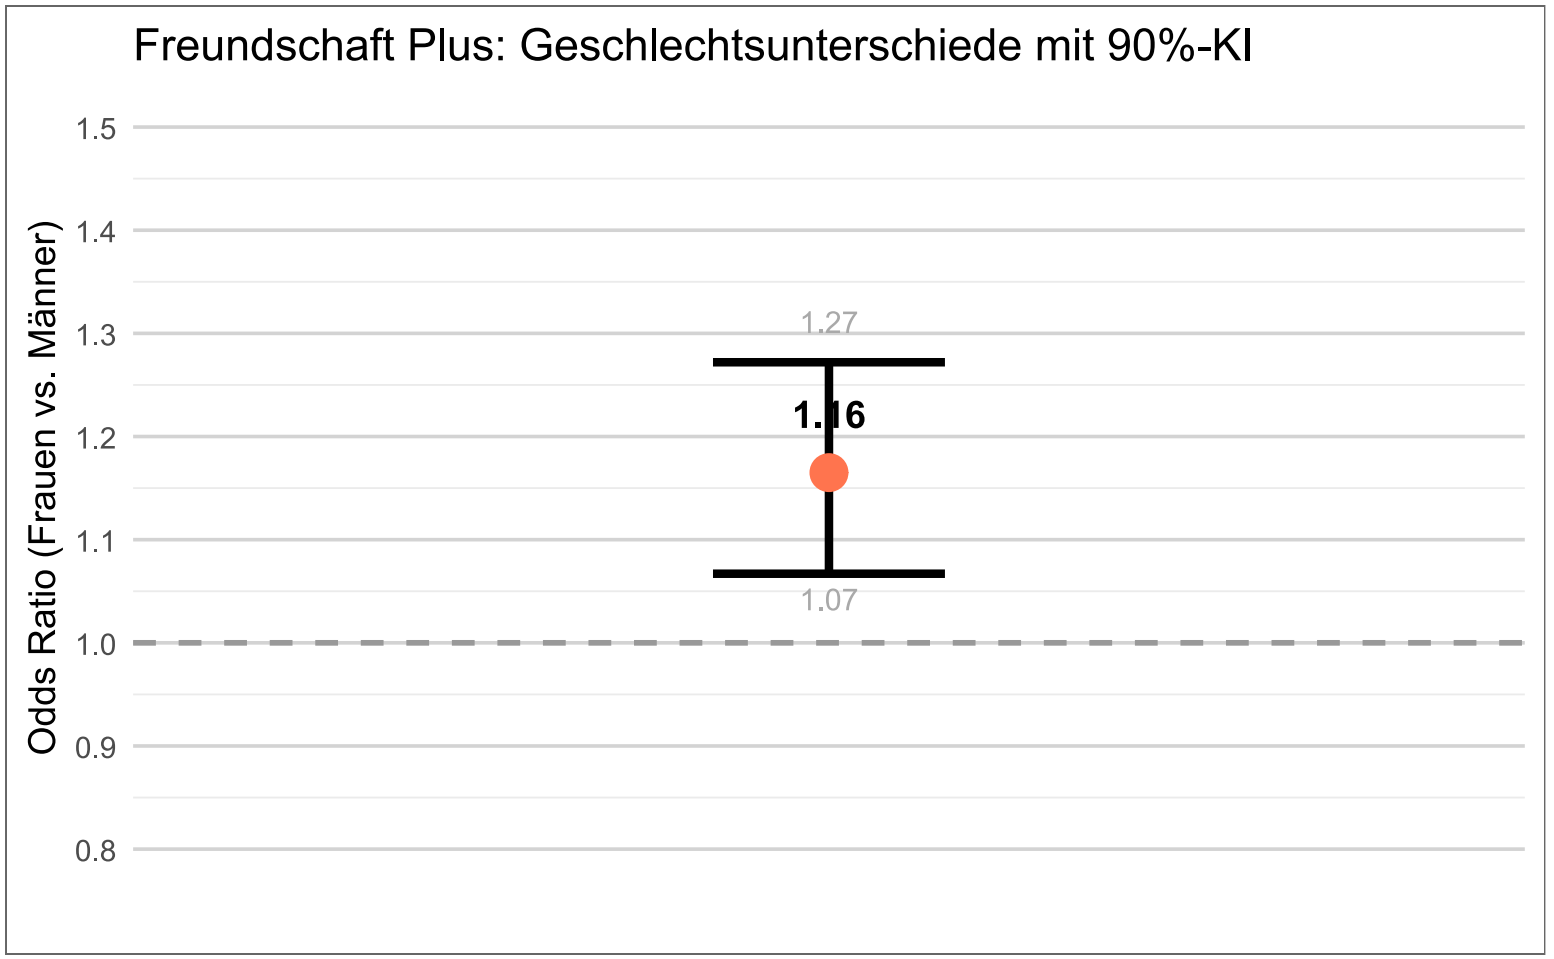
$e^{0.0644} = 1.067$

Obere Grenze:

$e^{0.2405} = 1.272$

90%-Konfidenzintervall auf OR-Skala: $[1.07, 1.27]$

Visuelle Darstellung



Berechnung des Konfidenzintervalls bei multivariaten Regressionskoeffizienten

Wir verdeutlichen die Berechnung des Konfidenzintervalls für Alter im multivariaten Kontext.

Schritt 1: Multivariate vs. Bivariate Effekte

```
BIVARIATE REGRESSION (sat2 ~ age):

  β = 0.0169 (SE = 0.0019 )

  Signifikant: JA (p < 0.001)

MULTIVARIATE REGRESSION (kontrolliert für sex, east, sin11_cat):

  β = 0.0027 (SE = 0.0018 )

  Signifikant: NEIN (p = 0.130)
```

DIFFERENZ:

$\Delta\beta = 0.0142$

(Dies ist der Confounding-Effekt durch sin11_cat)

Schritt 2: Interpretation des multivariaten Koeffizients

Der Koeffizient 0.0027 ist der **partielle Effekt**:

- **Definition:** Effekt von age auf sat2, *nachdem* alle anderen Variablen kontrolliert wurden
- **Praktisch:** Mit der obigen Formel: Für jedes Lebensjahr mehr steigt sat2 um 0.0027 Punkte (wenn sex, east, sin11_cat konstant bleiben)

Schritt 3: Standardfehler im multivariaten Modell

$$\mathrm{SE}(\beta_1)_{\text{multi}} = \sqrt{\frac{\sigma^2_{\text{multi}}}{\sum (x_i - \bar{x})^2 \times (1 - R^2_{1|others})}}$$

Schritt 4: t-Statistik und Signifikanz

```
t = β / SE =  0.0027  /  0.0018  =  1.5152
```

```
p-Wert =  0.1297399
```

```
Interpretation:
```

- t = 1.5152 ist relativ klein
- p = 0.1297 > 0.05

✗ NICHT statistisch signifikant (nach Kontrolle)

Schritt 5: Kritischer t-Wert

```
df = n - k =  17327  -  10  =  17317

t_0.025(df) = 1.9601

(≈ 1.96 bei großem df)
```

Schritt 6: Konfidenzintervall berechnen

$$\mathrm{CI} = \hat{\beta}_{\mathrm{age}} \pm t_{\mathrm{crit}} \times \mathrm{SE}(\hat{\beta}_{\mathrm{age}})$$

```
Untere Grenze =  0.0027  -  1.9601  ×  0.0018

              =  0.0027  -  0.0035

              =  -8e-04

Obere Grenze  =  0.0027  +  1.9601  ×  0.0018

              =  0.0027  +  0.0035

              =  0.0062

95%-KI: [ -8e-04 ,  0.0062 ]
```

Speaker notes